基于深度 Q 网络改进交通信号灯控制设计与实现

于 荣[1], 郑 福[*,2]

(1. 海南大学 网络空间安全学院, 海南 海口 570228; 2. 海南大学 数学与统计学院, 海南 海口 570228)

摘 要: 交通拥堵是全球许多城市面临的重大挑战. 通过采用深度 Q 网络(DQN)优化交通信号灯控制, 旨在减少车辆等待时间, 提高交通流量. 研究方法包括将交通信号灯控制问题转化为强化学习问题, 利用 DQN 算法自适应学习优化策略. 实验结果表明, 改进后的 DQN 算法在减少车辆等待时间和提高通行效率方面表现优异, 整体效率提升了 20% 以上. 通过仿真实验验证了改进算法的有效性, 为城市交通管理提供了新的解决方案.

关键词: 深度 Q 网络; 交通信号灯; 强化学习; 优化控制

中图分类号: R373.9 **文献标识码**: A **文章编号**: 1673 - 0569(2025)02 - 0134 - 08

DOI:10.13831/j.cnki.issn.1673-0569.2025.02.006

0 引言

交通拥堵是全球许多城市面临的重大挑战, 随着城市化进程的加快, 这一问题变得愈发严重. 根据统计, 交通拥堵导致的经济损失每年高达数十亿美元, 同时也增加了环境污染和社会压力. 交通信号灯作为城市交通管理的重要工具, 其优化对缓解交通拥堵具有重要意义. 然而, 现有的交通信号控制方法, 如定时控制和自适应控制[1], 在面对复杂多变的交通环境时表现出明显的局限性, 难以实现最佳控制效果.

交通信号控制的优化一直是城市交通管理的重要研究方向. 传统方法主要包括定时控制和自适应控制. 定时控制通过预设的信号灯切换时间进行控制, 适用于交通流量相对稳定的区域. 然而, 这种方法在应对动态变化的交通环境时表现不佳. 自适应控制如悉尼协调自适应交通系统(Sydrey coordinated adaptive traffic system, SCATS)和绿信比 - 周期 - 相位差优化技术(split-cycle-offset optimization technique, SCOOT)[2], 可以根据实时交通流量数据进行调整, 虽然提高了交通效率, 但需要复杂的硬件和软件支持, 实施成本较高. 也有学者提出基于模糊蚁群算法的城市交通网络节点分配优化策略[3], 能够提升一定的效率, 但有一定的局限性. 强化学习是一种动态生成控制策略的方法, 它允许一个或多个智能体通过与环境互动获得的经验来学习如何解决环境中的具体任务. 在交通信号控制领域, 早期的强化学习方法很大程度上依赖于手工提取特征, 这不仅需要大量的人力资源, 而且状态的稳定性较差, 容易导致关键状态信息的丢失. 近年来, 随着 AlphaGo 等项目的成功, 强化学习领域越来越受到人们的关注, 并激发了更多的研究兴趣. 尤其是 Q 学习[4], 近年来在交通信号控制中得到了广泛关注. Q 学习通过构建状态 - 动作值函数(Q 函数)来评估每个动作的长期回报, 从而找到最优策略. 尽管 Q 学习在简单的交通环境中表现良好, 但在面对大规模、复杂交通网络时效率较低. 深度 Q 网络(Deep Q Network, DQN)结合了深度神经网络和 Q 学习, 能够处理高维度的状态空间, 适用于复杂的交通环境. 近期研究显示, DQN 在交通信号控制中具有较大的潜力. Li 等[5]提出的基于 DQN 的交通信号控制方法, 在模拟环境中显著减少了车辆的平均等待时间; Gao 等[6]采用 DQN 优化多交叉口信号灯控制, 提升

收稿日期: 2024 - 11 - 25.

基金项目: 国家自然科学基金项目(12371446); 海南省自然科学基金项目(123MS004).

作者简介: 于荣(1999—), 男, 海南大学硕士研究生, 主要从事网络空间安全方面的研究.

通信作者: 郑福, fuzheng@ hainanu. edu. cn.

中国知网 https://www.cnki.net

了整体交通流量. 然而,在现有研究中,DQN 的训练效率、稳定性和泛化能力仍存在一定的局限性.

本文提出了一种改进的 DQN 算法,通过优化网络结构和经验回放机制[7],提高了训练效率和稳定性. 在理论上,丰富了基于强化学习的交通信号控制方法;在实践上,提供了一个可行的解决方案,有助于提高城市交通管理的效率.

1　算法模型与改进设计

在本文中,智能体通过与周围环境的互动来学习制定最优策略[8]. 这种互动是通过一个微观交通模拟系统来实现的,该系统允许智能体在多种情境下进行实践,并在模拟过程中识别出哪些因素会导致错误的信号灯相位被激活. 在强化学习框架[9]下,智能体被赋予 3 个基本特性:状态空间、动作空间以及奖励函数(图 1).

1.1　状态空间

近期的研究在交通信号灯控制领域提出了一些包含大量信息的状态描述方法,但这些方法需要收集的数据在实际中难以获取,导致它们难以被实施. 相比之下,智能体在某一特定时间点对环境状态的感知采用了一种简洁且易于操作的状态表示技术,这种方法增加了获得积极成果的机会. 在每个交叉口的各个方向上,进入交叉口的车辆被划分到不同的单元格中,并且这些单元格能够检测到是否有车辆存在. 通过将路面情况离散化来表示环境状态,目的是让智能体能够了解在特定时刻车辆的分布情况.

1.2　动作空间

动作集合定义了智能体与环境互动的可选方式,它指的是对交通信号灯的一系列设置. 执行特定的操作即意味着在特定的一组车道上激活绿灯,并持续一定的时间. 以下是智能体可以执行的所有可能操作的描述.

(1)东西向直行和右转:启动绿灯阶段,允许在东西向行驶且计划直行或右转的车辆通过.

(2)东西向左转:启动绿灯阶段,专为在东西向行驶且需要左转的车辆设置.

(3)南北向直行和右转:启动绿灯阶段,允许在南北向行驶且计划直行或右转的车辆通过.

(4)南北向左转:启动绿灯阶段,专为在南北向行驶且需要左转的车辆设置.

1.3　奖励函数

奖励函数设计为负的总等待时间,即通过减少车辆的等待时间来获得更高的奖励公式为:$R = \sum_{i=1}^{N} W_i(t)$,其中 $W_i(t)$ 表示第 i 辆车在时间 t 的等待时间,N 为当前所有等待车辆的数量.

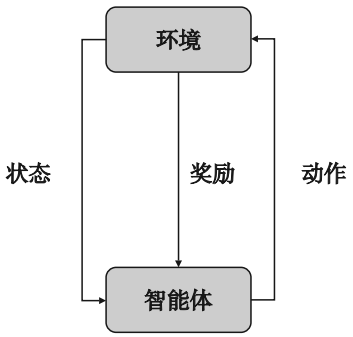

图 1　强化学习基本模型示意图

1.4　改进后 DQN 算法

在传统的 Q 学习[10]中,智能体通过更新 Q 值函数来学习最优策略. Q 值函数的更新依赖于当前输

中国知网　https://www.cnki.net

出值和目标值,其中目标值通常由下一个状态的 Q 值函数输出的最大动作值来近似. 更新公式如下:

$$Q(s_t,a_t)=Q(s_t,a_t)+\alpha(r_{t+1}+\gamma\max_A Q(s_{t+1},a_{t+1})-Q(s_t,a_t))$$

其中:α 是学习率,r_{t+1}是与在状态 s_t 采取行动相关的奖励,$Q(s_{t+1},a_{t+1})$ 表示近期未来的 Q 值,s_{t+1}是环境在状态 s_t 选择动作后的下一个状态,γ 是介于 0 和 1 之间的折扣因子,用于降低未来奖励的重要性. 然而,这种更新方式可能导致智能体对动作值的过高期望,引发过估计问题,从而降低学习效率. 高估偏差在现实世界并不均匀,这可能会影响策略决策,不是最优策略(表 1).

表 1 改进 DQN 算法流程

改进 DQN 算法流程
初始化:初始化 DQN 网络参数和经验池
训练过程:
获取当前状态
根据 ε - greedy 策略选择动作
执行动作,获取奖励和新状态
将经验存储到经验池中
从经验池中随机抽取小批量数据进行训练,更新网络参数
定期更新目标网络参数
策略改进:采用 ε - greedy 策略,在训练过程中逐渐减少 ε 值,从而实现探索和利用的平衡

在文献[11]介绍了一个优化后的公式,表达式如下:

$$Q(s_t,a_t)=r_{t+1}+\gamma\max_A Q'(s_{t+1},a_{t+1})$$

其中:r_{t+1}是在状态 s_t 下执行动作后获得的奖励,$Q(s_t,a_t)$表示在状态 s_{t+1}下的 Q 值,即动作执行后的下一状态的 Q 值,折扣因子 γ 用于表示未来奖励相对于即时奖励的减少程度. 该公式描述了如何结合即时奖励和未来动作的折扣 Q 值来更新当前状态下动作的 Q 值. $Q'(s_{t+1},a_{t+1})$表示未来动作的潜在价值,它基于 s_{t+1}之后的最大折扣回报,即 $Q''(s_{t+2},a_{t+2})$. 同样地,$Q''(s_{t+2},a_{t+2})$也包含了到达下一个状态的最大折扣回报,即 $Q'''(s_{t+3},a_{t+3})$. 这表明智能体在选择动作时,不仅考虑即时奖励,还考虑了预期的未来折扣奖励. 在模拟过程中,智能体逐步学习动作序列的价值. 最终目标是选择一系列动作,以实现累积回报最大化,从而达到最佳性能.

本文采用的经验回放技术是一种在训练过程中用于增强智能体性能和学习效率的方法. 这种技术不是立刻使用智能体在模拟中获得的数据(在线学习方式),而是将这些数据以随机样本组的形式分批提供给智能体,这些样本组被称为批量处理. 这些批量处理的数据源自一个叫作内存的数据结构,它在训练期间保存了所有收集到的样本. 每个样本由 4 个元素组成,记为 $m=\{s_t,a_t,r_{t+1},s_{t+1}\}$,其中 r_{t+1},s_{t+1}是在采取动作后从状态获得的奖励,这个奖励导致了环境状态转移到下一个状态 s_{t+1}(图 2).

2 仿真实验

2.1 仿真环境

城市交通仿真(simulation of urban mobility,SUMO)[12]是一种交通仿真软件,在实验中用来模拟如图 3 所示的双向单交叉口. 0 到 15 的数字是车道编号用黄色标记的车道被称为受控车道,意味着这些车道由交通信号灯控制. 交叉口中的线条表示车辆可能的行驶路线,按顺时针方向用 0 到 11 的编号来标记这些路线. 相位决定了在每条路线上是否允许车辆通过,相位状态是针对 12 条路线的交通信号控制,路线编号依次递增. 字母 R、Y、G 分别代表红色、黄色和绿色的交通信号灯. 通过切换相位,交通信号灯能够控制交叉口的交通流. 在设置好道路网络和需求之后,就构建了交通交叉口的仿真.

中国知网 https://www.cnki.net

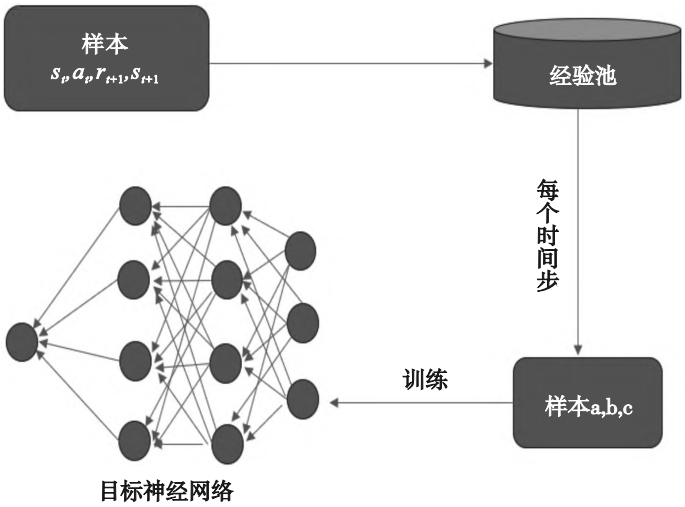

图 2　内存样本交互模型示意图

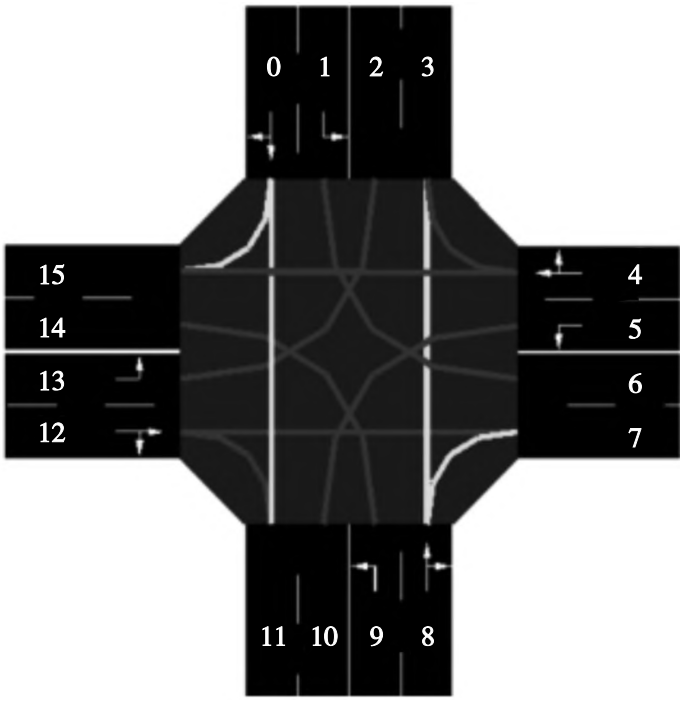

图 3　交通路网示意图

2.2　模型训练参数

在本模型中,所有参数配置保持一致. 经验回放缓冲区的容量设定为 20 000,批量处理的样本数量为 64,开始时的探索概率设为 1,探索概率的下限为 0.01,探索概率以 0.001 的速度递减,折扣因子设为 0.99,学习率设置为 0.001,神经网络为 4 层,每层包含 400 个神经元,而目标网络的更新频率为 0.001.

2.3　对比实验及评价指标

在各种参数保持一致的条件下,对比传统 DQN 算法和改进后 DQN 算法在评价指标上的差异. 评价指标设置了 3 种,通行时间:车辆通过交叉口的平均时间;平均速度:车辆通过交叉路口时的平均行

中国知网　https://www.cnki.net

驶速度;排队长度:红灯时排队车辆的平均长度.

3 实验结果分析

在本研究中,交通环境和神经网络的参数被设定为一致,共进行了10轮同步仿真实验.在这些实验中,记录了每个迭代轮次的通行时间、平均速度和排队长度.通过对这些数据的处理,得到了传统DQN算法和改进DQN算法信号控制方法的仿真结果.

每轮仿真实验包含200个训练轮次.从图4~图9可以看出,传统DQN算法由于智能体在训练初

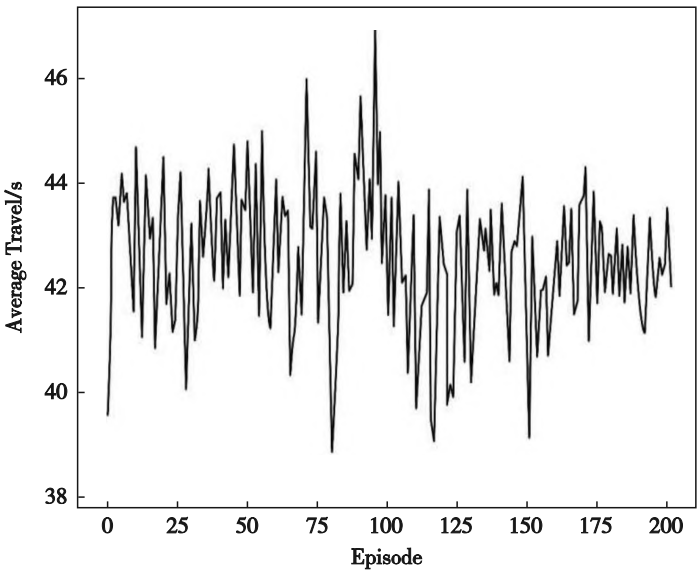

图4 传统DQN车辆平均通行时间与训练轮次数曲线

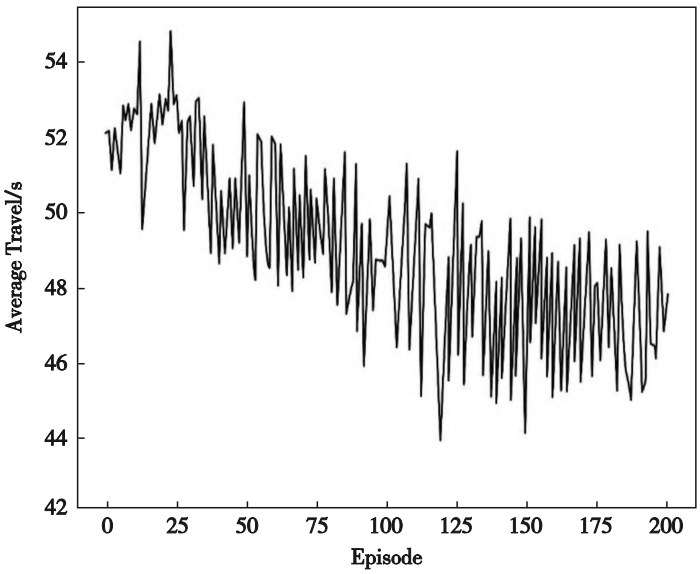

图5 传统DQN车辆平均排队长度与训练轮次数曲线

中国知网 https://www.cnki.net

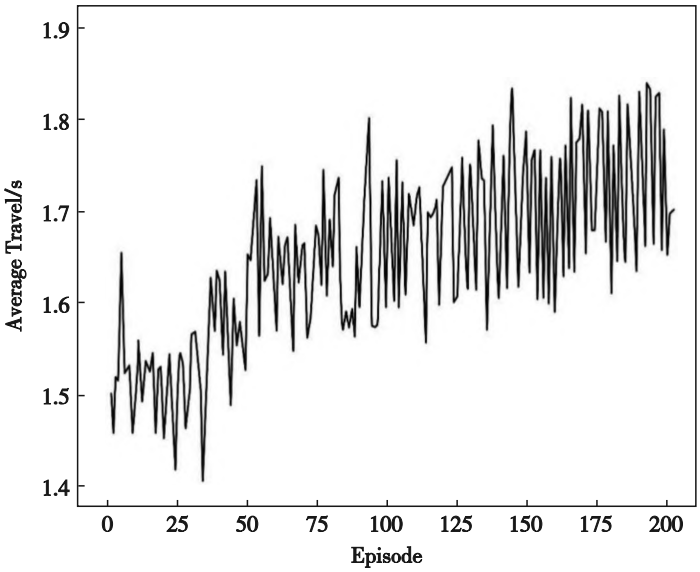

图 6　传统 DQN 车辆平均速度与训练轮次数曲线

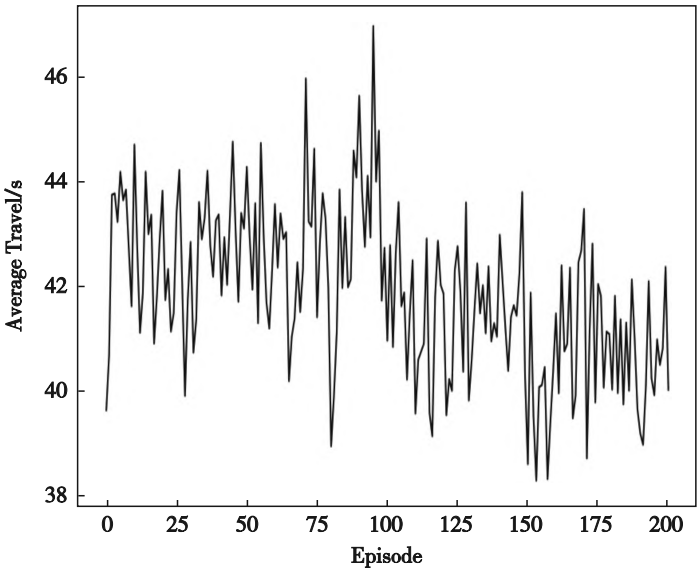

图 7　改进 DQN 车辆平均通行时间与训练轮次数曲线

期采取的探索策略,可能导致选择不合理的随机动作,因此交叉口的通行时间较长,排队长度较大,平均速度较低. 随着训练轮次的增加,智能体逐渐倾向于利用策略,神经网络也开始趋于稳定,在第 200 个轮次通行时间达到 42 s,排队长度达到 48 m,平均速度达到 1.65 m/s. 作为对比,改进后的 DQN 算法虽然在训练初期和传统 DQN 算法效果区别不大,但到第 200 轮次时,通行时间达到 40 s,排队长度达到 45 m,平均速度达到 1.8 m/s. 最终,通行时间比传统 DQN 算法提升了 5%,排队长度比传统 DQN 算法提升了 6%,平均速度比传统 DQN 算法提升了 10%,这说明改进后的 DQN 算法取得了一定的效果(表 2).

中国知网　https://www.cnki.net

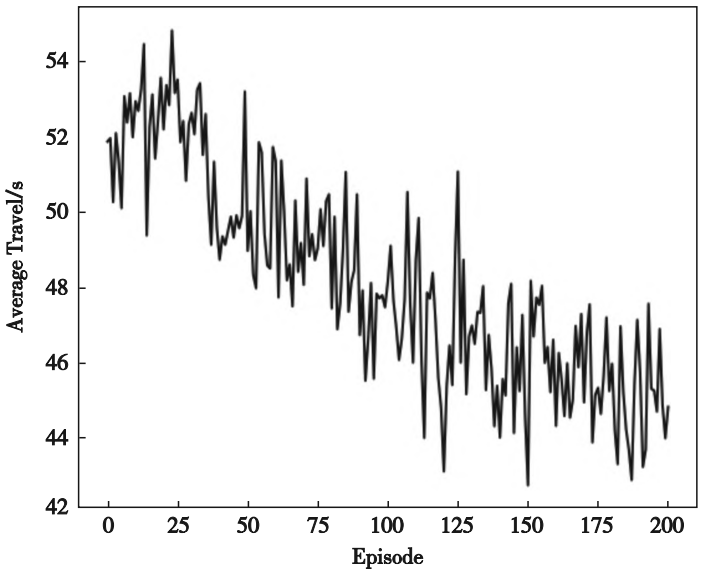

图8 改进DQN车辆平均排队长度与训练轮次曲线

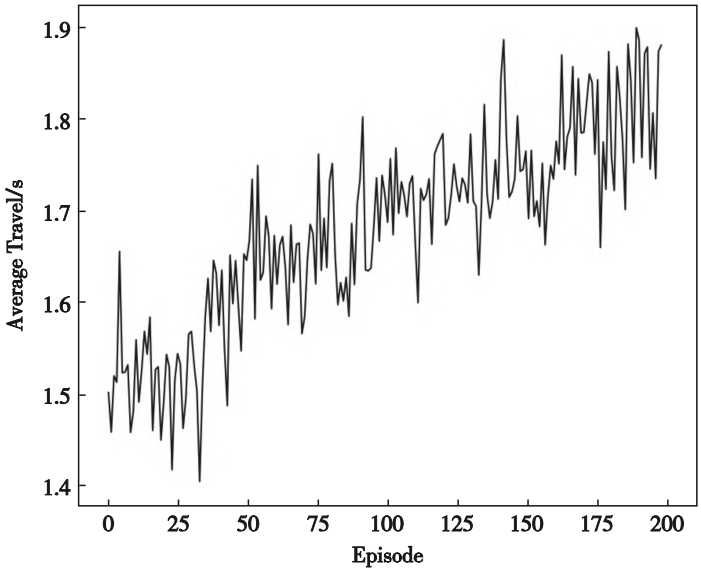

图9 改进DQN车辆平均速度与训练轮次曲线

表2 不同方式下的路网评价指标对比

评价指标	传统DQN	改进DQN
排队长度/m	48	45
通行时间/s	42	40
平均速度/($m \cdot s^{-1}$)	1.65	1.85

4 小结

本研究旨在通过改进DQN算法,优化城市交通信号灯控制.研究表明,改进后的DQN算法在减少

中国知网 https://www.cnki.net

车辆等待时间、提高交通流量和缩短排队长度方面表现优异. 具体而言,通过优化网络结构、引入优先经验回放机制和改进奖励函数,显著提高了模型的训练效率和稳定性. 研究成果展示了改进 DQN 算法在实际交通管理中的潜在应用价值. 通过优化交通信号灯控制,可以有效提高城市交通效率,减少交通拥堵,从而降低交通管理成本.

参考文献

[1] PORCHE I,LAFORTUNE S. Adaptive look-ahead optimization of traffic signals[J]. ITS Journal-Intelligent Transportation Systems Journal,1999,4(3/4):209-254.

[2] HUNT P B,ROBERTSON D I,BRETHERTON R D,et al. SCOOT—a traffic responsive method of coordinating signals [J]. Systems,1981,2(2):164-173.

[3] 邵东波,杨春林,钱平,等. 基于模糊蚁群算法的城轨交通网络节点分配优化策略[J]. 渤海大学学报(自然科学版),2022,43(1):83-88.

[4] SUTTON R S,BARTO A G. Reinforcement Learning:an Introduction[M]. Cambridge,MA:MIT Press,2018.

[5] LI L,LYU Y S,WANG F Y. Traffic signal timing via deep reinforcement learning[J]. IEEE/CAA Journal of Automatica Sinica,2016,3(3):247-254.

[6] GAO J,SHEN Y,LIU J,et al. Adaptive traffic signal control:deep reinforcement learning algorithm with experience replay and target network[J]. Acta Automatica Sinica,2020,46(3):1-10.

[7] SCHAUL T,QUAN J,ANTONOGLOU I,et al. Prioritized experience replay[J]. arXiv preprint arXiv:1511.05952,2015.

[8] 张洪森,刘 添,赵玉红,等. 智能交通信号灯的研究与设计[J]. 工业控制计算机,2020,33(10):132-133.

[9] GE Z Y. Reinforcement learning-based signal control strategies to improve travel efficiency at urban intersection[C]//2020 International Conference on Urban Engineering and Management Science (ICUEMS). Zhuhai,China. IEEE,2020:347-351.

[10] 刘成健,罗 杰. 基于参数融合的 Q 学习交通信号控制方法[J]. 计算机技术与发展,2018,28(11):48-51.

[11] 赵纯,董小明. 基于深度 Q-Learning 的信号灯配时优化研究[J]. 计算机技术与发展,2021,31(8):198-203.

[12] ECLIPSE F. SUMO-simulation of urban mobility[EB/OL]. [2024-05-20]. https://www.eclipse.org/sumo.

Research and implementation of traffic signal control based on Deep Q-Network algorithm optimization

YU Rong[1],ZHENG Fu[2]

(1. College of Cyber and Security,Hainan University,Haikou 570228,China;
2. College of Mathematics and Statistics,Hainan University,Haikou 570228,China)

Abstract: Traffic congestion is a major challenge faced by many cities around the world. This paper aims to reduce vehicle waiting times and improve traffic flow by optimizing traffic signal control using Deep Q-Networks (DQN). The method includes modeling the traffic signal control problem as a reinforcement learning problem and using the DQN algorithm to adaptively learn and optimize the strategy. The experimental results show that the improved DQN algorithm performs excellently in reducing vehicle waiting times and improving traffic efficiency, with an overall efficiency improvement of more than 20%. The validity of the improved algorithm was verified through simulation experiments, providing a new solution for urban traffic management.

Key words: Deep Q-Network;traffic lights;reinforcement learning;optimal control

中国知网　https://www.cnki.net