文章编号:1009-6744(2025)04-0063-10 中图分类号:U491.5 文献标志码:A
DOI:10.16097/j.cnki.1009-6744.2025.04.007

基于深度强化学习的城市交通信号分层协同控制方法

代亮*,杜鹏飞,黄自彬,杨朋博
(长安大学,电子与控制工程学院,西安 710064)

摘要: 强化学习具有强大的自适应性和学习能力,能够根据环境变化和反馈信号不断调整策略和行为,实现持续优化,为城市交通信号控制提供新的技术手段。针对现有强化学习方法在交通信号协同控制中存在的智能体协作效率低下与控制区域划分机制缺失问题,本文提出一种交通信号分层协同控制架构,通过构建交叉口智能体,进行状态空间与回报函数的关联性协同设计,并建立基于拥堵扩散的交通控制子区划分模型,实现动态划分交通控制子区。最后,构建子区智能体协调子区内部交叉口智能体,交叉口智能体根据子区智能体提供的全局性建议以及所在交叉口情况完成信号控制方案的优化,实现区域交通信号分层协同控制。仿真结果表明,与现有定时控制与强化学习方法相比,本文方法平均行程时间分别降低56.78%和29.23%。相比MPLight(Max Pressure Light)方法,平均速度提升7.21%,平均行程时间与停车次数分别减少22.62%和3.98%。此外,通过对比在不同规模以及拓扑结构路网的性能表现,验证本文方法在同质交叉口路网中具有一定可移植性。

关键词: 智能交通;交通信号控制;深度强化学习;多智能体;子区划分

Hierarchical Collaborative Control of Urban Traffic Signals Based on Deep Reinforcement Learning

DAI Liang*, DU Pengfei, HUANG Zibin, YANG Pengbo
(School of Electronics and Control Engineering, Chang'an University, Xi'an 710064, China)

Abstract: Reinforcement learning has strong adaptability and learning ability, which can continuously adjust strategies and behaviors based on changes in the environment and feedback signals, thereby achieving continuous optimization and providing new technological means for urban traffic signal control. In response to the low efficiency of intelligent agent collaboration and the lack of control area partitioning mechanism in existing reinforcement learning methods for traffic signal collaborative control, this paper proposes a traffic signal hierarchical collaborative control architecture. By constructing intersection intelligent agents, this paper performs the correlation and collaborative design of state space and reward function. A traffic control sub zone partitioning model based on congestion diffusion is established to dynamically partition traffic control sub zones. The regional coordinated traffic signal control framework is established by deep reinforcement learning, and the information interaction mechanism is proposed with multi-level agents. The dynamic division method of traffic control sub-area is developed based on the congestion diffusion relationship of urban intersections. The results show that, compared with the existing timing control and reinforcement learning methods, the average travel time of the proposed method is reduced by 56.78% and 29.23%, respectively. In addition, the proposed method has certain portability in the road network of homogeneous intersections.

Keywords: intelligent transportation; traffic signal control; deep reinforcement learning; multi-agent; sub-area division

0 引言

交通拥堵是城市交通中普遍存在的问题,城市交通网络是为出行者和物流服务的系统,缓解交通拥堵可以产生可观的收益,例如,降低运输成本、节

收稿日期:2025-02-28 **修回日期:**2025-03-28 **录用日期:**2025-04-09
基金项目:陕西省交通运输厅交通科研项目/ Transportation Research Project of Shaanxi Provincial Department of Transport (24-15R);长安大学中央高校基本科研业务费专项资金/ The Fundamental Research Funds for the Central Universities, CHD (300102323201)。
作者简介:代亮(1981—),男,陕西安康人,教授,博士。 ***通信作者:**ldai@chd.edu.cn
引用格式:代亮, 杜鹏飞, 黄自彬, 等. 基于深度强化学习的城市交通信号分层协同控制方法[J]. 交通运输系统工程与信息, 2025, 25(4): 63-72. [DAI L, DU P F, HUANG Z B, et al. Hierarchical collaborative control of urban traffic signals based on deep reinforcement learning[J]. Journal of Transportation Systems Engineering and Information Technology, 2025, 25(4): 63-72.]

中国知网 https://www.cnki.net

省通勤时间和减少环境污染等。由于地理环境以及城市规划等因素的限制，仅通过扩建道路缓解交通拥堵成本高昂且收效甚微。优化交通信号灯配时方案可以高效和经济地缓解交叉口拥堵和减少交通事故发生。随着交通传感器被大规模部署，产生的海量和多维度的交通数据为自适应交通信号控制提供新机遇[1]。其中，结合强化学习(Reinforcement Learning, RL)的交通信号灯自适应控制方法表现出巨大的潜力[2]。RL通过智能体与环境的交互，学习最优控制策略，增强交通信号灯控制器对环境变化的适应能力。

基于RL的信号控制研究工作主要针对单交叉口展开，GENDERS等[3]选择n步Q学习算法，并行模拟多个智能体与环境，利用多个智能体改进学习改进奖励实现更优越的信号控制性能。张玺君等[4]使用自注意力网络从交通状态信息中挖掘潜在特征作为深度强化学习(Deep Reinforcement Learning, DRL)算法的输入，在单交叉口环境下，在车辆平均等待时间等指标上具有更好的性能。然而，交通拥堵现象在一个交叉口的产生可能会逐渐扩散至周边多个交叉口，实行区域交通信号协同控制对于提高路网整体交通效率有着不可替代的作用。因此，很多研究者提出基于RL的区域交通信号协同控制方法。

最初针对区域交通信号协同控制研究采用集中式控制方式，XIAO等[5]使用集中式控制系统实现单个智能体对交通路网进行全局控制，在路网规模扩大时训练难度提升，存在局限性。为克服集中式控制存在的问题，研究者提出区域内具有明确协调和通信的多智能体信号控制方法。CHU等[6]提出基于独立DQN(Deep Q-Network)的算法，将智能体相邻智能体的动作以及观测空间作为输入，并按缩放远处智能体的信息。ZHU等[7]提出一种分布式动脉交通信号协调方法，通过引入邻域经验共享框架和知识同质化封装机制，有效解决多交叉口场景下控制策略干扰和异构特征协调问题。陈喜群等[8]提出一种基于异构多智能体自注意力网络方法，考虑多交叉口交通流的空间相关性，能够顺序决策最优反应动作。与单智能体控制相比，部分状态合作的多智能体控制能够有效适应区域内交通流的变化。然而，部分合作因局部信息受限难以实现全局最优，因此，分层RL方法被应用在交通信号协同控制中。马东方等[9]通过设置中心智能体和局部智能体，实现单路口优化与全局协调的结合。采用分布训练-分区记忆的单智能体决策模型，由中心智能体全局评价和调整局部智能体的行为，在保障支路交通效率的同时减少干线车辆的停车次数。郑晔等[10]提出一种双层智能体区域协同控制方法，设置工作智能体保证单个交叉口不堵塞，管理智能体对工作智能体进行协同控制。LI等[11]基于实时交通流密度的动态分区方法将交通网络划分为强耦合区域，并设计轻量级时空融合特征提取网络，增强区域内信号灯智能体的协作。TAN等[12]使用多个区域智能体和一个集中的全局智能体，通过聚合区域智能体的成果然后由集中智能体进行跨区域协调，有效减少密集交通流期间区域内的排队长度和排队时间。然而，以上静态划分控制区域的方法难以适应交通流的时空动态变化，而动态划分能根据实时交通需求灵活调整控制范围，提升整体控制效率。

目前，应用RL方法开展区域交通信号协同控制研究，对于交叉口之间的协同控制机制仅仅考虑部分信息共享、全局共享、小规模路网全局控制以及静态划分控制区域的分层控制，较少研究动态划分交叉口的区域协同控制方式。现有研究表明，在传统的信号控制方法中，针对交叉口关系划分控制区域可以有效提升信控效果，胡立伟等[13]建立交叉口关联度模型将交通拥塞控制区划分为疏散与平衡两类控制子区，根据不同控制目标设计信号控制方案，在减少车辆延误等方面有明显改善。因此，如何在RL技术框架下通过动态划分控制区域处理大规模路网区域协同控制的问题，成为当前研究亟待解决的问题。为提升城市路网全局交通效率，增强路网中信号灯的有效协作，本文提出基于分层RL的区域信号协同控制方法。将信号灯建模为智能体，并针对区域协同信号控制任务建立分层控制结构。设置交叉口和子区两类智能体：交叉口智能体基于近端策略算法优化单路口方案；子区智能体根据实时交通状态调整控制的交叉口智能体对象，从全局层面协调区域内所有交叉口智能体，实现全局交通效率的提升。

1 单智能体信号控制架构设计

合理的动作空间、状态空间与回报函数直接决定智能体的学习稳定性与最终性能表现，现有研究中，在设计以上要素时较少考虑各要素之间的关联性。针对此问题，本文协同设计状态空间与回报函数。在状态空间中，综合考虑环境的直接与间接信

中国知网 https://www.cnki.net

息；在回报函数中，添加基于势能的辅助回报。并使用近端策略优化算法对孤立交叉口信号灯智能体进行建模。

1.1 单智能体RL要素设计

本文选择基于相位的动作决策，为避免无固定相序的相位切换导致车流通行停滞，选择固定相位顺序改变相位持续时间控制交叉口信号灯。针对双向4车道十字交叉口环境，相位切换顺序定义为{NSG→NSLG→EWG→EWLG}。其中，NSG代表南北直行相位，NSLG代表南北左转相位，EWG代表东西直行相位，EWLG代表东西左转相位。每个相位均允许车辆右转。在每个时刻t智能体观察环境的状态s_t后，交叉口智能体选择循环相位切换方案中的下一个相位持续时间。每个相位切换之间会增加一个黄灯相位，确保驶离停止线的车辆通过交叉口。

状态空间的设计方案主要分为两种，离散化交通状态编码和人工选取交通评价指标。离散化交通状态编码是将交叉口附近道路划分为单元网格，通过提取每个车辆的位置矩阵、速度矩阵以及加速度矩阵等表示交叉口交通状态。交通评价指标通常是对交叉口附近车道交通参数求平均值或求和。目前，基于RL的交通信号灯控制研究中，状态空间中使用最多的5个元素分别是排队长度(38%)、相位状态(11%)、停车数量(10%)、车辆位置(6%)和车辆速度(6%)[1]。

本文提出基于直接与间接相关信息的组合状态空间设计方案。选取交叉口驶入车道与驶出车道车辆压力差值作为状态空间的直接相关信息。车道l压力差定义为

$$p(l_{\text{in}}, l_{\text{out}}) = v(l_{\text{in}})/v_{\max}(l_{\text{in}}) - v(l_{\text{out}})/v_{\max}(l_{\text{out}}) \tag{1}$$

式中：l_{in}和l_{out}分别为车道l的驶入车道和驶出车道，为统一状态的表示形式，将其进行归一化编码处理；$v_{\max}$为车道最大车辆容量；$v(l_{\text{in}})$和$v(l_{\text{out}})$为l车道的排队车辆数。

最大压力作为与回报函数中直接对应的直接信息可以即时联动，但智能体在进行决策时容易忽视一些车道排队车辆无法消散的情况，导致局部最优解。因此，需要在状态空间中添加间接信息帮助智能体在长时间跨度下选择动作。本文中，选择排队长度和上一相位的持续时间作为间接相关信息。排队长度定义为驶入车道的车辆数，并通过除以车道最大车辆容量进行归一化处理，上一相位时间使用独热编码向量。排队长度定义为

$$q = v(l_{\text{in}})/v_{\max}(l_{\text{in}}) \tag{2}$$

状态空间S由直接信息交叉口总车辆压力差和间接信息交叉口附近车道排队车辆长度及上一相位绿灯时间构成，定义为$S \in \left(R^{L+L_{\text{in}}}\right)|P|$，其中，$R$为压力差，$L_{\text{in}}$为排队长度，$P$为绿灯相位时间。

根据状态空间与回报函数协同设计理念，在状态空间中，出现的直接信息需要与回报函数中某个奖励对应，即主线回报。然而，只针对主线任务设置回报函数是理想化的设计模式，在实际应用中，智能体很难探索到有效的策略。针对上述问题本文选择添加基于势能的回报塑形[14]，主线回报的设置与状态空间定义中的直接相关信息相匹配，选择最大化压力差作为主线回报。基于势能的辅助回报选择平均速度和差分延迟。辅助回报设计为

$$R_{\text{v}} = \sum_{v \in l} u \Big/ u_{\max} N \tag{3}$$

$$R_{\text{d}} = D_t - D_{t-1} \tag{4}$$

式中：u为平均速度；$u_{\max}$为车道最大车速；D_t为在t时刻交叉口车辆总延迟；N为总车辆数；R_{v}与R_{d}分别为平均速度与差分延迟的一般表示形式。

辅助回报的势能形式为

$$R'_{\text{v}} = \gamma R_{\text{v}}(s_{t+1}) - R_{\text{v}}(s_t) \tag{5}$$

$$R'_{\text{d}} = -\left[\gamma R_{\text{d}}(s_{t+1}) - R_{\text{d}}(s_t)\right] \tag{6}$$

式中：R'_{v}与R'_{d}为平均速度与差分延迟的基于势能表示形式，基于势能的差分延迟回报设置为负值，用以表示对延迟增加速度的惩罚；γ为辅助回报折扣因子。回报函数式为

$$r = -\left|\sum_{l_{\text{in}}, l_{\text{out}} \in L} p(l_{\text{in}}, l_{\text{out}})\right| + R'_{\text{v}} + R'_{\text{d}} \tag{7}$$

式中：L为交叉口车道l的集合。

1.2 基于近端策略优化的单智能体信号控制方法

近端策略优化算法(Proximal Policy Optimization, PPO)是A2C(Advantage Actor Critic)算法的变体，在A2C算法样本管理和梯度计算做出改进。为提高在线采样的效率，将同批样本分成多个小批量样本并重复利用多次，在计算策略梯度时限制参数更新幅度避免训练的不稳定性。

基于PPO孤立交叉口信号灯控制过程可以分为以下步骤：首先，通过交通仿真软件对交叉口的环境进行建模，基于RL的信号灯控制可以被视为部分可观测马尔可夫决策过程，交叉口的状态信息由观测空间表示；其次，初始化交叉口环境，包括初

中国知网　https://www.cnki.net

始化道路环境、车辆和信号灯初始状态等，开始交互。

训练过程如图1所示，PPO智能体通过演员网络与环境交互，获取状态并输出动作概率密度函数的均值和方差，从中采样得到动作。执行动作后，环境返回奖励和下一状态，这些数据存入缓冲区。旧演员网络执行类似过程，计算新旧策略的概率分布。评论家根据缓冲区数据输出状态价值函数和优势函数，更新其参数。演员网络利用PPO Clip目标函数和优势函数进行梯度下降更新。当轨迹数据达到预设长度或回合结束时，演员网络参数复制给旧演员网络。多个并行演员网络收集数据，经过一定时间步长后完成梯度更新。数据迭代多个周期后重新采样，重复策略更新过程。

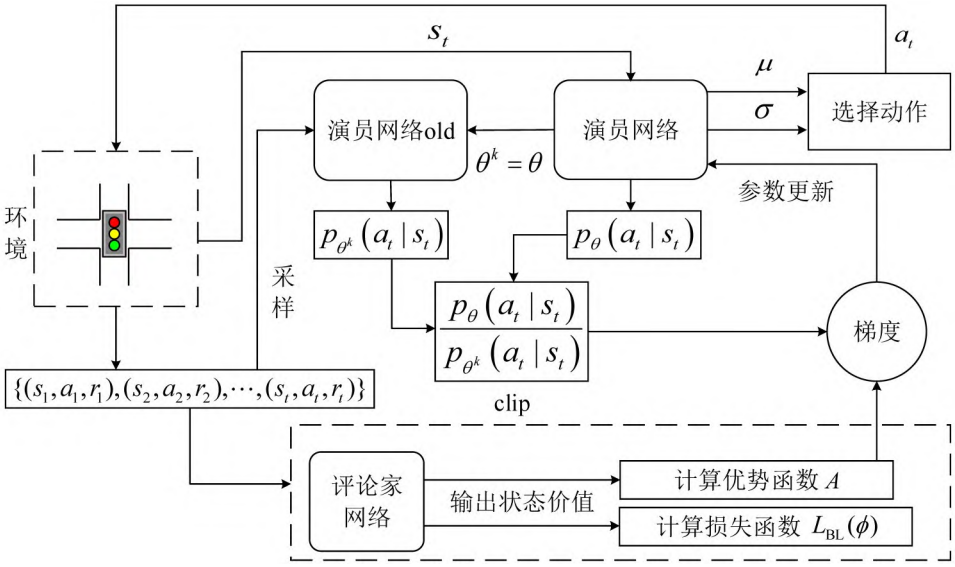

图1 PPO智能体训练过程

Fig. 1 PPO intelligent agent training process

2 区域交通信号分层协同控制

区域交通信号控制需要协调区域内多个交叉口信号灯配时提升路网整体通行能力。当路网规模过大的情况下，应用分层RL将区域协同交通信号控制问题分解为多个子任务，既可以完成信息的共享，又可以避免维度灾难。本文提出一种分层协同优化方法，为区域内每个交叉口设置一个交叉口智能体，同时，设置子区智能体用于协调子区内部交叉口智能体。子区智能体根据区域内交叉口之间拥堵扩散的时间与空间关系动态调整控制区域，为子区内部智能体提供全局性建议，实现区域交通信号分层协同控制。

2.1 控制子区动态划分方法

交叉口的拥堵往往会沿着上下游交叉口发生扩散，对其周围区域的交通产生影响。本文根据交叉口拥堵发生的时间及空间关系定义拥堵扩散，通过交叉口的拥堵扩散关系划分控制子区。当两个交叉口之间满足发生拥堵的时间间隔小于预定的时间阈值，并且最短距离小于预定的空间阈值，则认为这两个交叉口发生拥堵，存在拥堵扩散关系。交叉口本地拥堵成本定义为由于交叉口周围道路拥堵而导致的交通延误和车辆排队综合指标。拥堵扩散成本定义为拥堵从一个交叉口扩散到其他交叉口所带来的扩散成本，由交叉口拥堵扩散概率以及其他交叉口本地拥堵成本计算得到。总拥堵成本由一个交叉口的本地拥堵成本和拥堵扩散成本构成，以交叉口 i 为例子，定义为

$$C_i=\hat{I}_i+\sum_{j}^{j\in K_i}P_{ij}C_j \tag{8}$$

式中：$\hat{I}_i$ 为交叉口 i 的本地拥堵成本；j 为与交叉口 i 有拥堵扩散关系的交叉口；C_j 为交叉口 j 的总拥堵成本，当一个交叉口拥堵没有扩散到任何交叉口，则认为此交叉口的总拥堵成本等于其本地拥堵成本；K_i 为与交叉口 i 有拥堵扩散关系的交叉口集合；P_{ij} 为拥堵由交叉口 i 扩散到 j 的扩散概率，定义为

$$P_{ij}=P\left(j_{t+T_s}=1\middle|i_t=1\right) \tag{9}$$

式中：$i_t=1$，表示 i 交叉口在 t 时刻发生拥堵；$j_{t+T_s}=1$，表示 j 交叉口在 $t+T_s$ 时间内发生拥堵；T_s 为拥堵扩散的时间阈值。

本地拥堵成本由交叉口附近的道路平均排队

中国知网 https://www.cnki.net

长度与平均交叉口延误所构成的综合指标构成，定义为

$$\hat{I}=\omega_1\cdot q+\omega_2\cdot D \tag{10}$$

式中：$\hat{I}$ 为判断拥堵的指标；q 为交叉口排队长度；ω_1 和 ω_2 为权重，分别表示排队长度和交叉口延误的重要程度；D 为交叉口平均延迟，定义为

$$D=\left(\sum_{i=1}^{n}T_{i,\mathrm{cross}}-\hat{T}\right)\Big/n \tag{11}$$

式中：n 为车辆数量；$T_{i,\mathrm{cross}}$ 为第 i 辆车通过交叉口所需的实际时间；$\hat{T}$ 为在无延误时车辆通过交叉口所用时间。

根据拥堵扩散定义，以发生拥堵交叉口的时间关系与空间关系为限制条件，将交叉口视为节点，道路视为边，在路网中构建交叉口拥堵扩散图。交叉口拥堵扩散构建过程如图2所示。根据交叉口拥堵的判断依据可以得到在 t 时刻处于拥堵状态的交叉口A和B。根据这些交叉口与其他交叉口的空间关系判断，在时间阈值内其他交叉口发生的拥堵是否与这些交叉口有扩散关系。如果存在扩散关系，将此交叉口连接到已有交叉口拥堵扩散图中；如果与任何交叉口均不存在扩散关系，将其作为新拥堵扩散图的起点交叉口C。重复相同的操作，直到整个路网的交叉口均被遍历，得到整个路网的交叉口拥堵扩散图。通过计算每个拥堵扩散图中的交叉口拥堵成本，完成对交叉口拥堵影响程度的分级。最后，以路网拥堵扩散图作为信号控制子区。

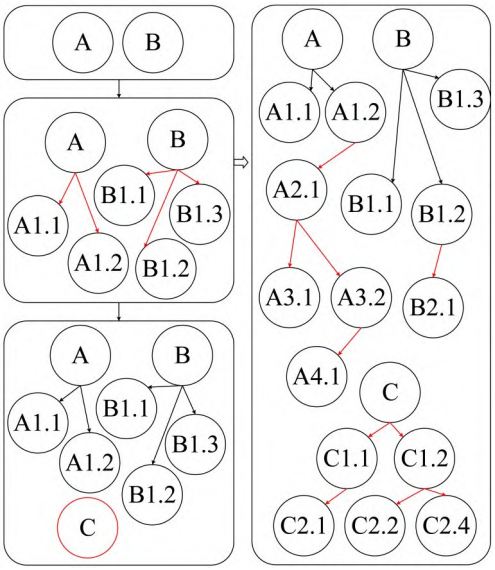

图 2　拥堵扩散图构建过程

Fig. 2　Construction process of congestion diffusion map

在划分子区时，可以获得每个控制子区中的交叉口之间存在拥堵扩散关系以及每个交叉口的总拥堵成本。根据总拥堵成本以及拥堵产生的时间关系可以衡量控制子区内交叉口的重要程度，对交叉口进行分级。子区交叉口拥堵影响综合指标，即重要程度等级为

$$G_i=\left(C_i/C_{\max}\right)\cdot T_i \tag{12}$$

式中：G_i 为一个控制子区内交叉口 i 的拥堵影响综合指标；C_i 为交叉口拥堵总成本，代表拥堵程度权重；$C_{\max}$ 为子区内最大的总拥堵成本；T_i 为时间权重，定义为

$$T_i=1\Big/\left[1+\beta\left(t-t_i\right)\right] \tag{13}$$

式中：T_i 为拥堵发生的先后顺序对时间权重的影响；t 为当前时间；t_i 为 i 交叉口拥堵的发生时间，拥堵事件发生越早，获得的时间权重越大；为调整参数，控制时间权重的衰减速度。在式(12)中，对拥堵程度权重进行归一化处理，保证 G_i 在不同指标范围内有可比性。

参考美国道路通行能力(Highway Capacity Manual, HCM)手册中对交叉口服务水平的划分标准[15]，根据子区内交叉口的拥堵影响综合指标将交叉口划分为5个等级，如表1所示。

表 1　拥堵影响综合指标

Table 1　Comprehensive index of congestion impact

等级	A	B	C	D	E
拥堵影响指标	≥1.0	[0.8, 1.0)	[0.5, 0.8)	[0.2, 0.5)	<0.2
回报函数值	10	4	3	2	1

2.2　分层协同控制框架

分层区域信号协同控制框架如图3所示，区域路网中，交叉口的信号灯被建模为独立的智能体，表示为 A_Z^k，Z 为交叉口智能体所属的区域，k 表示其编号。交叉口智能体的任务根据所在交叉口的状态以及奖励完成所在交叉口的信号控制任务。在区域路网中，对于划分出的更小区域设置子区智能体表示为 A_Z，在每个控制子区内部，每个时间步 t 内，交叉口智能体与所在交叉口环境进行交互，学习相位控制策略；同时，接收来自控制子区智能体的推荐相位动作的全局性建议作为回报函数的一部分，用以隐式获取子区内其他交叉口信息，进行子区内协同控制。子区划分模块在每个设定时间步 t 获取路网中交叉口拥堵的产生与扩散信息，构建交叉口拥堵扩散传播图，获取交叉口拥堵影响程度。以 t 时间步的拥堵扩散传播图对路网划分控制子区，并根据拥堵影响综合指标对每个控制子区

中国知网　https://www.cnki.net

内的交叉口进行分级。

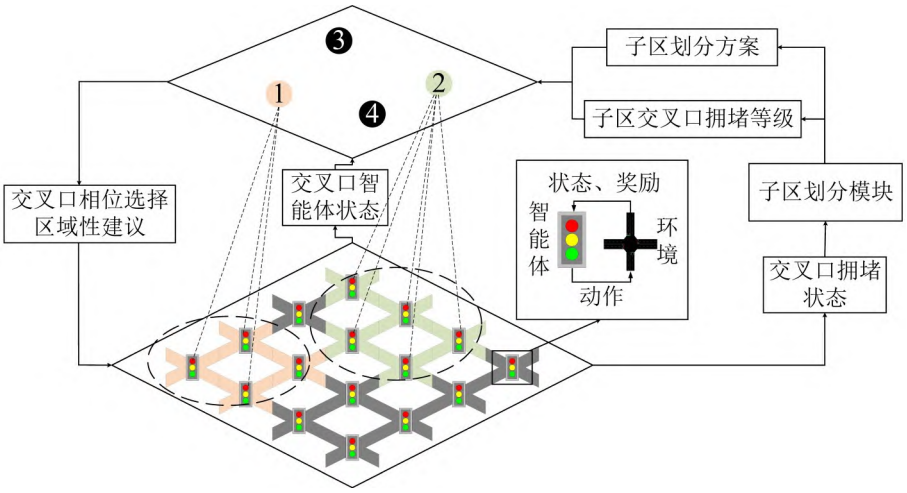

图3 分层区域信号协同控制框架

Fig. 3 Layered regional signal collaborative control framework diagram

交叉口智能体建模以单智能体信号控制架构为基础，在状态空间与奖励函数中增加子区智能体的全局建议。更新后的状态空间表示为 $S \in R^{L+L_{\text{in}}} \cdot |P| \cdot |\hat{P}|$。其中，$\hat{P}$ 代表交叉口所属区域的子区智能体的全局性相位建议，其余元素与单交叉口定义状态空间相同。

子区智能体状态空间选取交叉口的直接状态信息，驶入车道与驶出车道车辆差值压力作为子区智能体的状态空间。对于区域中的交叉口智能体 A_Z^k。压力差定义为

$$p_Z^k(l_{\text{in}}, l_{\text{out}}) = \sum_k v(l_{\text{in}}) \Big/ \sum_k v_{\max}(l_{\text{in}}) - \sum_k v(l_{\text{out}}) \Big/ \sum_k v_{\max}(l_{\text{out}}) \tag{14}$$

在区域状态中添加从区域整体评级信息，根据表1中对于区域中交叉口拥堵影响综合指标，定义为 G_Z^k，$G_Z^k = \{-1, -2, -3, -4, -5, -10\}$。因此，对于子区智能体的状态可以定义为

$$H_Z = \left\{ p_Z^k(l_{\text{in}}, l_{\text{out}}), G_Z^k \right\} \tag{15}$$

子区智能体设置的目的是为子任务提供指导意见，向底层智能体推荐全局优化目标所期望动作。但直接干涉底层智能体动作选择导致底层智能体无法根据环境学习有效控制策略。因此，本文提出的子区智能体动作设计为区域内交叉口智能体下一个时间步期望的相位。底层智能体在学习本地信号控制任务策略也能够接受来自子区智能体的全局性指导意见。动作定义为

$$A = \{\text{NSG} \rightarrow \text{NSLG} \rightarrow \text{EWG} \rightarrow \text{EWLG}\} \tag{16}$$

动作中包含相位循环顺序中的4个可能相位。智能体通过接受区域内所有交叉口智能体状态空间选取所有交叉口满足全局控制目标的期望相位，期望动作与实际执行动作接近程度越高，所获得的奖励最高。交叉口智能体的全局奖励定义为

$$r(\hat{P}) = \{0, -1, -2, -3\} \tag{17}$$

子区智能体将区域状态空间中的每个交叉口的驶入车道与驶出车道车辆压力作为回报函数中的主线回报部分，定义为 r_j^k，即

$$r_j^k = -\left| \sum_{l_{\text{in}}, l_{\text{out}} \in L_j} p(l_{\text{in}}, l_{\text{out}}) \right| \tag{18}$$

式中：r_j^k 为区域 k 中交叉口 j 的压力负值；L_j 为 j 交叉口的车道集合。与子区智能体中交叉口重要程度应用基于势能函数定义为 $r(G_j^k)$，即

$$r(G_j^k) = G_j^k - G_j^{k'} \tag{19}$$

式中：G_j^k 为 t 时隙区域 k 中交叉口 j 的重要程度等级；$G_j^{k'}$ 为 $t-1$ 时隙区域 k 中交叉口 j 的等级，重要程度等级下降越多，优化效果越好。子区智能体的总奖励 r^k 定义为

$$r^k = \sum_{j=1}^{N} r_j^k + \sum_{j=1}^{N} r(G_j^k) \tag{20}$$

3 仿真测试

为验证所提出子区划分方法的有效性，基于SUMO交通仿真平台构建交叉口交通环境，使用rllib实现近端策略优化算法，通过SUMO的Traci接口完成交互。通过与经典区域信号控制方法对比验证本文所提出方法性能。

中国知网 https://www.cnki.net

3.1 实验设置

本文所提出区域信号协同控制方法存在子区划分，较小的区域路网无法有效验证子区动态划分带来的性能提升。因此，为验证本文所提出的区域信号协同控制方法的性能，选择在较大规模的不同区域路网中进行仿真实验。数据集具体介绍如表2和图4所示。Manhattan实验数据选取纽约曼哈顿2510个交叉口1 h数据，分别选择其中由7条主路28条支路构成的196个交叉口与3条主路16条支路构成的48个交叉口作为研究对象。车辆数量是从纽约出租车轨迹数据中采样生成的。其中，转弯和直行比例为：10%(左转)、60%(直行)和30%(右转)，每个交叉口距离为300 m。数据集满足大规模和真实性的要求，符合本文所提出方法对于拥堵交叉口交通流随时间变化的要求。Ingolstadt_21实验数据来自于德国英戈尔施塔特市内包含21个交叉口的部分路网，包括道路网络布局和车流数据。Ingolstadt_21中的每个交叉口结构之间存在异构性，每个交叉口车道数和信号相位数量不同，用于验证可移植性。

表 2 实验数据集

Table 2 Experimental data set

名称	路网来源	车流数据来源	交叉口数量	仿真步长	交叉口结构
Ingolstadt_21	德国英戈尔施塔特	传感器采集	21	3600	异构
Manhattan_16x3	美国纽约曼哈顿	出租车轨迹生成	48	3600	同构
Manhattan_28x7	美国纽约曼哈顿	出租车轨迹生成	196	3600	同构

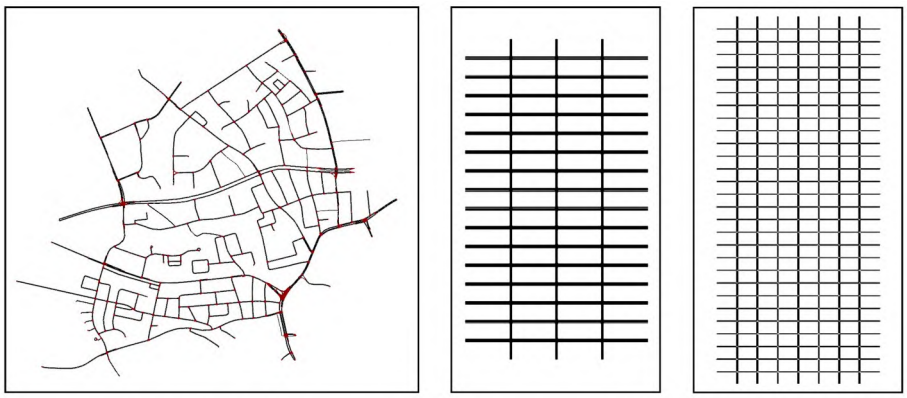

(a) Ingolstadt_21　　(b) Manhattan_16x3　　(c) Manhattan_28x7

图 4 实验场景

Fig. 4 Experimental scene

RL网络训练参数设置如表3所示。所选取实验路网中交叉口数量较多，因此，需要更多的训练次数保证智能体收敛到最佳的控制效果，训练次数设置为1000。区域智能体的状态空间显著增大，因此，学习率降低到0.00001，确保模型能够有效地学习到新的状态表示，并防止过快地收敛到次优解或完全失去学习能力。状态空间的扩展和动态变化的控制区域导致样本的稀疏性增加，需要增大训练批量，提高训练的稳定性，因此，将批训练量大小设置为1024。同时，并行环境数设置为16，提高训练效率和泛化能力。熵系数同样受更大的状态空间影响，需要增大，促进更多的探索动作，熵系数设置为0.25。

表 3 实验参数设置

Table 3 Experimental parameter settings

参数	值	含义
训练次数	1000	
折扣因子γ	0.95	对未来奖励的重视程度
学习率α	0.00001	沿着梯度方向更新步长大小
训练批量大小(batch size)	1024	采样数量
并行环境数	16	训练过程中同时运行的环境数量
更新步幅	2048	更新所使用的数据量
损失计算熵系数	0.25	平衡样本探索和利用
剪裁系数	0.4	控制梯度范围

中国知网　https://www.cnki.net

3.2 测试结果分析

对比实验包括两个部分：首先，将本文提出的区域信号控制方法与现有信号控制方法进行对比；其次，验证动态子区划分对所提出方法的性能提升影响；最后，在不同交通场景下验证本文所提出方法的可移植性。本文选取平均行程时间(Average Travel Time, ATT)、平均速度(Average Speed, AS)和平均停车次数(Average Stop Times, AST)作为评价指标。以上3个指标能够综合考虑交通流的通畅性、效率和出行体验，用以评估信号灯控制效果的综合性能。

为比较传统信号控制方案以及区域交通信号控制中部分信息共享、全局信息共享以及无通信静态划分控制区域方法与本文方法的控制效果，选取定时控制、感应控制、IPPO(Independent PPO)、CoLight与MPLight作为对比的基准信号控制方法。

感应控制使用传感器或摄像头采集数据，根据交叉口处实际检测到的交通流量确定相位方案和相位持续时间[16]。IPPO算法将PPO算法扩展到多智能体任务中，每个智能体均独立运行一套PPO算法，彼此之间无信息共享。CoLight是2019年提出的一个区域信号控制方法[17]。该方法将每个交叉口建模为图中的一个节点，使用图注意力机制促进相邻交叉口的通信。MPLight基于DQN算法和处理大规模路网多交叉口信号控制问题[18]。通过对信号相位竞争关系进行建模，完成全局信息共享，并且在大规模网络上表现出较好的控制效果。

在曼哈顿交通场景下的3种评价指标平均值如表4所示，在Manhattan_28x7路网中，本文提出的方法在3种评价指标中表现均达到最佳水平。相比MPLight方法，平均行驶时间减少22.62%，平均行驶速度提升7.21%，平均停车次数减少3.98%。子区智能体与交叉口智能体的状态空间与回报函数中均没有包含行程时间，智能体仍然通过优化其他因素间接降低行程时间。本文提出的分层方法可以找到有效的策略优化整体的交通流畅度，减少区域内平均行驶时间。受高密度交通流的影响，智能体学习到的策略在平均速度以及停车次数指标上，提升幅度有限。

表4 区域信号控制方法评价指标对比

Table 4 Comparison of evaluation indicators for regional signal control methods

场景	评价指标	固定配时	感应控制	IPPO	CoLight	MPLight	本文方法
Manhattan_28x7	ATT/s	1150.87	934.61	793.41	701.50	642.75	497.36
	AS/(m·s^{-1})	2.92	2.95	3.01	3.17	3.33	3.57
	AST	3929	3880	3865	3705	3821	3669

3种评价指标随仿真时间变化如图5所示。本文提出的方法在平均行程时间指标上表现出显著优势，在整个仿真周期内均维持在较低水平。MPLight方法在仿真初期(车流密度较低阶段)与本文方法性能相当，但在仿真中期出现明显的平均速度波动。本文方法在整个仿真过程中保持最优的整体性能。在停车次数指标方面，仿真初期，5种方法的差异并不显著。随着仿真时间的推移，在车流密度较大的情况下，本文方法在抑制车辆频繁启停方面展现出一定优势，其停车次数低于其他方法，表明本文方法能够有效减少城市交叉口排队车辆的污染排放。

验证子区划分对多智能体协作的消融实验训练过程奖励值变化如图6所示。从图6中可以看到，2种方法均在1000轮次的训练中收敛。本文所提出与静态划分控制区域的方法平均奖励提高18.74%。本文提出的方法，在CoLight方法的基础上采用分层架构，以最大程度减少区域内交叉口拥堵成本为目的。使用子区智能体完成智能体之间的协调任务，以推荐相位作为每个交叉口的奖励隐式协调交叉口智能体。动态调整控制区域的机制使区域交通效率进一步提升。

为验证所提出方法在不同规模以及结构的路网上是否具有可移植性，在Manhattan_16x3 Ingolstadt_21进行仿真测试，结果如表5所示。和在Manhattan_16x3路网中，与MPLight方法对比，平均行程时间与平均停车次数分别减少17.01%和5.22%，平均速度提升5.09%。Ingolstadt_21路网平均行程时间与平均停车次数分别减少3.35%和5.06%，平均速度提升5.53%。

中国知网 https://www.cnki.net

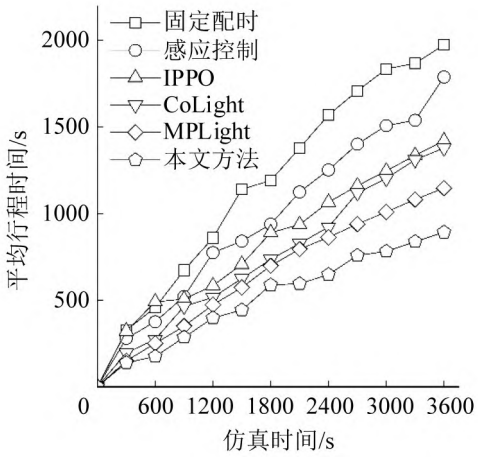

(a) 平均行程时间对比

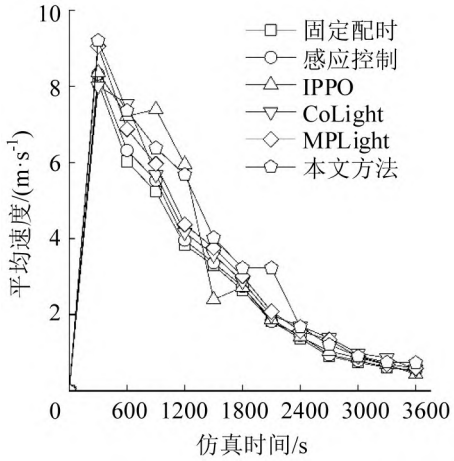

(b) 平均速度对比

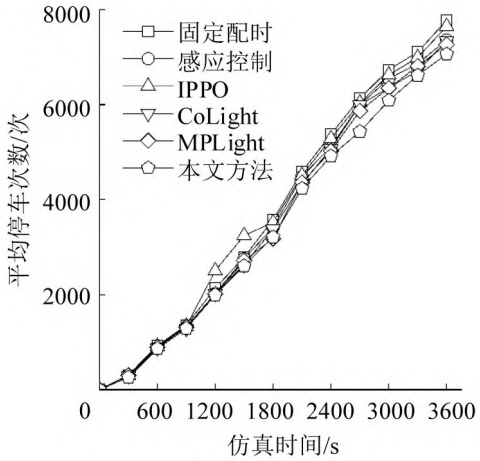

(c) 平均停车次数对比

图 5 评价指标对比

Fig. 5 Comparison chart of evaluation indicators

训练好的模型在平均速度和平均停车次数上性能提升与Manhattan_28x7相差较小，Manhattan_16x3路网中的性能提升与Manhattan_28x7相比总体表现差距不大。Ingolstadt_21路网在平均行驶时间上表现较差，Ingolstadt_21由于路网规模减少，交叉口环境地形与大小不同，数据分布的偏差导致模型无法有效地适应新环境，导致性能提升有限。结果表明，本文所提出的方法可以适应相同结构的不同规模路网，而在交叉口结构差异过大的路网上可移植性仍有提升空间。

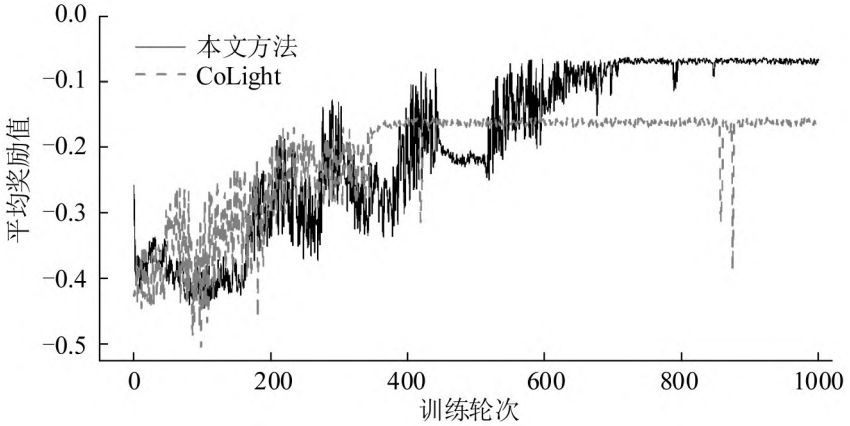

图 6 平均奖励值对比

Fig. 6 Comparison chart of average reward values

表 5 验证本文方法可移植性的评价指标对比

Table 5 Comparison of evaluation indicators for verifying portability of method proposed in this article

场景	评价指标	固定配时	感应控制	IPPO	CoLight	MPLight	本文方法
Manhattan_16x3	ATT/s	650.60	593.85	473.33	426.26	343.39	285.04
	AS/(m·s⁻¹)	3.39	3.41	3.37	4.11	4.52	4.75
	AST	1732	1741	1703	1631	1615	1609
Ingolstadt_21	ATT/s	293.14	230.20	255.32	189.20	191.07	184.67
	AS/(m·s⁻¹)	7.54	7.92	7.71	8.03	7.78	8.21
	AST	976	897	921	866	850	807

中国知网 https://www.cnki.net

4 结论

针对城市交通信号区域协同控制问题，提出一种基于分层RL的区域信号协同控制方法。首先，将单交叉口信号灯建模为RL智能体，设置RL要素；然后，针对区域协同信号控制任务建立分层控制结构，设置不同层级的智能体，动态划分子区智能体控制区域，实现区域内交叉口信号灯的协同控制；最后，通过仿真测试验证所提出方法的有效性，得到以下主要结论：本文提出的方法在多个交通场景下均表现出较好的性能，特别是在减少行程时间和提升交通流畅度方面；与静态化分区控制子区的系统控制方法相比，平均行驶时间减少22.62%，平均行驶速度提升7.21%；动态子区划分进一步增强了多智能体协作的效果，提升了模型的稳定性和收敛速度；与静态控制区域划分的RL信号控制方法相比，本文提出方法平均奖励提高18.74%。

参考文献

[1] SHAIKH P W, EL-ABD M, KHANANFER M, et al. A Review on swarm intelligence and evolutionary algorithms for solving the traffic signal control problem [J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(1): 48-63.

[2] MOHAMMAD N, ATHARVA N, LIANA G, et al. Reinforcement learning in urban network traffic signal control: A systematic literature review [J]. Expert Systems with Applications, 2022, 199: 116830.1-116830.32.

[3] GENDERS W, RAZAVI S. Asynchronous n-step q-learning adaptive traffic signal control [J]. Journal of Intelligent Transportation Systems, 2019, 23(4): 319-331.

[4] 张玺君, 聂生元, 李喆, 等. 基于自注意力机制的深度强化学习交通信号控制[J]. 交通运输系统工程与信息, 2024, 24(2): 96-104. [ZHANG X J, NIE S Y, LI Z, et al. Traffic signal control with deep reinforcement learning and self-attention mechanism[J]. Journal of Transportation Systems Engineering and Information Technology, 2024, 24(2): 96-104.]

[5] XIAO N, YU L, YU J, et al. A cold-start-free reinforcement learning approach for traffic signal control [J]. Journal of Intelligent Transportation Systems, 2021, 26(4): 476-85.

[6] CHU T, WANG J, CODCA L, et al. Multi-agent deep reinforcement learning for large-scale traffic signal control[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 21(3): 1086-1095.

[7] ZHU H , FENG J, SUN F, et al. Sharing control knowledge among heterogeneous intersections: A distributed arterial traffic signal coordination method using multi-agent reinforcement learning[J]. IEEE Transactions on Intelligent Transportation Systems, 2025, 26(2): 2760-2776.

[8] 陈喜群, 朱奕璋, 谢宁珂, 等. 基于异构多智能体自注意力网络的路网信号协调顺序优化方法[J]. 交通运输系统工程与信息, 2024, 24(3): 114-126. [CHEN X Q, ZHU Y Z, XIE N K, et al. Coordinated sequential optimization for network-wide traffic signal control based on heterogeneous multi-agent transformer[J]. Journal of Transportation Systems Engineering and Information Technology, 2024, 24(3): 114-126.]

[9] 马东方, 陈曦, 吴晓东, 等. 基于强化学习的干线信号混合协同优化方法[J]. 交通运输系统工程与信息, 2022, 22(2): 145-153. [MA D F, CHEN X, WU X D, et al. Mixed-coordinated decision-making method for arterial signals based on reinforcement learning[J]. Journal of Transportation Systems Engineering and Information Technology, 2022, 22(2): 145-153.]

[10] 郑晔, 郭仁忠, 马丁, 等. 面向地理路网的交通信号智能协同控制方法[J]. 测绘学报, 2021, 50(9): 1203-1210. [ZHENG X, GUO R Z, MA D, et al. Multi-agent cooperative control for traffic signal on geographic road network[J] Acta Geodaetica et Cartographica Sinica, 2021, 50(9): 1203-1210.]

[11] LI Y, ZHANG Y, LI X, et al. Regional multi-agent cooperative reinforcement learning for city-level traffic grid signal control[J]. IEEE/CAA Journal of Automatica Sinica, 2024, 11(9): 1987-1998.

[12] TAN T, BAO F, DENG Y, et al. Cooperative deep reinforcement learning for large-scale traffic grid signal control [J]. IEEE Transactions on Cybernetics, 2020, 50 (6): 2687-2700.

[13] 胡立伟, 赵雪亭, 杨锦青, 等. 基于双层规划的城市交通拥塞疏导优化研究[J]. 交通运输系统工程与信息, 2021, 21(5): 222-227, 234. [HU L W, ZHAO X T, YANG J Q, et al. Urban traffic congestion mitigation and optimization study based on two-level programming[J]. Journal of Transportation Systems Engineering and Information Technology, 2021, 21(5): 222-227, 234.]

[14] NG A Y, HARADA D, RUSSELL S. Policy invariance under reward transformations: Theory and application to reward shaping[C]. Bled: International Conference on Machine Learning, 1999.

[15] Transportation Research Board. The highway capacity manual 7th Edition: A guide for multi-modal mobility analysis[M]. USA: National Academies Press, 2016.

下转第95页

中国知网 https://www.cnki.net

vehicles design for on-ramp cooperative merging[J]. IEEE Transactions on Intelligent Transportation Systems, 2025, 26(5): 5872–5887.

[14] ZHU J, WANG L, TASIC I, et al. Improving freeway merging efficiency via flow-level coordination of connected and autonomous vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(7): 6703–6715.

[15] MILANÉS V, SHLADOVER S E. Modeling cooperative and autonomous adaptive cruise control dynamic responses using experimental data[J]. Transportation Research Part C: Emerging Technologies, 2014, 48: 285–300.

[16] PANWAI S, DIA H. Comparative evaluation of microscopic car-following behavior[J]. IEEE Transactions on Intelligent Transportation Systems, 2005, 6(3): 314–325.

[17] HOU K, ZHENG F, LIU X, et al. Cooperative on-ramp merging control model for mixed traffic on multi-lane freeways[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(10): 10774–10790.

上接第72页

[16] ZHANG G, WANG Y. Optimizing minimum and maximum green time settings for traffic actuated control at isolated intersections[J]. IEEE Transactions on Intelligent Transportation Systems, 2011, 12(1): 164–173.

[17] WEI H, XU N, ZHANG H, et al. Colight: Learning network-level cooperation for traffic signal control[C]. Beijing: Proceedings of the 28th ACM International Conference on Information and Knowledge Management, 2019.

[18] CHEN C, WEI H, XU N, et al. Toward a thousand lights: Decentralized deep reinforcement learning for large-scale traffic signal control[C]. New York: Proceedings of the AAAI Conference on Artificial Intelligence, 2020.

中国知网 https://www.cnki.net