单位代码：10293 密 级：

南京邮电大学

专业学位硕士论文

论文题目：基于多智能体深度强化学习的区域交通信号协调控制研究

学号	1319055617
姓名	余鹏程
导师	罗杰
专业学位类别	工程硕士
类型	非全日制
专业（领域）	控制工程
论文提交日期	二零二二年六月

中国知网 https://www.cnki.net

Research on regional traffic signal coordination control based on multi-agent deep reinforcement learning

Thesis Submitted to Nanjing University of Posts and Telecommunications for the Degree of Master of Engineering

By

Pengcheng Yu

Supervisor: Prof. Jie Luo

June 2022

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

摘要

城市交通拥堵已经成为了一个日益严重的社会问题，对于公众的出行和整个社会发展都产生了负面影响。为了缓解交通压力，提高交通效率，区域交通信号协调控制成为当前研究的热点问题。针对现有交通信号协调控制研究中的不足，本文提出了一种基于多智能体深度强化学习的交通信号控制方法。采用深度双 Q 网络模型，通过基于协作式多智能体深度强化学习算法实现交通信号协调控制，仿真实验结果表明，本文提出的方法能有效降低区域内车辆平均排队长度，提升通行效率。本文主要研究内容如下：

（1）针对传统深度强化学习算法存在过估计和收敛速度慢等问题，提出了一种基于优先级经验回放的深度双 Q 学习路口交通控制方法。采用离散化交通状态编码方法将高维实时路口交通信息转化为由车辆位置和速度信息组成的二维矩阵，将路口交通相位压力差作为强化学习的奖励函数，通过优先级经验回放策略，提升训练样本的利用率，加快算法收敛速度。以单路口交通信号控制为研究对象，对所提出的算法进行仿真实验，证明了该算法具有更快的收敛速度和更好的性能表现。

（2）针对区域交通信号控制中由于路网复杂性，对控制算法的协调性要求高，提出了一种基于协作式多智能体深度强化学习的区域交通信号协调控制方法。将区域交通路网建模为一个无向图，图中每个结点作为一个强化学习智能体，同时将单智能体强化学习交通信号控制算法扩展到多智能体控制系统，多智能体之间通过共享状态和奖励信息实现协调控制，基于多智能体马尔可夫博弈达到纳什均衡状态。仿真实验表明，该方法能更好地实现对区域交通信号的协调控制，提高了区域路网内车辆的平均速度并减少了交叉口的排队车辆数。

（3）本文分析了深度强化学习在交通信号控制的应用现状，构建了一个用于区域交通协调控制实验的交通仿真系统。在 SUMO 中构建区域交通路网模型，使用 Python 编程语言实现协调优化控制算法，调用 TraCI 接口实现两者之间的通信，该系统为交通信号控制算法提供了一个仿真实验平台。通过对实际交通路网建模，利用深度强化学习交通信号控制算法在该系统上仿真实验，本文所提出的区域交通协调优化控制模型及方法能有效减少区域交通延误，提高路网交通效率。

关键词：交通信号控制，区域协调优化，深度强化学习，多智能体，协作学习

中国知网 https://www.cnki.net

Abstract

Urban traffic congestion has become a serious social problem, which has a negative impact on public travel and social development. In order to relieve traffic pressure and improve traffic efficiency, regional traffic signal coordination control has become a hot topic in current research. Aiming at the insufficiency of the existing traffic signal coordination control research, this thesis propose a traffic signal control method based on multi-agent deep reinforcement learning. The algorithm adopts the deep double Q network model to solve traffic signal coordination control based on the collaborative multi-agent deep reinforcement learning algorithm. Simulation results show that this method can effectively reduce the average queue length and improve the traffic efficiency. The main contents of this thesis are as follows:

(1) To solve the problems of traditional deep reinforcement learning algorithms such as overestimation and slow convergence, proposes a deep double Q learning algorithm for intersection traffic control based on priority empirical replay. The discrete traffic state coding method was used to transform the high-dimensional real-time intersection traffic information into a two-dimensional matrix composed of vehicle position and speed information. The phase pressure difference of intersection traffic was used as a reward function of reinforcement learning. The priority experience replay strategy was adopted to improve the utilization rate of training samples and accelerate the convergence speed of the algorithm. Taking single-intersection traffic signal control as the research object, the simulation results show that the proposed algorithm has faster convergence speed and better performance.

(2) In the area traffic signal control, due to the complexity of road network, the coordination of control algorithm is highly required. A coordinated control method of area traffic signal based on cooperative multi-intelligence deep reinforcement learning is proposed. The regional traffic network modeling as an undirected graph, each node in the graph as a reinforcement learning agent, the single agent reinforcement learning traffic signal control algorithm is extended to the multi-agent control system, more intelligent by sharing between state and reward information to solve coordination control, through multi-agent markov game to achieve Nash equilibrium. Simulation results show that the proposed method can better coordinate and control regional traffic signals, improve the average speed of vehicles in the regional road network and reduce the number of vehicles queuing at intersections.

中国知网 https://www.cnki.net

(3) This thesis analyzes the application status of deep reinforcement learning in traffic signal control, and constructs a traffic simulation system for regional traffic coordination control experiment. The regional traffic network model is built in SUMO, the coordinated and optimized control algorithm is realized by Using Python, and the communication between the two is realized by calling TraCI interface. The system provides a simulation platform for traffic signal control algorithm. By modeling the actual traffic network and simulating the system with the deep reinforcement learning traffic signal control algorithm, the regional traffic coordination optimization control model and method proposed in this thesis can effectively reduce the regional traffic delay and improve the traffic efficiency of the road network.

Key words: Traffic signal control, Regional coordination optimization, Deep reinforcement learning, Multi-agent, Collaborative learning

中国知网 https://www.cnki.net

目录

第一章 绪论 1
1.1 研究背景及意义 1
1.2 国内外研究现状 2
1.3 本文主要研究内容 5
1.4 本文的组织结构 6
第二章 交通信号控制及相关机器学习理论 7
2.1 交通信号控制 7
2.1.1 信号控制基本参数 7
2.1.2 评价指标 8
2.1.3 交通信号控制方式 8
2.2 强化学习 9
2.2.1 马尔科夫决策过程 10
2.2.2 Q-学习 12
2.3 深度强化学习 13
2.3.1 深度学习 13
2.3.2 深度 Q 学习 13
2.3.3 深度双 Q 学习 15
2.4 多智能体强化学习 16
2.4.1 多智能体系统 16
2.4.2 马尔科夫博弈中多智能体 16
2.4.3 纳什均衡策略 18
2.5 本章小结 19
第三章 基于深度强化学习的路口信号控制方法 20
3.1 引言 20
3.2 基于深度强化学习的交通信号控制问题描述 20
3.2.1 环境描述 21
3.2.2 状态空间定义 21
3.2.3 动作空间定义 23
3.2.4 奖励函数定义 24
3.3 基于 DDQN 的路口交通信号控制 26
3.3.1 深度双 Q 网络 26
3.3.2 优先级经验回放策略 27
3.3.3 控制系统结构 29
3.3.4 基于 DDQN 控制学习算法 30
3.4 仿真实验及结果分析 31
3.4.1 实验设置 31
3.4.2 实验结果分析 32
3.5 本章小结 34
第四章 基于深度强化学习的区域交通信号控制方法 35
4.1 引言 35
4.2 多智能体深度强化学习交通信号控制算法 35
4.2.1 多智能体控制结构 35
4.2.2 状态空间定义 36
4.2.3 奖励函数定义 36

中国知网 https://www.cnki.net

4.3 基于协作式多智能体 DDQN 区域交通信号控制 37
4.3.1 基于协作式多智能体强化学习 37
4.3.2 控制系统结构 37
4.3.3 协调控制算法 39
4.4 仿真实验及结果分析 40
4.4.1 仿真实验设计 40
4.4.2 实验结果分析 41
4.5 本章小结 44
第五章 基于 SUMO 的区域交通控制仿真系统构建 45
5.1 微观交通仿真软件 45
5.1.1 SUMO 仿真软件简介 45
5.1.2 仿真环境配置 45
5.2 基于 SUMO 的仿真系统的构建 46
5.2.1 仿真系统结构设计 46
5.2.2 信号协调控制模块 47
5.2.3 仿真系统流程设计 48
5.3 系统仿真实例验证 49
5.3.1 区域路网构建 49
5.3.2 实验参数设置 51
5.3.3 仿真实验结果分析 52
5.4 本章小结 52
第六章 总结与展望 54
6.1 总结 54
6.2 展望 54
参考文献 56
附录 1 攻读硕士学位期间撰写的论文 60
致谢 62

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景及意义

城市交通拥堵影响了人们生活出行，阻碍了社会经济发展，已经成为一个日趋严重的社会问题[1]。随着城市化步伐不断加快，这些负面影响会随着时间的推移而不断加剧。据交通管理局统计数据显示，截至 2021 年底，我国汽车保有量达 3.02 亿辆，新注册登记汽车 2622 万辆。根据 2021 年度《中国主要城市道路网密度与运行状态监测报告》显示，2020 年全国 36 个主要城市路网总体平均密度为 6.2 km/km^2，相较于 2019 年平均密度 6.1km/km^2，增加了约 1.5%。道路运行状态方面，全国 36 个主要城市工作日高峰平均运行速度为 20.5km/h，总体处于中度拥堵状态。机动车数量的增长速度远远大于基础道路建设的速度，导致路网交通压力不断增大以及愈加频繁的交通拥堵。图 1.1 为城市道路拥堵示意图。

图 1.1 城市道路通拥堵示意图

公路运输是现代运输主要方式之一，车辆能够在基础道路设施上高效运行，对于人们出行和城市经济发展都有重要意义，人口快速增长和车辆数量增加导致交通量已经远远超出了现有基础设施的承载能力。对于城市道路交通拥堵问题，通常有以下两种方法解决方法。一种方法是提高道路的交通运输能力，通过扩建基础道路设施来应对不断增长的交通量，但是这种解决方法需要消耗大量时间和资源，对于已经规划好的城市交通路网，在扩建过程中也会影响到正常道路上的车辆通行效率；另一种方法是在现有的基础道路设施上，通过路径规划、智能交通等技术对交通流进行合理的管理和控制，这种方法是可取的，因为它具有较低的执行成本，并且还能够利用现有的道路上的交通控制设备。

高效率的交通信号控制方法能够有效缓解交通拥堵，提升城市路网的通行效率[2]。传统的交通信号控制依赖于道路传感器收集的交通流数据，通过感应到有多少车辆通过交通路口对

中国知网 https://www.cnki.net

交通流自适应控制。随着传感器技术的发展，我们可以从多种渠道收集到更丰富的交通流信息，例如街道的监控摄像头可以详细地描述附近道路上的交通状况，有多少辆车在车道上等待交通灯，有多少辆车在道路上行驶以及每辆车的位置、速度等信息。此外，导航应用程序（如高德地图）、打车软件（如滴滴打车）、一些配备 GPS 的联网车辆也能够提供车辆轨迹数据，这些数据使我们对车辆运行状态有了更详细的了解，是对交通控制系统进行研究和改进的重要资源。另一方面，如今有了更强计算能力的计算机和更先进的计算模型，研究人员已经成功将模糊控制[3]、人工神经网络[4]、遗传算法[5]、强化学习[6]等智能方法应用到交通信号控制研究中。

本文研究将深度强化学习技术与多智能体系统应用于交通信号的控制与协调中。首先，提出一种基于深度强化学习算法的交通信号控制方法，对强化学习的状态、动作、奖励进行定义，通过深度双 Q 网络和优先级经验回放策略使智能体能够学习到有效的控制策略，在单路口交通环境中该算法取得了较好的控制效果。然后，在单路口的交通控制的基础上，结合多智能体控制和纳什均衡策略，将单智能体强化学习算法应用到多智能体环境中，提出了基于协作式多智能体区域交通信号控制方法。最后，通过基于 SUMO 的交通信号仿真系统，验证了本文提出的算法能实现区域交通信号协调控制，能有效地缓解交通压力。

1.2 国内外研究现状

城市交通信号控制是一个重要且具有挑战性的研究方向，其目的是通过协调车辆在交叉路口的移动来最大程度地缩短车辆平均行驶时间[7]。自 Webste[8] 1958 年首次发布交通信号控制方法以来，对城市交通控制的研究已经超过 60 年。控制方法包括定时控制、感应式控制和自适应控制，从单交叉口的信号控制到目前主要研究的区域交通信号协调控制[9]。

定时信号控制是最基础的控制方法，主要适用于交通量可以预测、变化模式基本固定的城市中心地区，其包括单段式定时控制和多段式定时控制两种形式。这种控制方法的优点在于容易实现协调控制、建设费用低以及安装维护方便，缺点在于不能适应实际交通流的变化，目前在中国等发展中国家应用广泛。在国外，英国学者 Webster[8]建立了以车均延误最小为目标的固定周期信号配时方法，即交通工程界熟知的 Webster 法，也称 TRRL（Transport and Road Research Laboratory）法，至今仍然是定时信号控制的重要基础。澳大利亚学者 Akcelik[10]首次提出了多目标优化的配时方法，即将停车延误时间和停车次数结合在一起作为优化目标，并引入“停车补偿系数”，被称为 ARRB（Australian Road Research Board）法。Park 等人[11]针对定时信号控制的不足，将遗传算法的接口技术与仿真模型相结合，同时对相位差、绿信比

中国知网 https://www.cnki.net

和周期时长进行优化，提出了一种随机信号控制优化方法。

感应控制是通过车辆检测器测定到达进口道的交通情况，使信号显示时间随交通到达情况而变化的一种控制方式，目前在美国等发达国家应用广泛。根据感应信号控制实施的方式划分，感应控制可以分为半感应控制、全感应控制和优化感应控制三种类型，其中半感应控制又可细分为主路半感应和次路半感应。感应控制的优点在于能够充分利用绿灯时间，提高通行能力，使车辆在停车线前尽可能不停车，从而达到安全、通畅的通车效果；缺点在于仅适合交通量不大且车辆到达较波动的情况。Cowan[12]基于实时交通条件构建了感应控制模型，并给出了车辆平均延误和平均排队长度的计算公式。Akcelik[13]提出了一种用于估算车辆感应控制下的平均绿灯时间和周期时长的分析方法，为研究感应控制下交叉口的特性提供了重要基础。Furth 等人[14]考虑了最小绿灯时间和最大绿灯时间约束的双环结构，提出了感应控制周期损失时间和平均周期的计算方法。Bai 等人[15]提出了一种基于感应控制和相位跳跃的交通引导方法，有助于更好地引导饱和状态下的车辆通行。

自适应控制是一类无需人的干预就能够自主地驱动智能机器实现其目标的自动控制。通过引入模糊逻辑、神经网络、专家系统、遗传算法等控制理论与自适应控制、自组织控制、自学习控制等人工智能技术，使其在控制过程中不再单纯依赖精确的数学模型，故非常适用于具有强非线性、复杂性和不确定性的城市交通控制系统。80 年代初期，Hunt 等人[16]提出的 SCOOT 方法以及 Luk 等人[17]基于 SCOOT 改进的 SCATS 方法，是最早期的自适应信号控制方法，也是现阶段社会上交通信号中投入使用最多的自适应交通信号控制方法。自我组织交通信号 (Self Organizing Traffic Lights) [18]作为一种新的方法类型，提供了一种周期性循环、相位时长非固定的控制策略，这种类型的方法要求相位依固定次序轮流出现，其次序不可改变。Li 和 Schonfeld[19]提出一种基于模拟退火（SimulateAnneal，SA）和遗传算法（Genetic Algorithms,GA）的混合算法，用于城市主干道信控优化，数值结果表明，SA-GA 算法在解决方案质量和收敛速度方面优于 SA 和 GA。Hoogendoorn[20]提出了一种基于受控马尔可夫过程概念的新控制框架，该框架明确考虑了预测的交通条件和系统性能的不确定性，也有研究利用多级在线学习过程来更新和调整其知识库和决策机制，以及利用高阶神经网络逼近动态交通系统。

区域交通信号协调控制是城市交通信号控制研究中的主要研究方向，由于城市交通路网中交叉口的控制系统不仅要满足自身的控制需求，还需要考虑相邻交叉口的影响，以实现区域交通协调优化控制。对于交通信号的协调控制问题，一种方法是通过对一个区域中的多个交叉口进行集中控制，随着路网规模的扩大，集中式控制方法由于联合动作空间过大问题无法被广泛应用[21]；还有一种使用分布式的方法，每个智能体能独立对本地交通信号进行控制，

中国知网 https://www.cnki.net

通过与相邻路口共享信息的方式实现协调控制[22]。

国外研究者在区域交通信号协调控制领域的研究现状如下。

Wiering 等人[23]首次提出了一种基于多智能体强化学习的交通信号控制算法。以最大程度地减少城市中车辆等待时间，多智能之间通过不同类型的全局通信方式进行决策。实验结果表明，算法的性能优于非自适应交通灯控制器，该算法在小型网络上取得了较好的控制效果，但是无法实现对大型路网的交通协调控制。Abdoos 等人[24]将一个相对较大的交通路网建模为多智能体系统，通过收集路网的局部信息，使用 Q-learning 学习最佳控制策略，动作空间的参数表示使该方法可扩展到不同类型的交叉口。仿真结果表明，在不同的交通需求下，所提出的算法优于固定时间方法，但是该方法没有实现多路口的协调控制。El-Tantway 等人[25]提出了一种用于自适应交通信号控制器的集成网络多智能体强化学习系统。使用强化学习方法和博弈论的协同学习交通信号控制，系统能够以独立模式和集成模式运行，独立模式是每个路口控制器独立于其他智能体运行，集成模式是每个控制器与相邻的交叉口协调信号控制动作，并在小型、中型、大型三个交通路网上进行了测试，证明了该系统的设计合理性和可移植性。Chu 等人[26]提出了一种完全可扩展的、分散的多智能体强化学习算法，使用 Advantage Actor Critic 作为算法的网络模型，通过对邻域智能体进行通信，提高了算法的观测能力，引入空间折扣因子以降低学习难度。在大型综合交通网格和大型真实摩纳哥城市交通网络中，模拟高峰时段交通流，将提出的算法与独立的 A2C 和独立的 Q 学习算法进行了比较，结果表明该算法有更好的控制效果。Chen 等人[27]提出了一种分布式深度强化学习方法以解决城市级别的交通信号控制问题。将城市路网中每个交叉口建模为一个独立的智能体。通过在各智能体之间共享学习经验提高学习速度，为了实现协调，引入了最大压力的方法来对智能体进行设计。通过在多个场景中进行仿真实验，包括在纽约市曼哈顿 2510 个交通灯的真实场景，表明了该模型的有效性。Nishi 等人[28]和 Hua 等人[29]提出使用图卷积网络的方法，基于协作的多智能体学习彼此之间的通信。该方法不仅能学习相邻智能体与目标智能体隐藏状态之间的相互作用，而且还能学习交叉口多级之间的影响。

国内也有很多研究者对区域交通信号协调控制进行研究，主要研究现状如下。

温凯歌[30]提出了一种交通路口的随机动态模型，并结合强化学习算法，以最小化排队长度为目标实现了交通信号的控制。通过对比实验验证了该算法具有较高的控制效率。杨文臣等人[31]根据多智能体强化学习交通信号控制方法在国内外研究情况，对当前研究现状进行了分类归纳总结，并对未来的研究方法提出了展望。吴昊[32]提出了基于马尔科夫决策过程的强化学习信号控制方法，使用停车次数作为算法的奖励，通过搭建交通仿真平台对提出的算法进行实验验证，证明了该方法可以降低车辆在交叉口的停车次数和延误时间。Li 等人[33]提出

中国知网 https://www.cnki.net

了一种基于区域交通控制的深度强化学习算法。通过深度学习的方法来减少车辆与环境交互产生的大量交通流数据，然后使用堆叠降噪自动编码器来去除产生的异常数据，通过与固定时间方法和传统强化学习进行对比实验，证明了该算法的优越性。唐菁[34]提出了基于半监督双竞争网络的宽度强化学习的交通信号控制方法。通过半监督学习方法解决交通控制中的小数据集问题，研究了不同的参数对算法的控制性能的影响。通过在 SUMO 微观仿实验证明算法的有效性。孙浩[35]提出了基于深度强化学习的交通网络信号协调控制算法。使用模型迁移方法将单交叉口的交通信号控制迁移到多路口的交通信号控制中，并通过价值分布共享多路口之间的状态信息，通过空间折扣因子区分状态信息的重要性。通过在低流量和高流量的区域路网进行对比实验，验证了算法的优越性。谢东瀚[36]提出了基于中心协调网络的多智能体强化学习交通信号控制算法，将中心协调网络学习方法解决了由于区域路网中交通流的不确定性导致算法收敛差的问题，将平均域近似算法加强多智能体之间的局部通信能力。通过在设计的区域路网中仿真实验，证明了算法能更好实现区域交通信号的协调控制，极大地提高了交通效率。

1.3 本文主要研究内容

为有效解决城市交通拥堵问题，本文通过对区域交通信号控制方法进行分析，得出基于多智能体深度强化学习的交通信号控制算法是解决这一问题的有效方法之一。主要研究包括以下方面：

首先，针对深度强化学习算法在交通控制应用中，存在算法收敛速度慢、控制效果差等问题，本文提出了一种基于深度双 Q 网络的交通信号控制算法。采用离散化状态编码方法将交通信息转化为由车辆位置信息和速度信息组成的二维矩阵作为强化学习状态，将路口交通相位压力差作为算法的奖励，压力的计算不仅考虑了道路上车辆排队长度，还考虑了道路的容量问题。通过优先级经验回放策略，提升训练样本的利用率，加快算法收敛速度。在单路口环境中对所提出的算法进行仿真实验，证明了算法具有更快的收敛速度和更好的性能表现。

其次，针对区域交通信号控制中由于路网复杂性，对控制算法的协调性要求高的问题，本文将单交叉口的强化学习交通信号控制算法扩展到区域交通控制中，提出了一种基于协作式多智能体深度强化学习区域交通信号协调控制方法。该方法将区域交通路网建模为一个无向图，图中每个结点作为一个强化学习智能体，通过多智能体之间马尔可夫博弈达到纳什均衡，智能体决策过程中考虑了相邻节点的状态和奖励信息，实现对交通信号的协调控制。仿真实验表明，该方法能更好地实现对区域交通信号的协调控制。

中国知网 https://www.cnki.net

最后，基于 SUMO 微观交通仿真软件和 Python 编程语言构建了一个区域交通协调优化控制仿真系统。在SUMO中构建区域交通路网模型，Python编程语言实现深度强化学习框架，为基于强化学习的交通信号协调控制算法提供了一个仿真实验平台。通过对实际交通路网建模和协调控制模块的设计，利用深度强化学习交通信号控制算法在该系统上仿真实验，结果表明了该系统能很好地进行二次开发，能实现对交通信号控制算法的实验验证。

1.4 本文的组织结构

第一章：绪论。介绍目前城市交通信号控制研究背景及意义。对国内外对基于深度强化方法在区域交通信号控制中的研究现状进行介绍，阐述本文的主要研究内容和具体章节安排。

第二章：交通信号控制及相关机器学习理论。首先介绍交通信号控制的基本参数和评价指标，以及主要的交通信号控制类型；然后对强化学习中的马尔科夫的决策过程和 Q-学习方法进行概述；最后对两种深度强化学习算法和多智能体强化学习进行介绍。

第三章：基于深度强化学习的路口信号控制方法。通过对深度强化学习交通信号控制问题进行描述，定义强化学习三要素，详细介绍了基于归一化压力差的方法作为奖励，结合基于优先级经验回放策略的 DDQN 算法，实现对交叉口的交通信号控制。最后通过仿真实验证明算法的有效性。

第四章：基于多智能体深度强化学习的区域交通信号控制方法。通过分析目前强化学习算法在区域交通信号控制中的应用，提出了一种多智能体深度强化学习算法，多智能体通过马尔科夫博弈达到纳什均衡，并通过共享信息方式提高控制策略的协调能力。最后通过实验验证了所提算法的有效性，提高交通流的通行效率。

第五章：基于SUMO的区域交通控制仿真系统。对微观仿真软件以及仿真环境进行介绍，搭建一个交通控制方法的仿真系统，详细介绍了仿真系统的设计与搭建，以及各个模块实现的功能。通过建立一个实际路网的微观模型，实现了对基于强化学习算法在系统仿真模拟。

第六章：总结与展望。总结了本文所做的研究内容以及存在的不足，对于未来的研究方向作出展望。

中国知网 https://www.cnki.net

第二章 交通信号控制及相关机器学习理论

2.1 交通信号控制

2.1.1 信号控制基本参数

（1）信号周期

信号周期是指交通信号灯按顺序执行一周所用时长。周期时长影响路口交通信号灯的控制的效果。

（2）信号相位

信号相位作用是给交叉口上各个驶入车道上交通流分配通行权，避免产生交通混乱。本交叉口采用四相位控制方案，图 2.1 表示了四相位控制的示意图。

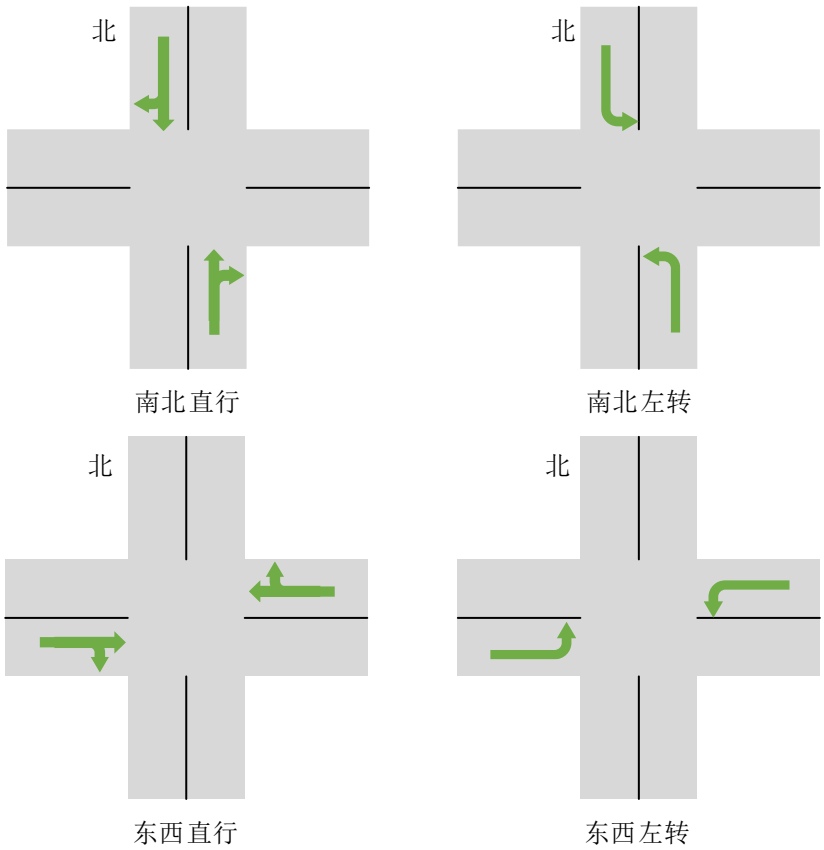

图 2.1 交通控制中四相位示意图

（3）绿信比

绿信比是指一个在信号周期内，某个相位的绿灯时长t_{Gi}与信号周期时长 T 的比值，第 i 个相位的绿信比λ_i表示为：

中国知网 https://www.cnki.net

$$\lambda_i = \frac{t_{Gi}}{T} \tag{2.1}$$

（4）交通流量

交通流量是在单位时间内通过车道上某一点车辆的数量。交叉口上游道路的交通流量和车道上车流离散程度影响下游车道的交通流量大小。

2.1.2 评价指标

为了定量考虑交通流对路网交通整体运行的影响，保证评价结果的科学性、全面性和客观性，评价指标的建立应做到科学、客观、全面，充分地反映交通拥堵程度。主要有以下几个评价指标。

（1）行驶时间

在交通信号控制中，车辆行驶时间定义为车辆进入交通系统与离开交通系统的时间差。

（2）延误时间

交叉路口延误时间是实际行驶时间与标准行驶时间值的差值。该指标表示车辆通过路口时所用时间，延误时间值越大表明交叉路口越拥挤。

（3）排队长度

排队长度是指在交叉口驶入车道上速度小于 0.1m/s 车辆的数量。排队长度是评价交通状况的重要指标，一般情况下，平均队列长度越长表示当前交叉口拥堵程度越严重。

（4）吞吐量

吞吐量是指单位时间内交叉口各驶入车道车辆通过交叉口数量总和，可以反映了发生交通拥堵的概率。

2.1.3 交通信号控制方式

按照控制范围可以将交通信号控制方式分为：

（1）单路口控制

单路口控制是交通信号控制中最基本的控制方式，是城市交通信号控制的基础。单路口控制不需要考虑其他路口的控制策略的影响，适用于距离相邻路口比较远、关联程度较低的交通路口。在我国城市交通信号控制方式中，单路口交通信号控制仍然占有较大的比例[37]。

（2）干线协调控制

干线协调控制指将主干道上若干个连续交叉口作为研究对象，实现所用交叉口的协调控

中国知网 https://www.cnki.net

制[38]。“绿波”交通信号控制方法是干线协调控制中的经典方法，对于主干道上的交通流在到达每个交叉口时都能分配到通行权，形成一条绿波带[39]。

（3）区域协调控制

区域协调控制是将城市交通路网中某一区域作为研究对象，对区域内交通信号的协调控制。在区域路网中，每个交叉口不是独立存在的，相邻路口间的信号控制是相互影响的。根据区域内交通流的特征以及控制策略的不同，可以对单个交叉口控制，也能对多个交叉口联合控制。区域协调控制方法的目标都是通过对整个区域内交通信号进行协调控制，使整体的通行效率最高[40]。

按照不同的控制策略还可以将交通控制分为：

（1）定时控制

定时控制是使用历史统计交通数据，给出一个统一的或基于一天时间的交通信号配时方案。该方法适用于交通需求和模式在很长一段时间内保持一致的交叉口。定时控制的优点是这种无探测方法不需要传感器，具有较低的安装和维护成本；缺点是其配时方案都是基于历史交通流数据，对交通流的控制不够灵活，无法在车流不断变化的实际路网场景中进行控制。

（2）感应控制

感应控制是根据感应线圈或者感应器的方式获得交通流数据以设置相应信号配时方案。感应控制能够根据不同时刻交通流数据的变化实时调整控制方案，能够适应交通流的动态变化并提升控制效果。

（3）自适应控制

自适应控制根据交通流实时信息，采用专家系统、智能算法等方式实现交通信号的自适应控制。这类方法能够有效提升交通路网通行效率，减少交通拥堵，也是目前研究的主要方向。智能控制算法是一种具有学习、抽象推理和决策能力的方法，能够随着环境变化给出相应的自适应调整。

在自适应控制中，智能控制方法结合了人工智能的相关技术，拥有独立决策的能力，较强的实时性、鲁棒性和独立性，是如今研究的重点方向。本文研究了强化学习、深度学习、多智能体技术在交通信号控制中的应用，下面对这些方法的基本原理进行介绍。

2.2 强化学习

强化学习（Reinforcement Learning, RL）[41]是机器学习中的一个领域，智能体通过与环境交互，在没有任何先验知识的情况下通过学习策略，达到一个特定的目标。这个过程通常也

中国知网 https://www.cnki.net

被表述为马尔可夫决策过程(Markov decision processes, MDP) [42]。

2.2.1 马尔科夫决策过程

智能体和环境之间的关系可以建模为马尔可夫决策过程，智能体必须利用已有的经验来获取奖励，同时进行探索，使得未来可以获得更好的动作选择空间（即从错误中学习）。智能体通过观察环境得到反馈和下一个状态，然后选择动作的过程，就是一个马尔可夫决策过程。

图 2.2 说明了强化学习的马尔科夫决策过程，一个智能体在时间t时感知环境当前状态S_t，然后在一个特定策略π下执行一个动作A_t，得到来自环境接反馈的奖励R_t和下一时刻的状态S_{t+1}。在给定的控制条件下，如何优化策略以获得最佳的控制效果是强化学习的核心问题。

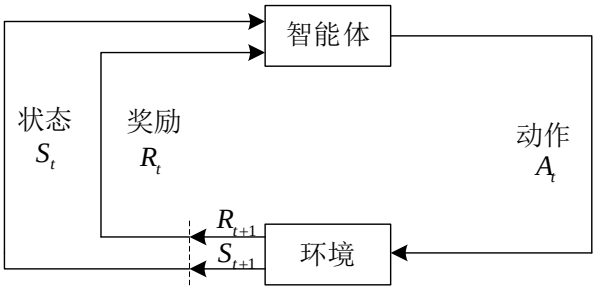

图 2.2 马尔可夫决策过程

（1）马尔可夫过程

马尔可夫决策过程是强化学习算法的核心，描述了由环境的一系列可能状态组成的随机模型，当前环境的状态仅依赖于前一个状态，这也称为马尔可夫性。强化学习问题中环境的状态符合马尔科夫性，即在当前状态S_t下执行动作A_t并转移至下一个状态S_{t+1}，而不需要考虑之前的状态$S_{t-1},\dots,S_1$。也就是说，状态S_t从历史中捕获了所有相关状态信息，如果状态$S_{t-1},\dots,S_1$被丢弃，仍然得到当前状态S_t到下一个状态S_{t+1}转移概率，转移概率表示为：

$$\mathbb{P} = [S_{t+1}|S_t] = \mathbb{P}[S_{s+1}|S_1, S_2, S_3, \dots, S_t] \tag{2.2}$$

马尔科夫过程是随机过程的一种，又被称为马尔科夫链。描述空间状态由一个状态转移到另一个状态的随机过程，由一个二元组$M = \langle S, P\rangle$表示，S 是有限状态的集合，P 是状态转移概率。

状态转移矩阵由状态转移概率组成，状态转移概率是指从一个马尔科夫状态 s 转移到下一个状态s'的概率，表示为：

$$P_{ss'} = \mathbb{P}[S_{t+1} = s'|S_t = s] \tag{2.3}$$

假设有 n 个状态，将所有的状态从上到下、从左到右排列，组成一个 $n\times n$ 的矩阵，那么其状态转移矩阵如下式所示：

中国知网 https://www.cnki.net

$$P = \begin{bmatrix} P_{11} & \cdots & P_{1n} \\ \vdots & \ddots & \vdots \\ P_{n1} & \cdots & P_{nn} \end{bmatrix} \tag{2.4}$$

（2）马尔科夫奖励过程

马尔科夫奖励过程（Markov Reward Process, MRP）描述的是状态之间的转移关系，在各个状态的转移过程中赋予不同的奖励值就得到了马尔科夫奖励过程。马尔科夫奖励过程由一个四元组$\langle S, P, R, \gamma \rangle$组成。$S$ 代表了状态的集合（维度有限的）；P 描述了状态转移矩阵 $P_{ss'} = \mathbb{P}[S_{t+1} = s' | S_t = s]$；$R$ 表示奖励函数，$R(s)$描述了在状态s下的期望奖励，$R_s = \mathbb{E}[R_{t+1} | S_t = s]\gamma$；表示衰减因子，$\gamma \in [0,1]$。我们的目标是最大化整个过程中得到的奖励，状态$S_t$的价值可以通过回报函数$G_t$进行评估，表示为：

$$G_t = R_{t+1} + R_{t+2} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \tag{2.5}$$

马尔科夫奖励过程的状态价值函数表示为：

$$V(s) = \mathbb{E}[G_t | S_t = s] \tag{2.6}$$

（3）马尔可夫决策过程

马尔可夫决策过程是马尔可夫奖励过程的扩展，它包含智能体做出的动作。如果环境中的所有状态都符合马尔可夫性，则马尔可夫决策过程用五元组表示为$\langle S, A, P, R, \gamma \rangle$，其中 S 代表有限状态集合，P 是状态转移矩阵，A 代表了决策过程中有限动作的集合，γ表示未来衰减因子，$\gamma \in [0,1]$，R 表示奖励函数，可以表示为：

$$R_{(s,a)} = \mathbb{E}[R_{t+1} | S_t = s, A_t = a] \tag{2.7}$$

智能体在特定状态下采取动作是由策略π决定的，MDP 策略描述了当前状态与动作之间的关系。可以表示为：

$$\pi(a|s) = \mathbb{P}[A_t = a | S_t = s] \tag{2.8}$$

策略描述了一个状态到下一个状态的映射关系。如果当前处于状态S_t，智能体会从该状态映射出采取每个可能动作的概率。

强化学习通常被抽象为一个马尔可夫决策过程，即寻找最优策略的过程。学习者和决策者叫做 Agent，与 Agent 进行交互的其它一切 Agent 之外的都是环境。Agent 不断地选择动作，环境也给出相应的反馈，达到新的状态。Agent 的目标就是通过选择不同的动作来最大化这个反馈值，期望奖励是对当前所处的状态的评价。

MDP 的状态价值函数$V_\pi(s)$是从状态 s 开始，遵循策略π所获得的期望回报：

中国知网 https://www.cnki.net

$$V_\pi(s) = R_{t+1} + R_{t+2} + \cdots = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s\right] \tag{2.9}$$

动作值函数$Q_\pi(s,a)$是从状态 s 开始，采取动作 a，然后遵循策略π获得的期望回报：

$$Q_\pi(s,a) = \mathbb{E}_\pi[G_t | S_t = s, A_t = a] \tag{2.10}$$

在上述所有等式中都使用给定的策略来选择动作执行，这可能导致执行的动作并不是具有最大状态-动作值的动作，强化学习的关键目标是找到使我们的奖励最大化的最优策略。

最优状态价值函数$V_*(s)$是所有策略的最大值函数。可以从系统中获取的最大期望奖励。

$$V_*(s) = \max_\pi v_\pi(s) \tag{2.11}$$

最优动作价值函数$Q(s,a)$是所有策略的最大动作值函数。它告诉我们从状态 s 开始并采取行动 a，从系统中获得的最大期望奖励。

$$Q_*(s,a) = \max_\pi Q_\pi(s,a) \tag{2.12}$$

通过最大化$Q_*(s,a)$可以找到最优策略：

$$\pi_*(a|s) = \begin{cases} 1 & if \;\; a = argmax_{a\in A} Q_*(s,a) \\ 0 & otherwise \end{cases} \tag{2.13}$$

2.2.2 Q-学习

强化学习是一种介于监督学习和无监督学习之间的方法。它不是严格的监督学习，因为其训练不依赖于标记过的数据，也不是无监督学习，因为强化学习中有奖励机制，智能体需要在环境的不同状态下采取的“正确”动作以实现其目标。根据智能体是否能和环境进行交互可以将强化学习方法可以分为基于模型（Model-Based）和无模型两类（Model-Free）。基于模型强化算法为智能体创建一个虚拟模型，通过学习状态s_t到s_{t+1}的转移概率，在每个特定环境中执行动作对模型训练学习；无模型强化算法是对未知环境进行探索，智能体是通过试错学习来选择最优策略。无模型强化学习算法更加适用于交通仿真场景。

将智能体在状态s_t下采取动作a_t取得的最大期望回报表示为$Q_*(s,a)$。由贝尔曼方程可得：

$$Q_*(s,a) = \mathbb{E}\left[r(s_t,a_t) + \gamma \max_{a_{t+1}}(s_{t+1}, a_{t+1})\right] \tag{2.14}$$

基于价值的强化算法有 Q-learning[43]和 SARSA[44]。在这两种算法中，状态-动值（Q-value）都存储在 Q 表中，并通过 Bellman 方程的递归性质和马尔科夫特性来更新 Q 表。更新公式为：

$$Q(s_t,a_t) \leftarrow Q(s_t,a_t) + \alpha\left[r(s_t,a_t) + \gamma \max_{a_{t+1}} Q(s_{t+1},a_{t+1}) - Q(s_t,a_t)\right] \tag{2.15}$$

中国知网 https://www.cnki.net

2.3 深度强化学习

2.3.1 深度学习

深度学习（Deep Learning, DL）[45]是机器学习的一个分支，也是人工智能研究前沿领域。深度学习在语音处理、计算机视觉、自然语言处理和医学应用等多个领域有广泛的应用[46]。深度学习的原理是利用多个分类器和一些激活函数一起工作，与传统的统计线性回归方法不同的是深度学习中有很多神经节点，这些神经节点也称为神经网络，一个分类器节点就是一个神经单元。在深度学习中，输入和输出之间有多层神经网络，每层由数百甚至数千个神经单元组成，这些网络层称为隐藏层，节点称为隐藏节点。

卷积神经网络[47]（Convolutional neural Networks, CNN）最早是在 20 世纪 80 年代提出的。卷积神经网络作为一种多层神经网络，每一层都是由多个二维平面组成，每个平面都有独立的神经元组成的。每个特征图（feature map）中的神经元只连接上一个特征图中一个小区域内的神经元。

LeNet-5 系统[48]是一个典型的卷积神经网络模型，在 MNIST 数据集上，它的错误率只有 0.9%，被广泛用于识别银行的手写支票，但不能识别大图像，图 2.3 为 LeNet-5 的网络。随着图形处理单元（Graphics Processing Unit, GPU）技术的快速发展，2012 年 Krizhevsky 等人[49]利用 GPU 解决了 ImageNet 问题，使得卷积神经网络再次流行起来。事实上，深度神经网络的瓶颈之一是其网络中隐藏的节点较多导致了训练时间长。但随着 GPU 在并行计算方面的速度越来越快，这个问题也逐渐被解决。

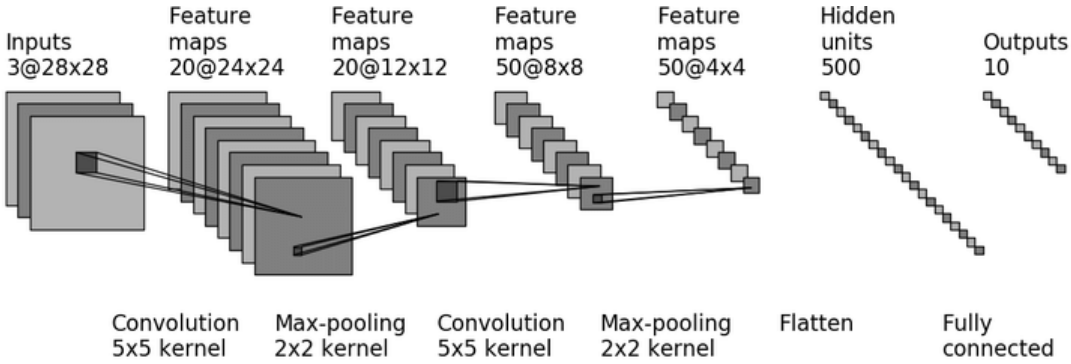

图 2.3 LeNet-5 Network

2.3.2 深度 Q 学习

Mnih 等人[50]于 2015 年提出了深度强化学习（Deep Q Network, DQN），算法结构图如图

中国知网 https://www.cnki.net

2.4 所示，引入了目标网络和经验回放两种技术，算法在几款经典雅达利视频游戏上的表现都远远超过了人类专家的水平。

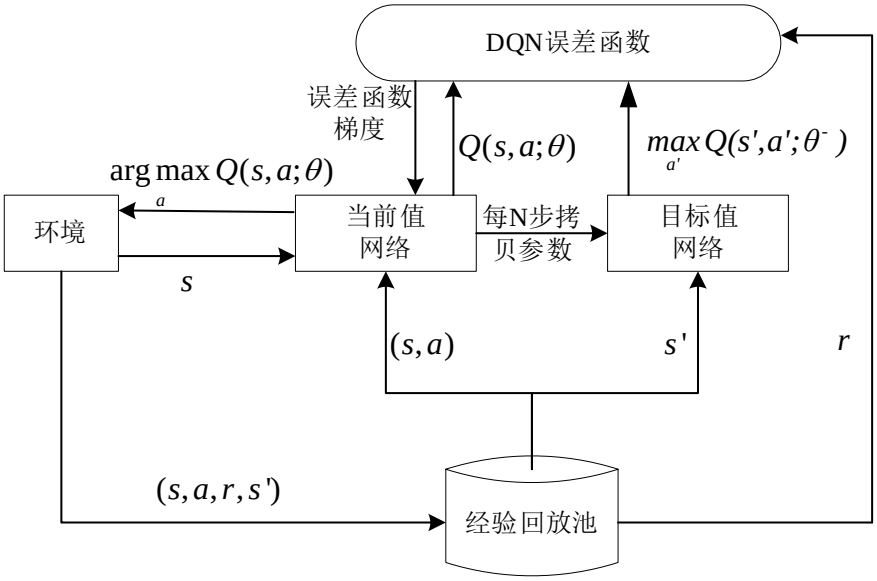

图 2.4 深度 Q 网络训练流程

在 Q-学习算法中，使用同一个神经网络来计算目标值和对目标值进行估计，这会导致在每次更新神经网络的时候，目标值也会随着神经网络改变，导致算法难以收敛。DQN 中加入了一个新的目标网络，当前网络和目标网络分别用$Q(s,a,\theta)$和$Q(s,a,\theta^-)$表示，θ和θ^-网络参数，在模型训练的过程中，当前网络根据环境当前状态s_t，选择一个具有最大价值函数的动作a'，目标网络会对选的动作进行评估，计算出在下一个状态s_{t+1}选择动作a'得到的 Q 值。目标值Y_t^{DQN}计算公式为：

$$Y_t^{DQN} = r + \gamma \max_{a'} Q(s_{t+1}, a'; \theta^-) \tag{2.16}$$

通过当前网络计算的价值$Q(s_t,a;\theta)$和目标网络计算价值估计$\max_{a'} Q(s_{t+1},a';\theta^-)$，计算出误差函数$L(\theta)$，并通过梯度下降法对更新当前网络参数，每个固定迭代步数，将当前网络参数同步给目标网络。误差函数计算公式为：

$$L(\theta) = E\left[\left(r + \gamma \max_{a'} Q(s_{t+1}, a'; \theta^-) - Q(s_t, a; \theta)\right)^2\right] \tag{2.17}$$

DQN 引入的另一技术是经验回放策略，它将训练过程中与环境交互获得的数据以四元组$\langle s_t, a_t, r_t, s_{t+1}\rangle$的形式存储在经验回放池中，通过统一采样样本对神经网络进行训练。由于强化学习连续的经验样本在时间上具有相关性，需要通过小批量采样进行学习提高训练效率。神经网络也需要大量的数据进行训练以达到收敛状态，经验回放机制可以对经验样本重复利用，加快算法的收敛速度。

具有经验重放策略和目标网络 DQN 算法流程如算法 2.1 所示。

中国知网 https://www.cnki.net

算法 2.1：基于经验回放的 DQN 算法

初始化经验回放池 D，回放池容量 N，ϵ参数，折扣系数γ，学习率α，训练回合数 M，每回合步数 T

初始化神经网络 Q-Network、Target-Network，网络参数θ，θ^-

for $episode = 1,\ M$ **do**

初始化仿真环境，初始化s_t

for $t = 1, T$ **do**

根据ε-*greedy* 策略，以概率ϵ从动作空间选择一个随机动作a_t

否则 Q-Network 根据$a_t = \max_a Q(s_t, a; \theta)$选择动作

执行动作a_t，智能体从环境得到奖励r_t和新的状态s_{t+1}

将经验样本$e = \langle s_t, a_t, r_t, s_{t+1} \rangle$存储在经验缓冲池 D 中

从经验回放池 D 中抽取数量为 *minibatch* 的经验样本$\left(s_j, a_j, r_j, s_{j+1}\right)$

$$y_j = \begin{cases} r_j & s_{j+1}\text{是最后一个状态} \\ r_{j+\gamma \max_{a'} Q(s_{j+1}, a', \theta^-)} & s_{j+1}\text{不是最后一个状态} \end{cases}$$

根据损失函数通过梯度下降法更新 Q-Network 的网络参数θ

每隔 C 步更新 Target-Network 网络参数θ^-，$\theta \leftarrow \theta^-$

end for

end for

2.3.3 深度双 Q 学习

在 DQN 中，通过当前网络$Q(s, a, \theta)$选择动作，每次迭代中采用max函数选择一个具有最优动作的 Q 值作为对动作的评估，这个过程会导致过估计的问题。Van Hasselt 等[51]提出了深度双 Q 网络（Double Deep Q Network, DDQN），DDQN 算法将动作选择和动作评估分开来缓解 Q 值的过估计问题。

首先通过当前网络$Q(s, a, \theta)$计算对所有可能的动作 a 的 Q 值，利用 argmax 函数选择最大 Q 值的动作，计算公式如下：

$$a' = \underset{a'}{argmax}\, Q(s_{t+1}, a'; \theta) \tag{2.18}$$

然后在目标值网络$Q(s, a, \theta^-)$中对选择的动作进行评估，目标值定义为：

$$Y_t^{DDQN} = r + \gamma Q\left(s_{t+1}, \underset{a'}{argmax}\, Q(s_{t+1}, a'; \theta); \theta^-\right) \tag{2.19}$$

DDQN 算法与 Nature DQN 算法具有相同的算法训练流程，DDQN 算法有时可能会低估

中国知网 https://www.cnki.net

动作值，但弥补了高估偏差的缺陷，可以更快地达到收敛状态。

2.4 多智能体强化学习

2.4.1 多智能体系统

多智能体强化学习是强化学习方法在多智能体系统中的应用，具有重要的研究意义[52]。在多智能体系统中，每个智能体根据自身的策略执行动作，同时还受系统中其他智能体动作的影响[53] 。多智能体强化学习按照智能体之间的关系分为基于完全合作、基于完全竞争，以及两者的结合[54]。在完全合作环境下，所有智能体朝着一个共同目标努力；而在竞争环境中，智能体为了完成一个目标而相互竞争，得到的回报总和通常为零。混合环境中既有合作关系，也有竞争关系。

多智能体强化学习可以分为独立式多智能体学习和集中式多智能体学习两种方式。在独立式多智能体学习中，每个智能体将其他智能体视为环境的一部分，根据本地或者局部环境独立进行决策。集中式多智能体学习通过联合系统中所有的状态，采用单智能体的方式选择一个联合动作对环境进行控制[55]。这种方法在智能体数量较多的控制系统中，由于联合状态空间和联合动作过大导致算法难以收敛。采用分布式方法可以解决状态空间爆炸的问题[56-57]，在基于分布式多智能体系统中，每个智能体可以通过信道获取其他智能体的信息，使用集中式的方式对所有智能体集中训练，最后通过分布式方式实现每个智能体的独立决策。随着系统中智能体数量不断增多，评价器网络规模不断扩大，集中式训练的方式无法处理较大规模多智能体的学习问题[58] 。基于信息共享的多智能体分布式方法可以解决这类问题，通过将多智能体系统建模为一个网络拓扑结构，相邻智能体之间可以通过共享网络参数、环境的观测、值函数等信息，解决智能体的协调控制问题。本文也采用基于信息共享的协作式多智能体方法，解决区域交通信号的协调控制问题。

2.4.2 马尔科夫博弈中多智能体

马尔科夫博弈（Markpv Game, MG）[59]是马尔科夫决策过程在多智能体系统环境中的扩展，马尔科夫博弈属于随机博弈问题。

在马尔科夫博弈中，可以用五元组$\langle \mathcal{S}, \{\mathcal{A}_i\}_{i\in n}, \mathcal{T}, \{\mathcal{R}_i\}_{i\in n}, \gamma\rangle$表示 n 个智能体的马尔科夫博弈关系，其中，$\mathcal{S}$是整个环境的有限状态空间集合；$\mathcal{A}_i$是每个智能体 i 能够选择的动作空间集合；$\mathcal{T}: \mathcal{S} \times \mathcal{A}_1 \times \ldots \mathcal{A}_n \times \mathcal{S} \rightarrow [0,1]$是转移函数，给出每个智能体在状态下选择动作转移到下一

中国知网 https://www.cnki.net

个状态的概率；$\mathcal{R}^i: \mathcal{S} \times \mathcal{A} \times \mathcal{S} \to \mathbb{R}$是每个智能体 i 是在每种状态$\mathcal{S}$下获得的预期奖励；联合动作空间$\mathcal{A} = \mathcal{A}_1 \times \mathcal{A}_2 \times \ldots \mathcal{A}_n$影响$\mathcal{R}_i$和$\mathcal{T}$，状态的转换是由所有智能体的联合动作决定的，一个智能体的行为直接或间接地影响另一个智能体的奖励。将全局状态$s \in \mathcal{S}$映射到局部动作$a^i \in \mathcal{A}$，其概率为$\pi^{(i)}(s, a_i) \in [0,1]$；$\gamma \in [0,1]$是折扣因子。图 2.5 是马尔科夫博弈的过程。

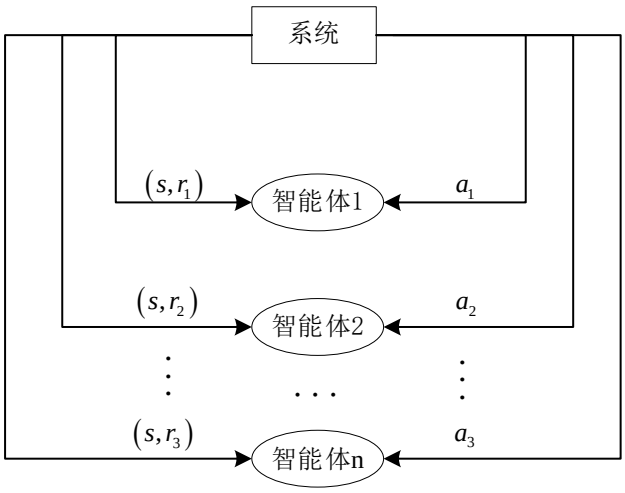

图 2.5 马尔科夫博弈过程

当在具有多个智能体的系统中，每个智能体学习的目标是最大化自己的奖励，对于整个环境，没有一个统一指标能够衡量整个系统的优劣。在马尔科夫博弈零和情况下，系统的总奖励总和始终为零，导致系统的回报与策略无关。纳什均衡描述了任何一组策略$(\pi_i^*, \cdots \pi_n^*)$，使得每个智能体 i 的对所有的状态$s \in \mathcal{S}$满足如下不等式：

$$V_i\left(s, \pi_1^*, \cdots, \pi_i^*, \cdots, \pi_n^*\right) \geq V_i\left(s, \pi_1^*, \cdots, \pi_i, \cdots, \pi_n^*\right), \pi_i \in \prod_i \tag{2.20}$$

其中$\prod_i$ 是所有智能体策略的集合，$V_i\left(s, \pi_1^*, \cdots, \pi_i^*, \cdots, \pi_n^*\right)$表示所有智能体全部达到纳什均衡时智能体 i 得到的累计收益。

$$V_i\left(s, \pi_1^*, \cdots, \pi_i^*, \cdots, \pi_n^*\right) = \sum_{a_1, \cdots, a_n \in A_1 \times \cdots \times A_n} Q^*\left(s, a_1, \cdots, a_n, s'\right) \pi_1^*\left(s, a_1\right) \cdots \pi_n^*\left(s, a_n\right) \tag{2.21}$$

$Q^*\left(s, a_1, \cdots, a_n\right)$表示状态-动作价值函数，计算公式为：

$$Q^*\left(s, a_1, \cdots, a_n\right) = \sum_{s' \in \mathcal{S}} \mathcal{T}\left(s, a_1, \cdots, a_n, s'\right)\left(\mathcal{R}_i\left(s, a_1, \cdots, a_n, s'\right) + \gamma V_i^*\left(s', \pi_1^*, \cdots, \pi_i^*, \cdots, \pi_n^*\right)\right) \tag{2.22}$$

其中，$\pi_i^*\left(s, a_i\right)$表示智能体 i 使用纳什均衡策略时选择动作a_i的概率；$\mathcal{R}_i\left(s, a_1, \cdots, a_n, s'\right)$表示智能体在状态$s$转移到状态$s'$时得到的奖励；$\mathcal{T}\left(s, a_1, \cdots, a_n, s'\right)$表示智能体采用联合动作$(a_1, \cdots, a_n)$后从状态$s$转移到状态$s'$的概率。

根据式（2.21）和式（2.22），式（2.20）中纳什均衡可以表示为：

中国知网 https://www.cnki.net

$$\sum_{a_1,\cdots,a_n\in A_1\times\cdots\times A_n} Q_i^*\left(s,a_1,\cdots,a_n\right)\pi_1^*\left(s,a_1\right)\cdots\pi_i^*\left(s,a_i\right)\cdots\pi_n^*\left(s,a_n\right)\geq \sum_{a_1,\cdots,a_n\in A_1\times\cdots\times A_n} Q_i^*\left(s,a_1,\cdots,a_n\right)\pi_1^*\left(s,a_1\right)\cdots\pi_i\left(s,a_i\right)\cdots\pi_n^*\left(s,a_n\right) \tag{2.23}$$

在马尔科夫博弈中，对于智能体 i，需要找到使得奖励最大化的策略 $\pi_i:\mathcal{S}\rightarrow\mathcal{A}_i$。在博弈过程中，如果除了智能体 i 外所有的智能体在状态 s 的 $Q^*{}_i\left(s,a_1,\cdots,a_n\right)$ 都是已知的，则可以得到其在状态 s 下的纳什均衡策略。

2.4.3 纳什均衡策略

纳什均衡[60]又称策略博弈纳什均衡，博弈模型主要由智能体、策略和奖励函数构成。多智能强化学习中，智能体的决策受到联合状态的影响，因此，解决多个智能体之间协调问题就是寻找纳什均衡的过程。策略博弈纳什均衡是指所有智能体策略满足如下不等式：

$$V_i\left(\pi_1^*,\cdots,\pi_i^*,\cdots,\pi_n^*\right)\geq V_i\left(\pi_1^*,\cdots,\pi_i,\cdots,\pi_n^*\right),\forall\pi_i\in\prod_i\ ,i=1,\cdots,n \tag{2.24}$$

为了评估每个智能体对环境的影响效果，定义了一个分布式状态动作值$Q^i(s,a)$来衡量智能体 i 的累计回报。

$$Q_i^\pi\left(s,a_1,\cdots,a_n\right)=\mathcal{R}_i\left(s,a_1,\cdots,a_n\right)+\gamma\sum_{s'\in\mathcal{S}}\mathcal{T}\left(s,a_1,\cdots,a_n,s'\right)\cdot\sum_{a_1'\in\mathcal{A}_1,\cdots,a_n'\in\mathcal{A}_n}\prod_{i=1}^{n}\pi_i(s',a_i')Q_i^\pi\left(s',a_1',\cdots,a_n'\right) \tag{2.25}$$

每个的智能体都有状态-动作值函数，但相应的奖励函数依赖于联合动作和状态转移概率。对于同一组静止策略，我们还可以定义每个智能体 i 的最佳动作对应的 Q 值。假设除了π_i之外的所有的策略都是固定的，$Q_{\Delta i}^\pi(s,a)$是保持除π_i以外的其他智能体的策略不变，然后让智能体 i 选择动作使奖励最大化的 Q 函数。所以在这种条件下，智能体 i 有一个最优的策略以得到在环境中的最大 Q 值。

$$Q_{\Delta i}^*\left(s,a_1,\cdots,a_n\right)=\mathcal{R}_i\left(s,a_1,\cdots,a_n\right)+\gamma\sum_{s'\in\mathcal{S}}\mathcal{T}\left(s,a_1,\cdots,a_n,s'\right)\cdot\max_{a_i'\in\mathcal{A}_i}\sum_{a_1',\cdots,a_{i-1}'}\sum_{a_{i-1}',\cdots,a_n'}\times\pi_1\left(s',a_1'\right)\cdots\pi_{i-1}\left(s',a_{i-1}'\right)\cdot\pi_{i+1}\left(s',a_{i+1}'\right)\cdots\pi_n\left(s',a_n'\right)Q_{\Delta i}^\pi\left(s',a'\right) \tag{2.26}$$

在多智能体系统中，除了智能体 i，其他智能体的策略已经确定的情况下，智能体 i 可以选择一个在状态 s 有最大 Q 值的策略π_i^*，满足公式：

$$E\left(Q_i^\pi\mid\pi_1,\cdots,\pi_i^*,\cdots,\pi_n;s\right)\geq E\left(Q_i^\pi\mid\pi_1,\cdots,\pi_i^*,\cdots,\pi_n;s\right) \tag{2.27}$$

一般的情况下，如果每个智能体都采取最佳对策，则达到纳什均衡，$\left(\pi_1,\cdots,\pi_n\right)$策略集合

中国知网 https://www.cnki.net

被称为纳什均衡策略。在纳什均衡条件下，只要所有智能体都采取纳什均衡策略，就没有哪个智能体能获得更多的利益，收敛于纳什均衡是多智能体强化学习的共同目标。

2.5 本章小结

本章首先介绍了交通信号控制中的基本概念，包括控制问题中控制参数、评价指标以及控制类型。然后对强化学习和 Q 学习原理进行介绍，重点描述了马尔科夫决策过程。结合深度学习，对两种深度强化学习算法进行论述。最后介绍了多智能体强化学习的马尔科夫博弈以及纳什均衡策略。本章叙述内容为后续章节提供一定的理论基础。

中国知网 https://www.cnki.net

第三章 基于深度强化学习的路口信号控制方法

在交通信号控制中，单路口的交通信号控制是城市交通信号控制系统中的基本控制单元，也是区域交通信号协调控制的基础。所以对单路口交通信号控制方法进行研究，对于改善城市道路交通拥堵状况、提高道路通行能力具有十分重要的现实意义，也为区域交通信号协调控制研究提供理论基础。

3.1 引言

将深度强化学习算法应用于路口交通信号控制问题中，如何定义智能体的状态、动作和奖励是研究的重点。对于状态空间定义，现有的基于强化交通信号控制算法中使用复杂状态空间，如最近的研究提出使用图像[61]来表示状态，状态空间维度太大导致算法需要大量的训练样本和更长的训练时间。对于奖励的定义，现有的研究[62]将奖励定义交通评价指标加权线性组合，如排队长度、行驶时间、交通信号相位等，不同的加权组合会导致算法训练结果完全不同，如何调整这些指标的权重也是研究中的难点问题。

最大压力控制是自适应交通信号控制的典型方法[62-65]，该方法的目的是使交叉口的压力最小化，压力可以定义为驶入车道和驶出车道上车辆的数量差值，通过仿真实验证明该方法可以最大化整个路网的吞吐量，但是该方法是基于贪婪策略的，可能出现局部最优的状况。Hua 等人[66]首次将最大压力控制和深度强化学习算法结合，将奖励定义为交叉口的压力，通过实验验证了该方法对路网中交通流的协调控制，优于传统的深度强化学习算法。

本章以单路口交通信号控制为研究对象，对强化学习的三要素进行定义。使用离散化交通状态编码（Discrete Traffic State Code, DTSE）[67]方法将交叉口驶入车道交通状态信息转换为由车辆的位置和速度信息所组成的二维矩阵作为状态空间的定义，用调节路口交通相位压力差值作为算法的奖励，压力的计算不仅考虑了道路上车辆的排队长度，还考虑了道路的容量问题。通过深度双 Q 学习网络模型在线学习交通信号的控制策略，从动作空间中选择一个动作执行，通过对路口信号灯的改变实现对交通流的控制。通过与传统的强化学习方法对比实验，本文提出的算法具有更快的收敛速率和更好的控制效果。

3.2 基于深度强化学习的交通信号控制问题描述

基于强化学习的路口交通信号控制模型在训练过程中，智能体通过对环境采样，获取车

中国知网 https://www.cnki.net

辆位置、速度、排队长度等状态信息s_t和奖励r_t，其中 t 是当前时间步长，神经网络根据状态s_t选择下一个动作a_t，环境根据选择的动作改变红绿灯的相位。基于深度强化学习交通信号控制问题可以描述为对于给定交叉口的状态，Agent 从一组预定义的动作集合中选择动作，使交叉口的累计奖励最大化，交叉口的交通效率最优。

3.2.1 环境描述

在本章中，环境是一个典型的受交通信号灯控制的城市道路交叉口。没有单独考虑行人运动的影响，因为在现实交通中，行人运动往往与伴随的通过车辆的运动同时进行。如图 3.1 所示的四向三车道十字路口，车道起点到交叉口的停车线的距离为 750 米。车辆可以从东、西、南、北四个方向驶入环境中，每个方向分由三条车道（左转车道、右转车道、直行车道）构成 12 条驶入车道和 12 条驶出车道。

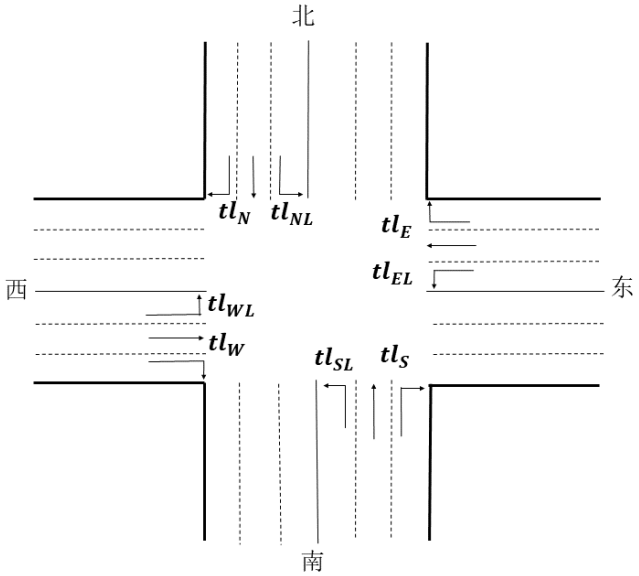

图 3.1 四向单交叉口模型示意图

在实际交通环境中，交叉口通过 8 种不同的交通信号灯对各个方向上交通流进行控制，其中直行和右转的交通流是由同一个信号灯控制。信号灯的集合如公式所示：

$$TL = \{tl_N, tl_{NL}, tl_W, tl_{WL}, tl_S, tl_{SL}, tl_E, tl_{EL}\} \tag{3.1}$$

仿真交通环境中信号灯的状态与现实交通环境相同，具有 3 种可能变化状态，如公式所示：

$$tl = \{\text{绿灯，黄灯，红灯}\} \tag{3.2}$$

3.2.2 状态空间定义

智能体根据输入的环境状态从动作空间中选择一个动作执行，选择的动作决定了智能体

中国知网 https://www.cnki.net

对交通信号控制的效果，复杂的状态描述会增加神经网络训练的复杂度。在训练过程中，交通路网中交通流的变化是不确定的，对于不同输入状态，智能体能够根据以往的经验选择一个最优的动作执行。

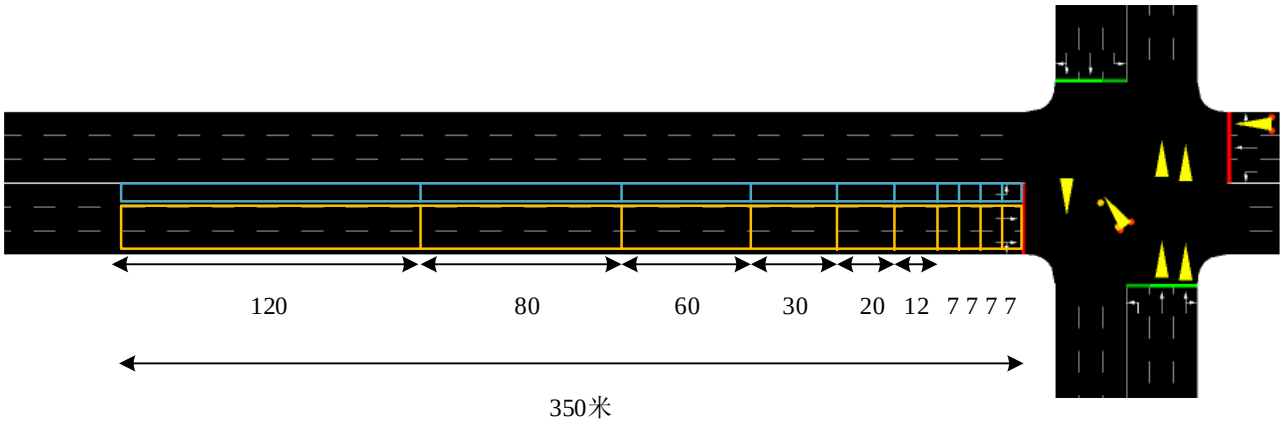

图 3.2 交叉口驶入车道离散化建模

本章采用了 DTSE 方法对交叉口的 4 条驶入车道离散化建模，将每条驶入车道划分为多个长度不一的单元格，将每个单元格内车辆状态信息转换为车辆位置信息矩阵和车辆速度信息矩阵。如图 3.2 所示，将距离十字路口停车线 350 米范围的驶入车道划分成 10 个长度不同的单元格，直行车道和右转车道共用一个单元格，因为它们是由一组红绿灯共同控制的，而左转车道则有一组单独的单元格，每个方向道路是由 20 个单元格组成，整个交叉路口由 80 个单元格组成。每个单元格的长度都不是相同的，离停车线越远，单元格越长，包含的车道长度就越长。这样划分的理由是，如果单元格设置太长，一些接近交叉线的车辆可能不会被检测到；如果单元格设置太短，则整个道路需要被划分为更多的单元格，导致状态空间增加，从而带来更高的计算复杂度。

对于交叉口四条驶入车道，车道 j 上某个单元格 i 内的车辆信息，转换为车辆的位置信息 $P_{i,j}$ 和速度信息 $V_{i,j}$。对于交叉口位置信息，使用布尔值来表示：

$$P_{i,j} = \begin{cases} 0, & \text{第}i\text{个单元格内没车辆} \\ 1, & \text{第}i\text{个单元格内有车辆} \end{cases} \tag{3.3}$$

则整个交叉口的位置信息可以用维度为 8*10 矩阵 P 表示：

$$P = \begin{bmatrix} P_{1,1} & \cdots & P_{1,10} \\ \vdots & \ddots & \vdots \\ P_{8,1} & \cdots & P_{8,10} \end{bmatrix} \tag{3.4}$$

对单元格的速度信息进行归一化处理，归一化速度表示为：

$$V_{i,j} = \frac{v_{avg}}{v_{max}} \tag{3.5}$$

其中，v_{avg} 表示单元格中车辆的平均速度，v_{max} 表示道路限制的最大速度。则交叉口的

中国知网 https://www.cnki.net

速度信息可以用维度为 8*10 矩阵 V 表示：

$$V = \begin{bmatrix} V_{1,1} & \cdots & V_{1,10} \\ \vdots & \ddots & \vdots \\ V_{8,1} & \cdots & V_{8,10} \end{bmatrix} \tag{3.6}$$

综上所述，则交叉口状态空间矩阵由位置矩阵和速度矩阵组成，状态矩阵表示为：

$$state = \{P, V\} \tag{3.7}$$

3.2.3 动作空间定义

在基于强化学习的交通信号控制方法中，对于交通信号的控制主要有两种方法。一种是固定相位顺序的控制方法，按照预先定好的相位顺序，根据交叉口各个车道上交通流分配每个相位的绿灯持续时间；另一种方法不固定相位的切换顺序控制方法，智能体根据最优控制策略，在动作空间中选择一个动作执行。在实际交通控制中，交通灯的变化周期是按照顺序切换，防止无规律的交通相位切换导致交通混乱，本文中也按照固定相位顺序的方法对交叉口的交通流进行控制。

本文采用如图 3.3 所示的四相位控制方案，相位按照东西直行（*EWA*）、东西左转（*EWLA*）、南北直行（*NSA*）、南北左转（*NSLA*）的顺序变换，相位集合定义为：

$$phase = \{EWA, EWLA, NSA, NSLA,\} \tag{3.8}$$

下面详细描述式（3.8）的每个动作：

EWA：东西方向的直行交通信号灯变为绿灯，允许东西方向车道上的车辆直行或者右转；

EWLA：东西方向的左转交通信号灯变为绿灯，允许东西方向车道上的车辆左转；

NSA：南北方向的直行交通信号灯变为绿灯，允许南北方向车道上的车辆直行或者右转；

NLSA：南北方向的左转交通信号灯变为绿灯，允许南北方向车道上的车辆左转。

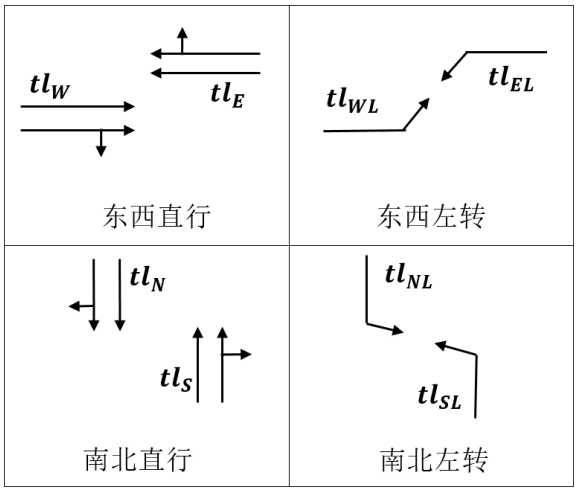

图 3.3 交叉口的四个信号相位

在每个时间步 t，智能体根据输入状态矩阵判断当前的信号相位是否需要切换，输出动作

中国知网 https://www.cnki.net

从动作$a_t \in A$，若$a_t = 1$，将信号灯切换到相位集合中的下一个相位；若$a_t = 0$，则保持当前信号相位不变。每个相位单位持续时间为$\Delta t = 10\text{s}$，当两个信号相位发生切换时，中间会有 3s 的黄灯时间。动作集合表示为：

$$A = \{1,0\} \tag{3.9}$$

如图 3.4 所示，当前时刻的信号相位为南北方向的绿灯，如果在时间步 t 中选择的动作与上一个时间步 $t-1$ 中所采取的动作相同，即$a_t = 0$，持续当前的南北方向绿灯相位，持续时间为Δt，没有黄灯阶段；相反，如果在时间步 $t+1$ 中选择的动作$a_{t+1} = 1$，将信号相位切换到下一个南北方向左转信号相位，两个动作之间将启动 3 秒的黄灯。

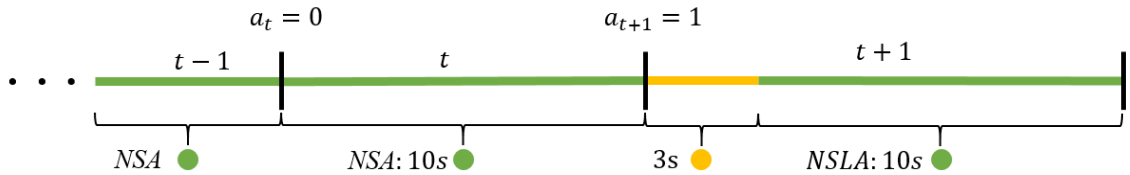

图 3.4 选择不同动作时信号灯变化情况

3.2.4 奖励函数定义

强化学习智能体通过奖励值来判断所采取策略的优劣，并持续对模型进行优化。奖励可以分为正面奖励和负面奖励，智能体选择正确的动作产生正面奖励，反之产生负面奖励。在交通控制环境中，学习目标是使通过交叉口的交通流量最大化，或者使得每辆车平均行驶时间最小，为了实现这一目标，奖励应该来自体现交通效率的一些性能指标，所以智能体能够知道采取的动作是降低还是提高了交叉口的交通效率[68]。在对交通控制方法分析中，一般使用几个交通控制评价指标加权和作为奖励，如吞吐量、平均延误和行驶时间等[69]。

本文提出了一种基于车道归一化压力的计算方法，将交叉口所有交通相位间压力差作为算法奖励。车道压力表示的是道路上交通流的密度，压力差值表示的是交叉口上下游车道上车辆密度之间的不平衡程度，差值越大，车辆分布越不平衡。在现实交通环境中，由于区域内的道路具有不同的长度，相同的排队长度可能意味着不同的交通状况，如果只考虑道路的通行能力，一些较长的路段将需要大量排队车辆才能获得绿灯[70]。因此，压力的计算也要考虑道路容量限制问题，本文提出的归一化压力的计算方法，在较低的交通负荷下，车道压力的增长是线性的，随着排队长度的增加，压力的大小呈指数增长，压力值越大表示当前相位获得绿灯的时间越长，能更好地缓解当前的交通压力。归一化压力公式的基本形式可以写成：

$$\rho_a = k \times Q_a + \omega \times (Q_a)^m \tag{3.10}$$

中国知网　https://www.cnki.net

其中，ρ_a为车道上的归一化压力，Q_a为车道 a 上车辆的排队长度。在式（3.10）中，当排队长度较小时，压力的增长是由$k \times Q_a$决定的，确保在Q_a值较小时曲线是线性的。随着排队长度的增加，压力的增长是由$\omega \times (Q_a)^m$决定的，确保在Q_a值较大时曲线呈指数增长。

归一化压力值在[0，1]区间内，压力值为 0 表示没有车辆排队。当排队长度达到道路最大容量时，压力值等于 1，这意味着道路不能从上游道路接收车辆。假设C_a为道路 a 上能承受的最大容量，当$Q_a = C_a$时，道路的压力达到最大值$\rho_a = 1$。

$$\rho_a = \begin{cases} 0, & if \ \ Q_a = 0 \\ 1, & if \ \ Q_a = C_a \end{cases} \tag{3.11}$$

将式（3.11）代入式（3.10）得到参数ω为：

$$\omega = \frac{1 - k \times C_a}{(C_a)^m} \tag{3.12}$$

将式（3.12）代入公式（3.10）得到归一化压力公式为：

$$\rho_a = (k \times Q_a) + (1 - k \times C_a) \times \left(\frac{Q_a}{C_a}\right)^m \tag{3.13}$$

假设某条车道的最大容量为$C_a = 200$，取$K = 0.001, m = 4$时的车道归一化压力函数如图 3.5 所示，在排队长度$Q_a < 40$时，压力值是线性的增长过程，当$Q_a > 40$后，压力值大小呈指数增长。说明当道路排队长度越接近道路的最大容量，压力的增长速率越快，压力值越大，获得通行的时间越长，能更好地缓解当前的交通压力。

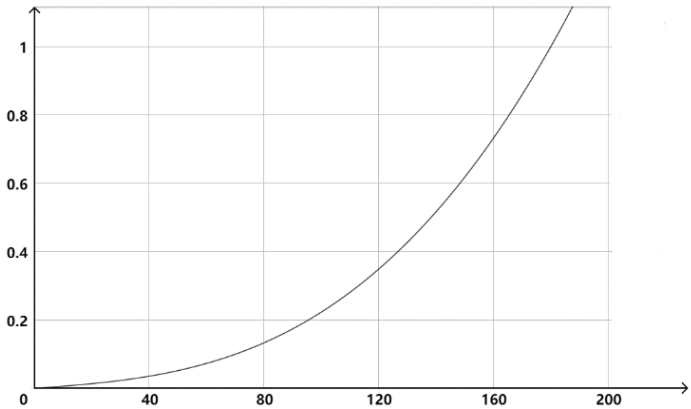

图 3.5 归一化压力函数图

交通相位压力差定义为驶入车道压力和驶出车道压力的差值。我们将车辆从车道 a 驶入车道 b 的交通相位$(a，b)$压力差表示为：

$$\rho_{(a,b)} = \rho_a - \rho_b \tag{3.14}$$

ρ_a和ρ_b分别为驶入车道 a 与驶出车道 b 上归一化压力；其中$(a, b) \in phase$表示(a, b)是相位集合$phase = \{NSG, EWG, NSLG, EWLG\}$中的一组相位运动。交叉口 i 的压力为四种相位压力差之和，表示为：

中国知网　https://www.cnki.net

$$P_i = \left| \sum_{(a,b)\in phase} \rho_{(a,b)} \right| \tag{3.15}$$

选择交叉口的压力作为强化学习算法的奖励，奖励函数如下式所示，奖励值越大，表示交叉口的压力之和越小。奖励函数表示为：

$$r_i = -P_i \tag{3.16}$$

3.3 基于 DDQN 的路口交通信号控制

3.3.1 深度双 Q 网络

在深度 Q 学习算法中，为了将环境的状态映射到与动作相关的 Q 值，建立了深度神经网络模型作为算法中动作价值函数的逼近器，动作的选择和动作的评估是耦合的，使用同一个网络来选择动作以及对状态-动作值进行估计。也就是说，目标网络根据状态s_t选择每个可能的动作a_t计算$Q(s,a)$，通过贪婪策略选择最大 Q 值对应的动作，这个过程会导致 Q 值的过估计问题，因此最终学习到的策略不是最优策略。

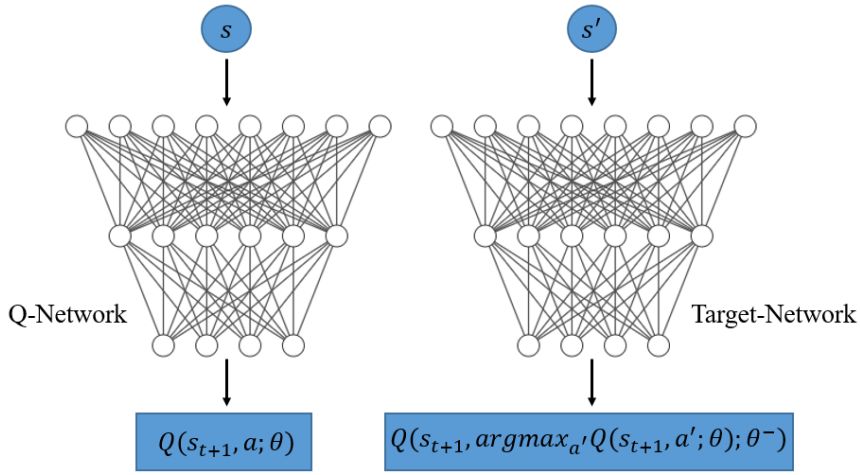

图 3.6 Target-Network 和 Q-Network

为了提升深度强化学习算法在单交叉口交通信号控制中的效率，采用 DDQN 作为控制算法的网络模型，如图 3.6 所示，将 Q 网络和目标网络分开，建立两个神经网络 Q-Network 和 Target-Network。Q-Network 根据环境输入的状态选择一个最大 Q 值对应动作，Target-Network 对选择的动作进行评估，通过误差函数梯度下降法更新 Q 网络参数，每隔 C 步更新目标网络参数。损失函数计算过程如下：

（1）首先 Q-Network 使用下一个状态s'来估计每个可能的动作 a 的 Q 值$Q(s_{t+1}, a)$；

（2）通过 $argmax$ 函数从所有可能的 Q 值中选择最大值对应的动作 $a' =$

中国知网 https://www.cnki.net

$\underset{a'}{argmax}\, Q(s_{t+1}, a'; \theta)$；

（3）Target-Network 根据选择的动作a'估计其在状态s_{t+1}下的目标 Q 值，通过损失函数对网络进行更新。

$$L(\theta) = E\left[\left(r_t + \gamma Q\left(s_{t+1}, \arg\max_{a'} Q(s_{t+1}, a'; \theta); \theta^-\right) - Q(s_t, a; \theta)\right)^2\right] \tag{3.17}$$

其中，$\underset{a}{\mathrm{argmax}}\, Q(s_{t+1}, a; \theta_t)$表示在Q网络在状态$s_{t+1}$下输出的最高动作值所对应的动作；$Q\left(s_{t+1}, \underset{a'}{argmax}\, Q(s_{t+1}, a'; \theta); \theta^-\right)$表示目标网络在状态$s_{t+1}$下对选择的动作的评估；$\gamma$表示折扣系数。

Q-Network 和 Target-Network 采用相同的网络结构，如图 3.7 所示，由输入层、卷积层、池化层、全连接层和输出层组成。输入层为路口车辆离散状态编码得到的车辆位置矩阵和速度矩阵，通过两层卷积层对信息进行提取，通过池化层来减少维度，然后进入全连接层，通过激活函数产生输出，最后得到状态-动作的价值分布。

智能体结构包含 2 层卷积层，2 层池化层和 2 层全连接层，卷积层的核尺寸分别为 3×3，步长为 1，池化层采用尺寸为 2×2 的最大池化方法。隐藏层激活函数采用非线性整流型（Rectified Linear Units, Relu）函数。输出层为线性全连接层，对应着动作的状态动作值。

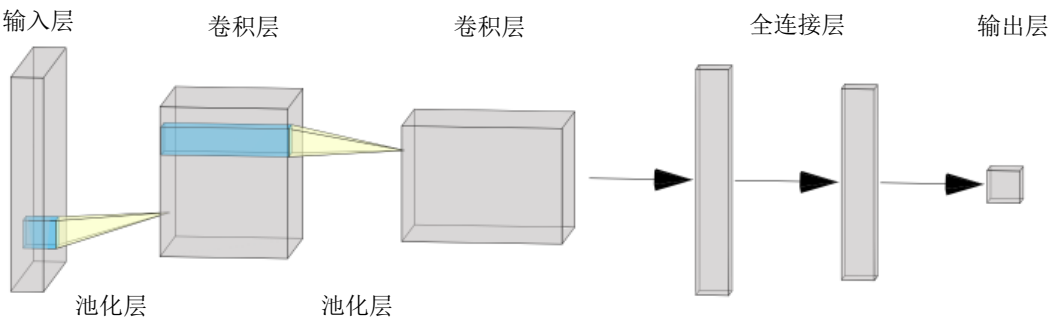

图 3.7 神经网络结构图

3.3.2 优先级经验回放策略

在传统的强化学习中，智能体在每次更新完神经网络后将输入数据丢弃，深度神经网络需要大量数据来对网络参数进行训练，传统的算法会导致学习效率低下。因此，在 DQN 中引入了经验回放机制提高算法的性能和学习效率。深度强化学习算法迭代过程中智能体将与环境交互得到的数据存储在经验回放池中，经验转移序列被定义为：

$$e_i = \{s_t, a_t, r_{t+1}, s_{t+1}\} \tag{3.18}$$

中国知网 https://www.cnki.net

经验回放的优点是通过将经验储存在一起打破了数据在时间上的相关性，可以有效减少学习所需的经验样本数量。算法以均匀采样的方式选取经验回放池的经验数据，会导致所有的数据都会以相同的概率被抽到，忽略了各数据的重要程度，如果某些数据重要程度很高但是出现的次数很少，采用均匀采样的方法可能会导致这些重要的经验数据被采样的概率很低，这种“马修效应”使得经验回放机制的效率较低。

因此本文采用一种基于优先级经验回放的深度强化学习算法[71]（Prioritized Experience Replay, PER），使用优先级采样代替均匀采样，转移序列e_i抽样概率为：

$$P(i) = \frac{p_i^\alpha}{\sum_k p_k^\alpha} \tag{3.19}$$

其中，p_i是对应的优先级，可以通过公式（3.20）定义转移序列的优先级；指数$\alpha \geq 0$衡量贪婪程度，$\alpha = 0$表示均匀采样的情况。

$$p_i = \frac{1}{Rank(i)} \tag{3.20}$$

其中$Rank(i)$是转移序列e_i基于 TD-error 误差在经验回放池中的排序。这种方法对于第一次出现的一个误差值很小的数据，在以后的训练中很难再被利用，而对于误差值很大的数据会频繁利用，从而导致过拟合的问题。

为了纠正这种偏差，我们引入重要性采样权重，通过改变权重调整经验的重要程度，采样权重表示为：

$$w_i = \left(\frac{1}{N} \cdot \frac{1}{P(i)}\right)^\beta \tag{3.21}$$

其中，N 是经验回放池中转移序列的数量，β是补偿系数。对于优先级高的数据对应的权重基本没有改变，而低优先级样本对应的权重在每次训练完都会更新。

智能体的训练阶段是在给定的环境状态下找到最大价值的动作的过程。在训练开始阶段，模型没有经过大量的样本进行训练，无法确定哪些动作是最有价值的，智能体对动作的选择是随机的，这是策略探索阶段；随着神经网络慢慢收敛，智能体可以选择具有最大 Q 值的动作减少探索率，这是策略利用阶段。智能体在训练中，如过多使用利用策略选择最优动作，可能会导致算法策略陷入局部最优的情况。

为了解决这一问题，在智能体能通过神经网络得到最优动作时，增加探索策略的概率，以便找到最有价值的动作，提高算法训练的效率。本文采用ϵ-greedy 策略确定智能体在每个批次选择探索或利用概率，对于某个批次 e，智能体以ϵ的概率从动作空间随机选择一个动作执行，否则以 1-ϵ的概率通过神经网络选择一个具有最大 Q 值的动作执行。ϵ的计算公式如下：

中国知网　https://www.cnki.net

$$\epsilon = 1 - \frac{e}{E} \tag{3.22}$$

其中，e 是当前训练的批次，E 是训练的总批次。

3.3.3 控制系统结构

基于 DDQN 的路口交通信号控制系统结构如图 3.8 所示，由环境、经验回放池、训练池、DDQN 误差函数、Q 网络和目标网络组成。接下来详细描述系统的执行过程。

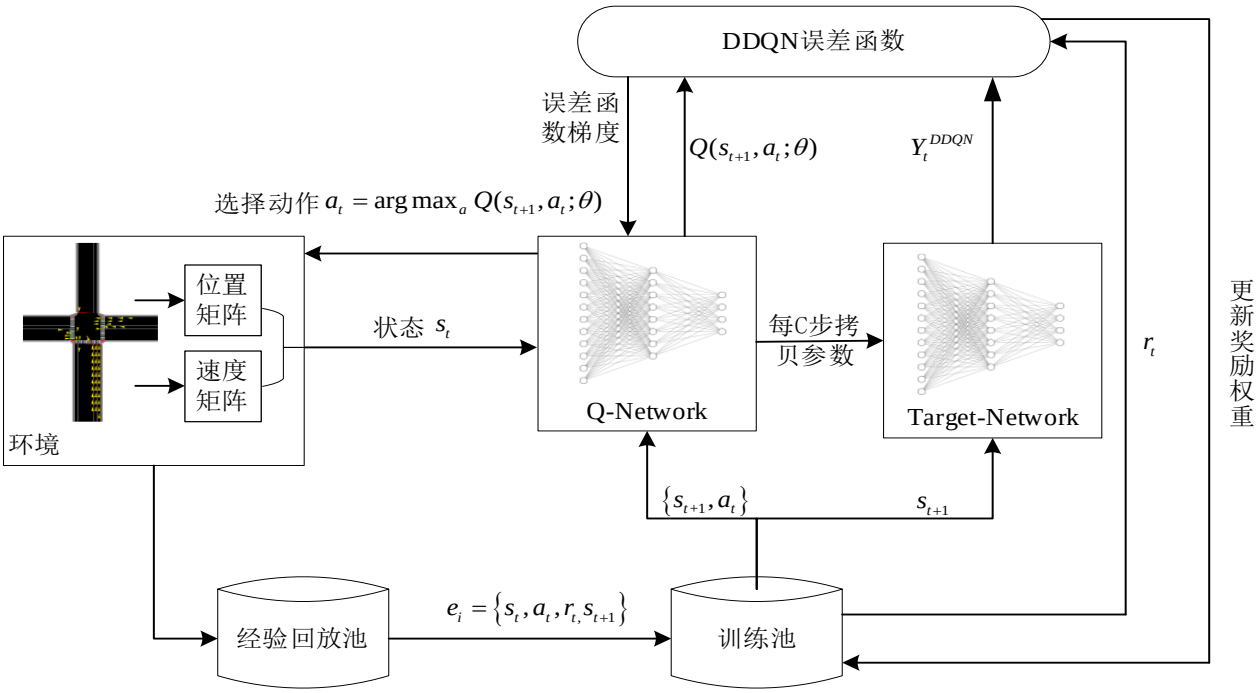

图 3.8 DDQN 框架图

（1）初始化

对 Q 网络和目标网络进行初始化，初始化网络结构和参数。对经验回放池和训练池的容量进行初始化，经验回放池最大容量 M 和训练池容量 B。

（2）控制决策

智能体与环境进行交互，通过获取环境最新的状态，从动作空间中选择一个具有最大 Q 值的动作。具体过程为，Q 网络接收到环境当前状态s_t，智能体采用$\epsilon - \text{greedy}$策略平衡探索和利用，在训练初期，由于缺乏经验样本，智能体会在动作空间随机选择动作执行，随着训练的进行，智能体会减少探索的概率，通过神经网络选择具有最优动作执行。

（3）经验缓冲池

当智能体选择动作后，环境会执行对应的动作，将当前环境反馈的奖励r_t和下一个状态s_{t+1}以及当前状态s_t和执行的动作a_t组成经验转移序列(s_t, a_t, r_t, s_{t+1})存储在经验回放池中。

（4）Q 网络训练

中国知网 https://www.cnki.net

按照优先级经验回放策略从经验回放池中抽取 B 组经验数据，通过式（3.17）计算损失函数$L(\theta)$，根据损失函数通过梯度下降法更新 Q 网络参数θ，并更新转移序列的优先级。

（5）目标网络更新

每当 Q 网络经过 C 次迭代训练后，同步更新目标网络的参数，即$\theta^{-}=\theta$。

3.3.4 基于 DDQN 控制学习算法

本章通过对强化学习状态、动作和奖励函数的设计，将深度双 Q 网络与优先级经验回放策略相结合实现对路口交通信号控制。基于 DDQN 的路口交通信号控制学习算法 3.1 所示。

算法 3.1：基于 DDQN 的路口交通信号控制学习算法

初始化神经网络 Q-Network，Target-Network，网络参数θ, θ^{-}

初始化经验回放池 M，抽样组数 B，ϵ参数，折扣系数γ，学习率α，训练批次 N，每批次步数 T

for $episode=1,\cdots,N$ **do**

　初始化仿真环境，初始化状态s_t，即当前交叉口的位置、速度矩阵

　初始化路网环境参数、动作空间 A

　初始化训练步数 $k=0$

　for $k=1,\cdots,T$ **do**

　　根据ε-greedy 策略，Q-Network 选择动作$a_t=argmax_a Q(S_{t+1},a;\theta_t)$

　　执行动作，$a_t=0$信号灯保持当前相位，$a_t=1$ 切换至下一相位；得到奖励r_t和新的状态s_{t+1}

　　将经验样本$\langle s_t,a_t,r_t,s_{t+1}\rangle$存储在经验缓冲池 M 中

　　更新环境定义当前交通状态$s_t\leftarrow s_{t+1}$, $i=i+1$

　　if $|M|>B$ **then**

　　从经验回放池 M 中依据优先级经验回放策略获取数量为 B 的经验样本

　　计算重要性采用权重w_i

　　通过随机梯度下降计算损失函数$L(\theta)$

　　根据损失函数通过梯度下降法更新 Q-Network 的网络参数θ

　　每隔 C 步更新 Target-Network 的网络参数θ^{-}，$\theta\leftarrow\theta^{-}$

　　更新转移序列的优先级，参数ϵ的值

　　end if

中国知网　https://www.cnki.net

3.4 仿真实验及结果分析

3.4.1 实验设置

单交叉口仿真区域如图 3.9 所示，每条车道长度为 750m，道路允许最大速度为 60km/h。在模拟环境中，交通流生成是一个至关重要部分，会对深度强化学习模型的性能产生重大影响。为了模拟现实道路中交通流产生的场景，根据 Weibull 分布生成训练中的交通流。所有仿真车辆都是从道路起始位置驶入交通路口，路网中每辆车长度为 5m，车辆间最小距离为 2m。

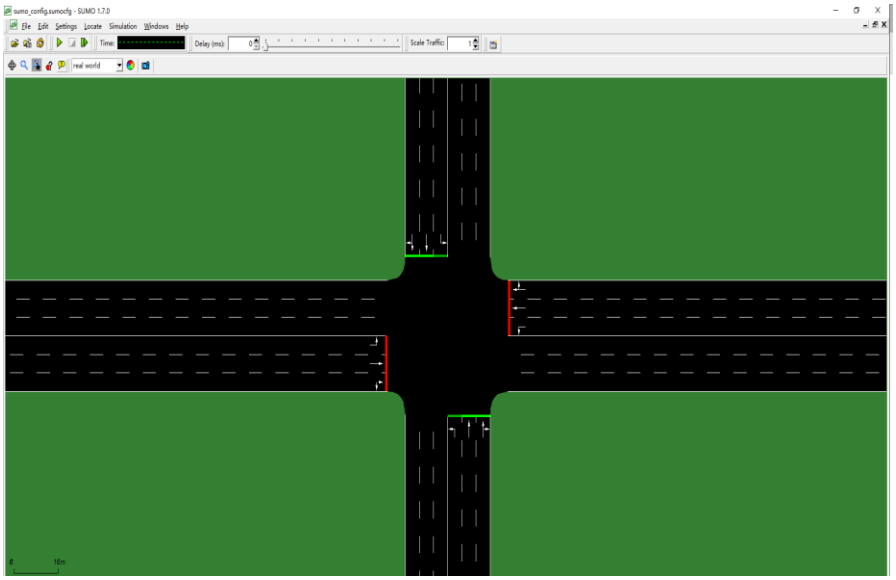

图 3.9 SUMO 模拟单路口仿真环境

现实道路中，城市路网中交通流量在早高峰和晚高峰会出现一个高峰期流量，为了尽可能实现对真实交通情况的仿真，设置了如图 3.10 所示的模拟一小时内高峰期的交通流的生成，其中 x 轴为一个仿真周期的时间步，y 轴为每分钟生成的车辆数量。在仿真初期，交通流生成的速率随着时间慢慢增大，在 15 分钟时达到高峰，然后随着时间慢慢减少。

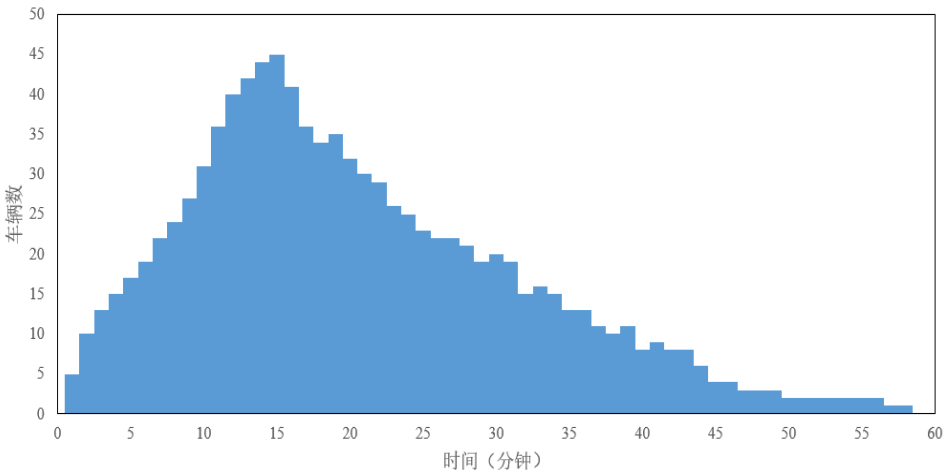

图 3.10 基于 Weibull 分布的车辆生成

中国知网 https://www.cnki.net

为了验证本文提出 DDQN 算法在交通信号控制中的效果，将其与传统的基于 DQN 的交通信号控制方法对比实验，训练期间，两种算法使用相同的网络结构及超参数设定。实验参数设置如表 3.1 所示。

表 3.1 仿真过程中的参数设置

交通参数	值
经验回放池 M	10000
抽样数 B	128
最小探索率	0.01
折扣因子γ	0.99
学习率α	10^{-4}
训练批次 N	1400
每批次步长 T	720

3.4.2 实验结果分析

在相同仿真环境下对两种深度强化学习交通信号控制算法进行训练，在训练阶段，仿真实验训练了 1400 个批次，每个步长的步数为 720 步，训练总步数为10^6，仿真实验智能体每隔 5s 进行一次决策。

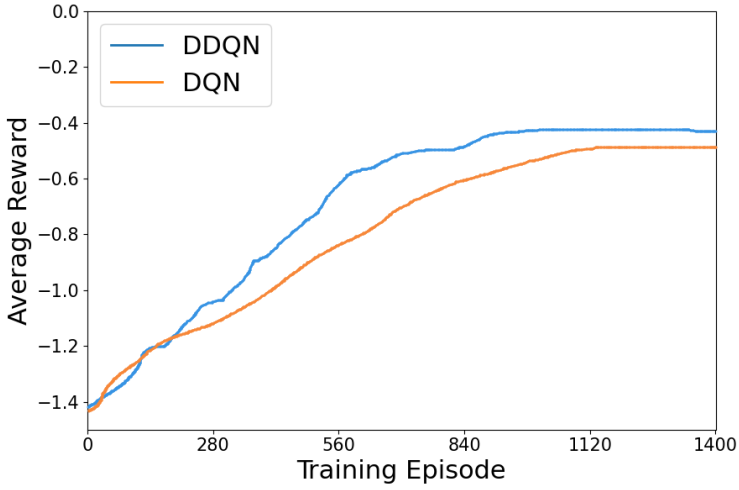

图 3.11 算法的平均累计奖励值趋势图

两种深度强化学习方法的平均累计奖励值如图 3.11 所示，横轴表示训练批次，纵轴表示平均累计奖励值。从图中可以看出训练初始阶段由于缺乏经验样本，智能体在环境中基于探索策略选择动作，算法获得奖励值较小。随着训练的进行，智能体不断与环境交互获得了大量的经验样本，算法奖励值不断升高，最终达到收敛状态。DDQN 在训练到第 900 个批次时

中国知网 https://www.cnki.net

算法趋于收敛状态，而 DQN 在 1200 个批次算法才逐渐收敛，DDQN 具有更高的奖励值以及更快的收敛速度。

仿真实验阶段，分别对两种交通控制方法进行了 10 次仿真实验，加入基于固定时长控制方法作为对比实验，固定周期设置为 120s，每个相位包括 27s 绿灯时间和 3s 的黄灯时间。通过对三种方法的实验结果取平均值得到如表 3.2 所示的对比结果，由表可知，DDQN 算法的表现是最好的，相对于 DQN 算法，平均行驶时间减少了 28.6%，平均行驶速度提升了 26.1%，平均排队长度减少了 42.7%，数据表明本文提出的 DDQN 方法能够缓解交通压力，较好地实现交通信号控制。

表 3.2 不同控制算法下的性能对比

方法	平均排队长度（辆）	平均行驶时间（*s*）	平均行驶速度(*m/s*)
定时控制	12.32	77.46	2.85
DQN	4.82	46.85	5.90
DDQN	2.76	33.40	7.23

将 10 次仿真实验数据取平均值，生成了平均数据变化曲线图，阴影部分是根据实验数据的标准差得到的数据的离散区间。图 3.12 描述了交叉口每秒的平均排队长度趋势图，由图可知，定时控制的交通信号控制方法不能对高峰期的交通流进行有效控制，在仿真实验后期，进入路网的车辆已经慢慢减少，但是交叉口已经处于完全拥堵的状态，无法对交通流进行有效的调度。DQN 和 DDQN 能够有效地实现交通控制，DDQN 在高峰期的对交通流的控制效果更好，能更好地缓解高峰时段的交通拥堵情况。

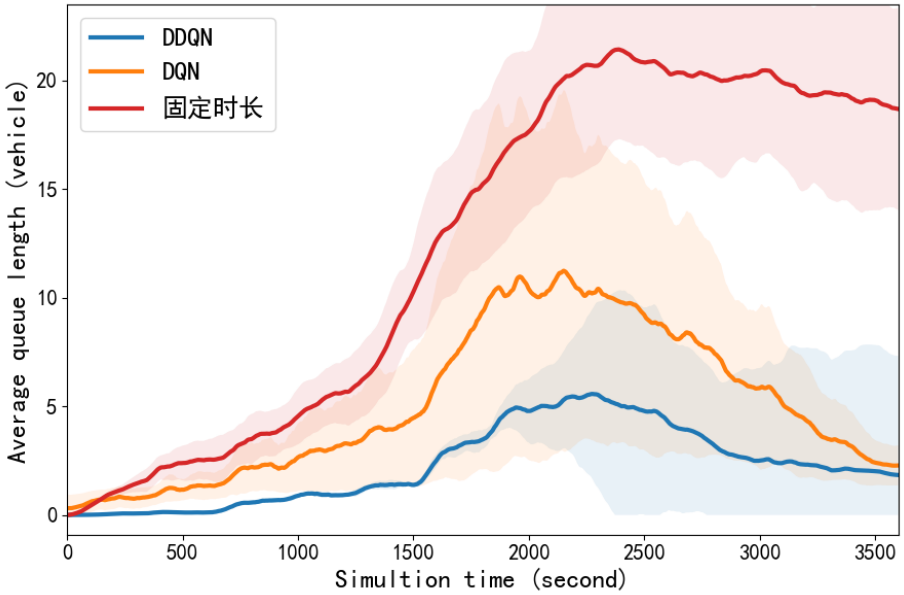

图 3.12 算法平均排队长度趋势图

中国知网 https://www.cnki.net

图 3.13 描述了单交叉口环境中车辆的平均行驶速度趋势图。由图可知，平均行驶速度变化趋势与平均排队长度变化趋势呈现较强的相关性，定时控制的交通信号控制方法在交通流达到高峰期后，道路一直处于拥堵，车辆平均行驶速度趋于 0。DDQN 和 DQN 在交通流达到高峰期后车辆平均行驶速度也慢慢降低，经过高峰期之后，车辆行驶速度也渐渐增大，表明控制算法能够将路口将拥堵的车流疏导，DDQN 算法在训练期间车辆行驶速度比 DQN 要高，具有更好的控制效率。

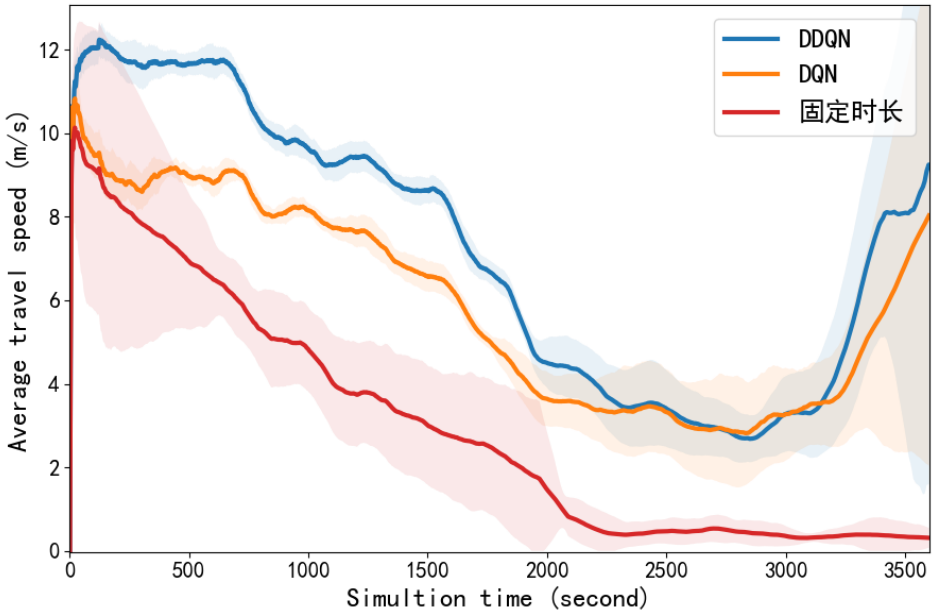

图 3.13 算法平均行驶速度趋势图

3.5 本章小结

本章提出了基于深度双 Q 学习的单交叉口交通信号的控制方法，首先对强化学习的状态、动作进行定义，然后提出了一种归一化压力差计算方法作为奖励，通过优先级经验回放策略对经验回放池样本进行采样，然后对 DDQN 网络模型进行训练。在模拟实际路网包含高峰交通量场景下对算法进行仿真实验，并与固定时长控制方法和基于 DQN 控制方法比实验，实验结果表明该算法在训练过程中具有更快的收敛速度以及更好的控制效果。

中国知网　https://www.cnki.net

第四章 基于深度强化学习的区域交通信号控制方法

4.1 引言

如今城市交通拥堵问题日渐突出，成为制约经济发展的主要原因之一。有效的交通信号控制方法对缓解交通拥堵、减少平均出行时间、提高交通网络吞吐量具有重要作用。而城市交通路网连接密集，相邻路口之间的信号具有高度的相关性，基于深度强化学习的单路口交通信号控制方法无法对区域交通信号进行有效的协调控制。使用多智能体深度强化学习（Multi-Agent Reinforcement Learning, MARL）[72]解决区域交通信号控制是当前研究热点方法之一。多智能体强化学习在区域交通信号控制应用中，一种方式是每个智能体对每个交叉口独立控制决策，不会考虑相邻路口之间的联系和影响；另一种方式是在独立决策同时考虑领域内智能体的决策对自身的影响，通过协作方式实现区域交通的协调控制[73]。

为了提高多智能体深度强化学习的区域交通信号控制协调性，本章首先介绍了马尔可夫博弈过程的基本知识，提出了一种基于协作式 MARL 算法，将多智能体系统建模为马尔可夫博弈过程，每个交叉口都视为一个智能体，智能体之间通过马尔科夫博弈达到纳什均衡。智能体在决策过程中通过邻域内交叉口共享状态信息和奖励信息提高算法协调控制效果。

4.2 多智能体深度强化学习交通信号控制算法

4.2.1 多智能体控制结构

在区域交通路网中，将每个交通路口建模为一个独立的智能体，如果每个智能体只考虑本地环境中的交通状态信息，不关心相邻交叉口的控制策略产生的影响，可能会导致算法难以收敛，甚至导致路网中产生局部拥堵。本文采用一种共享状态和奖励的多智能深度强化学习方法，智能体之间可以交换状态信息，在策略更新的过程中也会考虑邻域的奖励信息。

如图 4.1 所示，，n_1, n_2, n_3, n_4是其相邻的交叉口，对于智能体 i 与相邻的任意一个交叉口 j，$(i,j) \in I_{(i,j)}$。

中国知网 https://www.cnki.net

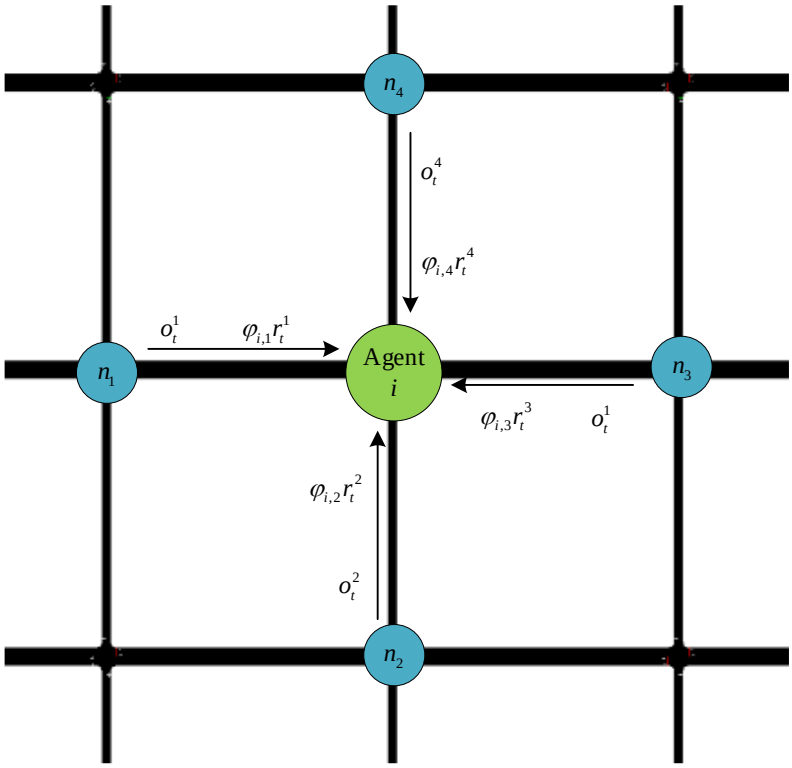

图 4.1 区域路网中的多智能体建模

4.2.2 状态空间定义

在第三章中的基于深度强化学习交通信号控制问题描述中，对智能体的状态、动作和奖励进行了定义，在多交叉口的环境中，交叉口 i 的状态定义空间定义为：

$$o_t^i = \left\{P_l^i, V_l^i\right\}, l \in L \tag{4.2}$$

其中P_l^i表示路网中交叉口 i 的驶入车道 l 中车辆的位置矩阵，V_l^i表示交叉口 i 的驶入车道 l 中车辆的速度矩阵。当前交叉口 i 联合状态空间由当前智能体本地状态空间和邻域智能体的状态空间组成，可以表示为：

$$s_t^i = \langle o_t^i, \{o_t^j\}_{j \in N_i} \rangle \tag{4.3}$$

其中，o_t^i表示在时间 t 时交叉口本地状态信息；o_t^j表示相邻路口状态信息的集合；N_i是如式（4.1）所示的邻居节点集合。

4.2.3 奖励函数定义

在第三章的基于 DDQN 的深度强化学习方法中，采用归一化压力差作为强化学习算法的奖励，在此基础上，使用加权和的方式将智能体奖励与相邻域的奖励结合到一起，引入空间

中国知网　https://www.cnki.net

折扣因子使邻域中智能体的奖励值与两个智能体之间的距离正相关，距离越近，获得的相邻智能体的奖励值就越大。空间折扣因子表示为：

$$\varphi_{i,j} = \varphi_0 \cdot d_i^j \tag{4.4}$$

d_i^k表示节点 i 和节点 j 之间的距离，$j \in N_i$；φ_0是折扣系数。

智能体奖励函数定义为当前时刻本地环境获得奖励与邻域内所有智能体奖励的和，表示为：

$$r_t^i = r_t^{i'} + \sum_{j \in N_i} \varphi_{i,j} \cdot r_t^j \tag{4.5}$$

其中，$r_t^{i'}$是智能体获得本地奖励；$\varphi_{i,j} \cdot r_t^j$是智能体获得的相邻智能体 j 的奖励信息，$\varphi_{i,j}$为空间折扣因子。

4.3 基于协作式多智能体 DDQN 区域交通信号控制

4.3.1 基于协作式多智能体强化学习

多智能体强化学习可以分为基于中心化的训练框架和去中心化的框架。基于中心化的多智能体强化学习使用联合建模的方式学习控制策略，将所有智能体所在环境的联合状态空间输入到神经网络中，得到一个对所有智能体进行控制的联合策略。由于联合状态空间和输出的动作空间很大导致算法的收敛性很差，无法在较多的智能体环境中协调控制。基于去中心化的多智能体强化学习框架中每个智能体能够独立控制，智能体根据观测的局部环境实现决策，但是这种算法会导致环境的不平稳，由于每个智能体是独立决策的，在训练过程中，会导致环境中的状态发生改变，打破了马尔科夫假设。

基于协作式多智能体强化学习方法[74]能解决环境不稳定问题，智能体之间通过共享信息的方式，加强多智能体之间的合作，在每个智能体能通过观测局部环境，通过与相邻智能体之间和合作完成算法的训练。这种方式也能够实现“局部中心化”，更好地克服环境中不平稳的问题，加强智能体之间的协作控制[75]。

4.3.2 控制系统结构

本文在将多智能体系统和深度双 Q 网络结合来优化协调区域交通信号控制问题。在区域路文中，对每个交通路口建模为一个智能体，通过与相邻交叉口之间共享交通状态信息和奖

中国知网　https://www.cnki.net

励信息，结合深度双 Q 网络模型实现对本地交通信号进行控制。协作式深度双 Q 学习系统结构如图 4.2 所示，多智能体系统中智能体 i 执行过程如下。

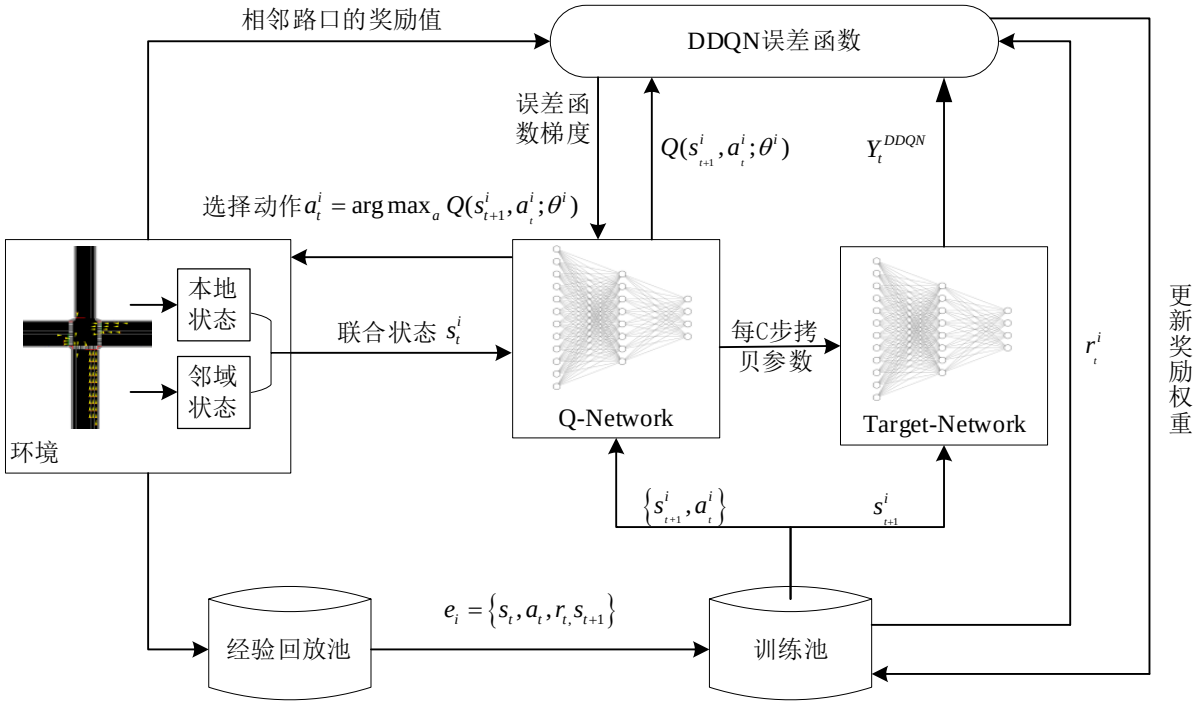

图 4.2 协作式深度双 Q 学习系统结构图

（1）初始化

对 Q 网络和目标网络进行初始化，初始化网络结构和参数。对经验回放池和训练池的容量进行初始化，经验回放池最大容量 M 和训练池容量 B。

（2）控制决策

智能体与环境进行交互，通过获取环境获取本地状态信息o_t^i和邻居路口状态信息$\{o_t^j\}_{j\in N_i}$，组成联合状态空间s_t^i输入神经网络，从动作空间中选择一个最大 Q 值的动作a_t^i，并将动作返回给环境执行，如果$a_t^i = 1$，将信号灯切换到下一个相位，如果$a_t^i = 0$，保持当前相位不变。

（3）经验缓冲池

将当前环境反馈的奖励r_t^i和下一个状态s_{t+1}^i以及当前状态s_t^i和执行的动作a_t^i组成经验转移序列$(s_t^i, a_t^i, r_t^i, s_{t+1}^i)$存储在经验回放池中。

（4）Q 网络训练

按照优先级经验回放策略从经验回放池中抽取 B 组经验数据，通过式（3.17）计算损失函数$L(\theta)$，根据损失函数通过梯度下降法更新 Q 网络参数θ，并更新转移序列的优先级。

（5）目标网络更新

每当 Q 网络经过 C 次迭代训练后，同步更新目标网络的参数，即$\theta^- = \theta$。

中国知网　https://www.cnki.net

4.3.3 协调控制算法

在区域交通环境中，将区域交通路网建模为一个无向图，将每个交叉口作为一个独立的智能体。将基于 DDQN 的单路口交通信号控制算法引入多智能体环境中，重新定强化学习的状态和奖励，智能体根据环境本地观测信息和相邻交叉口的状态分布信息组成的联合状态信息作为神经网络的输入，同时引入空间折扣因子，训练过程中智能体通过接受相邻智能体的价值分布进行决策，通过多智能体马尔可夫博弈达到纳什均衡，实现对区域交通信号协调控制。基于协作式多智能体 DDQN 区域交通信号控制算法如下。

算法 4.1：基于协作式多智能体 DDQN 的区域交通信号控制算法

初始化神经网络 Q-Network，Target-Network，网络参数θ, θ^-

初始化经验回放池 M，抽样组数 B，ϵ参数，折扣系数γ，学习率α，训练批次 N，每批次步数 T

for $episode = 1, \cdots, N$ **do**

初始化路网环境参数、动作空间 A

初始化训练步数 $k = 0$

for $k = 1, \cdots, T$ **do**

从初始化路网环境中得到当前交叉口交通状态矩阵o_t^i和相邻交叉口状态矩阵o_t^j

组成联合状态空间$s_t^i = \langle o_t^i, \{o_t^j\}_{j \in N_i} \rangle$

根据ε-*greedy* 策略，Q-Network 选择动作$a_t^i = argmax_{a^i} Q(S_{t+1}, a^i; \theta_t)$

执行动作，a_t^i =0 信号灯保持当前相位，a_t^i =1 切换至下一相位；得到奖励r_t^i和状态s_{t+1}^i

将经验样本$\mathrm{e} = \langle s_t^i, a_t^i, r_t^i, s_{t+1}^i \rangle$存储在经验缓冲池 M 中

更新当前交通状态$s_t^i \leftarrow s_{t+1}^i$；$k$=$k$+1

if $|M| > B$ **then**

从经验回放池 M 中依据优先级获取数量为 B 的经验

计算重要性采用权重w_i

通过随机梯度下降计算损失函数$L(\theta)$

根据损失函数通过梯度下降法更新 Q-Network 的网络参数θ

每隔 C 步更新 Target-Network 的网络参数θ^-，$\theta \leftarrow \theta^-$

更新转移序列的优先级

更新参数ϵ的值

end if

中国知网 https://www.cnki.net

4.4 仿真实验及结果分析

4.4.1 仿真实验设计

为了测试上述基于 DDQN 的多路口信号控制方法的性能，在 SUMO 交通仿真平台上搭建一个 5×5 的交通路网，路网中每个单交叉口的构造和 3.4 节定义的交叉口是相同的。

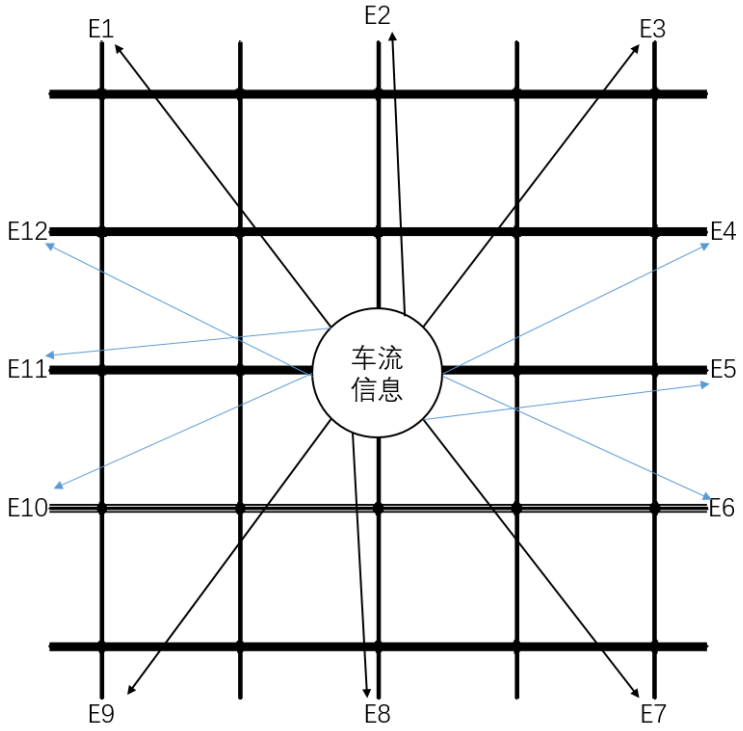

图 4.3 一个由 25 个十字路口组成的交通网格

如图 4.3 所示，对路网设置了 12 个 OD 点，*E*1 至 *E*12，组成了 12 个 OD 对。在仿真实验中，交通流不是均匀地在这些 OD 对中生成的，而是采用四组时变的交通流生成方式，这样的设置能更好地对算法性能进行测试。如表 4.1 所示，将 12 个 OD 对分成 F1-F4 共 4 组，分别以不同的速率生成交通流。

表 4.1 四组交通流分类

交通流	OD 对
F1	E1 至 E7，E2 至 E8，E3 至 E9
F2	E4 至 E10，E5 至 E11，E6 至 E12
F3	E7 至 E1，E8 至 E2，E9 至 E3
F4	E10 至 E4，E11 至 E5，E12 至 E6

在本实验中，智能体的训练周期包含 720 步，智能体每隔 5s 进行一次决策，等于 1 小时仿真时间。定义的四组交通流对应的车辆生成速率如图 4.4 所示，纵轴表示每小时产生的车

中国知网 https://www.cnki.net

辆数，横轴表示时间，在单位训练周期内车流量会存在一个明显的高峰期和低谷期。在一个单位训练周期内产生 2150 辆车，对于同一种方法来说，在不同的单位训练周期中（哪怕是连续的训练周期），其产生车辆的情况都是不同的，车辆的产生具有一定的随机性，同时，这也验证了在不同情况下，算法的有效性。而对于不同的方法来说，同一个训练周期内，所面临的环境是相同的，这是为了保证采用不同算法时的公平性。

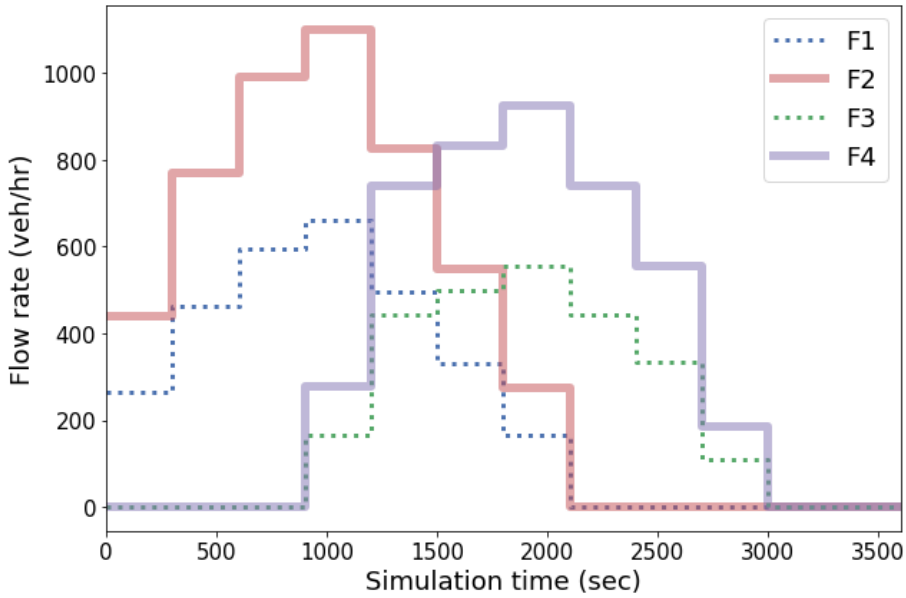

图 4.4 仿真实验中车流量时变图

整个实验路网配置的交通参数如表 4.2 所示。

表 4.2 实验路网配置的交通参数

交通参数	值
交叉口个数	25
路段数	120
每条路段的车道数	3
平均路段长度	400m
车辆最高限速	60km/h
总交通量	2150 辆

4.4.2 实验结果分析

为了验证本章所提出算法的性能，与完全独立多智能体强化学习算法 IQL 和共享状态信息的多智能体强化学习算法 IQL-S 做对比实验。IQL 是 Tampuu 等人[76]于 2015 年提出的一个完全独立多智能体强化学习算法，该算法常作为多智能体强化学习算法的对比基准，每个智

中国知网　https://www.cnki.net

能体仅使用本地观测作为输入，根据 DQN 的学习方式对各智能体独立训练。IQL-S 是 IQL 方法的改进，智能体在决策过程中考虑相邻交叉口的状态信息分布。

在训练阶段，仿真实验训练了 1400 个批次，每个批次的步数为 720 步，训练总步数为 10^6，仿真实验智能体每隔 5s 进行一次决策。两种深度强化学习方法的平均奖励值如图 4.5 所示，横轴表示训练步数，纵轴表示平均累计奖励值。IQL 算法由于没有考虑相邻智能体决策对自己的影响，算法奖励一直处于震荡的状态不能实现收敛，没有学习到有效的控制策略。IQL-S 算法考虑了相邻智能体的状态，算法奖励值一直在慢慢增加，最后趋于收敛，相较于 IQL 算法有了很大的提升，但是算法稳定性不是很高。本章提出的 MADRL-SI 算法在训练开始时，缺少训练样本导致奖励值较小，随着训练的批次的增加，奖励值不断增大，很快就达到了收敛状态。

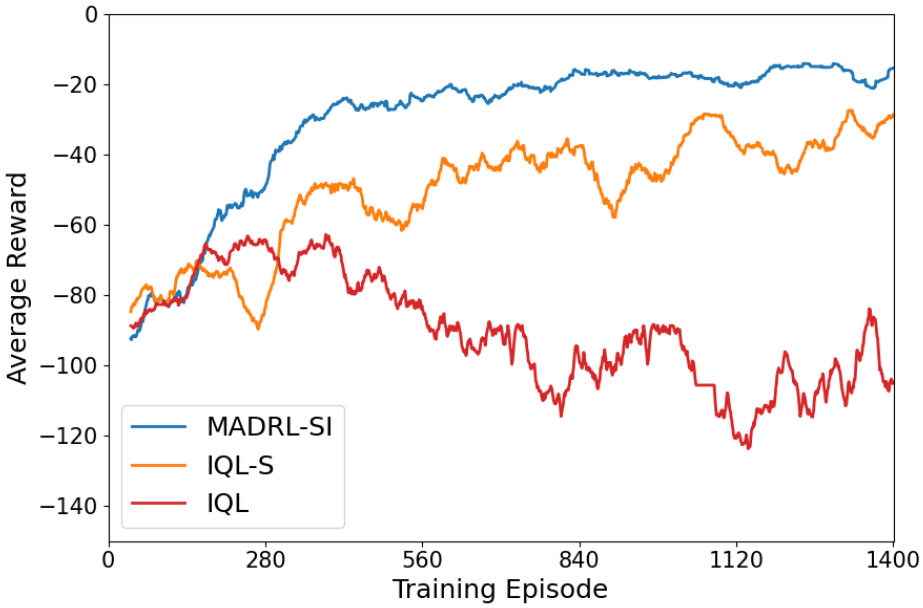

图 4.5 算法的平均累计奖励值曲线图

训练完成后，对三种训练好的模型做了 10 次仿真实验，图 4.6 为三种算法平均排队长度趋势图，图 4.7 为三种算法平均行驶速度趋势图。由图可知，IQL 由于算法在训练中没有收敛，模型无法实现有效的控制策略，导致道路处于完全拥堵的状态，并且随着交通的减少，路口的拥堵程度没有缓解。IQL-S 和 MADRL 训练后模型能实现对区域交通信号的协调控制，随着交通流的生成速率慢慢增加，两种控制算法的平均排队长度也在增加，平均速度在降低。达到高峰流量之后，随着交通流生成速率的降低，交通拥堵程度也在慢慢降低。MADRL 算法在交通流达到高峰期时，具有更短的平均排队长度和更快的平均行驶度，能较好实现对高峰期交通流的协调控制，能有效降低区域路网的拥堵程度，更快地实现对高峰期后的路网拥堵的缓解。

中国知网　https://www.cnki.net

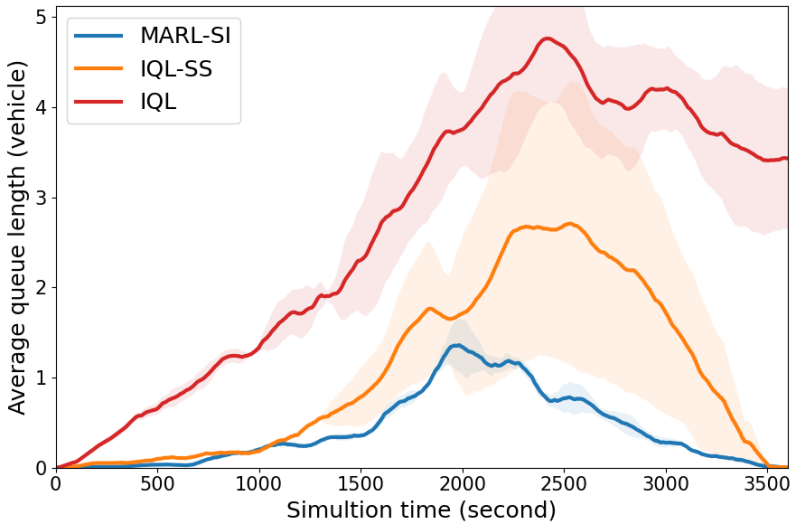

图 4.6 平均排队长度趋势图

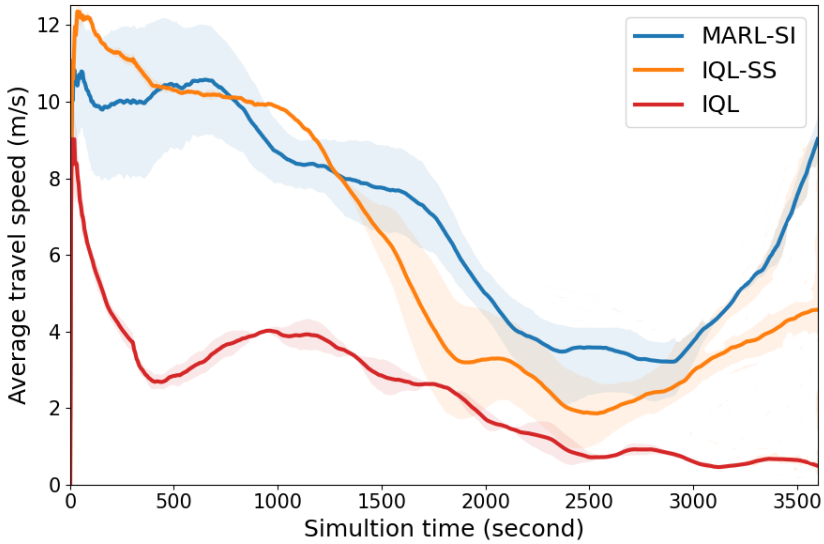

图 4.7 平均行驶速度趋势图

将 MARL-SI 算法的结果与 IQL、IQL-SS 算法进行对比，各个衡量指标中所取的平均值如表 4.3 所示。相较于 IQL-SS 算法，平均队列长度缩短了 45.3%，但车辆的平均行驶时间降低了 21.9%，平均行驶速度增加了 18.8%。结果表明，在较高车流量通行的情况下，MARL-SI 算法与 IQL 和 IQL-SS 算法相比，具有更好的效果。

表 4.3 三种算法的性能对比

算法	平均排队长度（辆）	平均行驶时间（s）	平均行驶速度(m/s)
IQL	1.23	307	2.09
IQL-SS	0.64	178	5.75
MARL-SI	0.35	139	6.83

综上所述，将基于协作式多智能体 DDQN 交通信号控制算法应用于区域交通信号优化协

中国知网 https://www.cnki.net

调控制中，能有效地减少车辆行驶时间，提高道路的通行效率和缓解交通拥堵。

4.5 本章小结

第三章提出的基于 DDQN 的交通信号控制方法在单交叉口环境中有较好的性能表现，但是不能满足在区域交通环境中对交通流协调控制的要求。本章根据多智能体强化学习算法以及纳什均衡理论，提出了分布式 DDQN 算法，将区域路网建模为一个多智能体模型，每个智能体通过共享相邻交叉口的状态和奖励信息对决策进行更新，实现对交通信号的协调控制。然后通过与独立的深度学习 IQL 算法与只共享状态信息的 IQL 算法对比实验，证明本章提出的基于协作式多智能体 DDQN 交通信号控制算法在区域交通信号协调控制中的可靠性和优越性。

中国知网 https://www.cnki.net

第五章 基于 SUMO 的区域交通控制仿真系统构建

近几年，随着城市交通拥堵问题日趋严重，分析交通状况设计出合理的交通控制方案，以缓解拥堵、减少车辆延误和提高道路安全性是许多科研工作者的研究方向。交通建模和仿真在交通基础设施规划和城市交通信号控制中具有不可替代的作用。由于交通信号控制方法难以在现实交通环境中进行实验验证，设计与搭建一个基于微观交通仿真软件的交通控制仿真平台是交通信号控制研究中重要的一步。本章使用 SUMO 交通仿真软件构建区域交通路网并动态模拟交通流并与 Python 编程开发语言实现的交通信号控制算法相结合，利用 SUMO 的 TraCI（Traffic Control Interface）接口，开发出基于 SUMO-Python 的交通控制仿真系统。

5.1 微观交通仿真软件

5.1.1 SUMO 仿真软件简介

SUMO（Simulation for Urban MObility）[77]是于 2001 年开发的一个免费开源的微观交通仿真软件。SUMO 可以对路网中的交通流进行微观控制，能够对每辆车辆的标识符（名称）、出发时间和车辆通过路线等进行定义，还可以对区域路网的中车道、速度或位置、车辆属性进行定义，并且对导入的路网文件的格式没有限制，与 VISSIM[78]也有跨平台兼容性，可以轻松导入 OD 矩阵和路网文件。SUMO 提供了便捷的 Python 开发接口 TraCI，通过这个接口，开发者可以在 SUMO 框架基础上对一些交通控制需求进行二次开发。

5.1.2 仿真环境配置

本章选择免费开源的 SUMO 构建路网模型作为仿真系统运行的环境，采用 Python 编程语言实现交通信号控制方法，通过 TraCI 接口完成和路网交通流进行通信，实现对交通流的协调控制。本文采用如表 5.1 所示的仿真环境和硬件的选型完成对强化学习的迭代训练。

由表可知，本文的仿真环境配置主要包括硬件和软件两方面。本文所选用的训练环境为谷歌的 Colaboratory（Colab）环境，其具有配置简便、云端共享的特点，并且提供免费的 Tesla T4 GPU，可以在浏览器中编写和执 Python 代码。软件方面考虑到稳定性与易用性，本文所采用的软件均为时下综合性能最优的版本。微观交通仿真软件使用 1.7.0 版本的 SUMO 软件，考虑到版本的兼容性，本文选择 1.2.0 版本的 Tensorflow 作为深度学习的框架，编程语言选择 3.7 版本的 Python 语言。

中国知网 https://www.cnki.net

表 5.1 仿真环境的配置方案

模块	选型	版本号
运行平台	Ubuntu	16
仿真平台	SUMO	1.7.0
GPU	Google Colab	Tesla T4
编程语言	Python	3.7
深度学习框架	TensorFlow	1.2.0

5.2 基于 SUMO 的仿真系统的构建

前文已经对两种交通仿真软件和运行环境进行了介绍，本章建立了一个基于强化学习算法的交通信号控制仿真系统，根据实际道路路网在 SUMO 微观仿真软件中搭建路网模型，使用 Python 编程语言实现深度强化学习交通信号控制算法，并通过 Traci 接口实现与 SUMO 中路网环境相互通信，实现对算法的仿真训练和测试。

5.2.1 仿真系统结构设计

如图 5.1 所示，建立基于深度强化学习交通信号控制系统，在城市交通信号的控制问题中，系统将区域路网中每个控制节点作为一个智能体，每个智能体均包括信息采集模块、信号协调控制模块、控制决策模块、执行模块、多智能体强化学习算法模块。

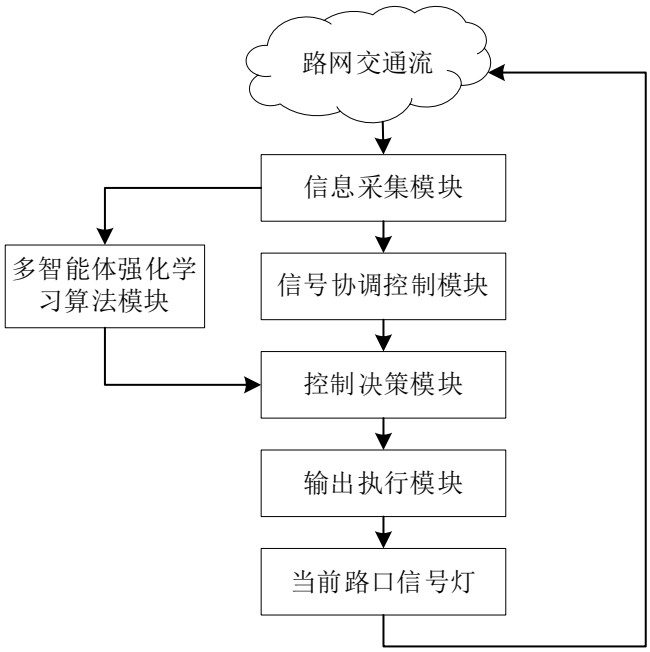

中国知网 https://www.cnki.net

图 5.1 仿真系统架构设计

信息采集模块用于获取交叉口的局部环境状态信息，采集区域路网中各交叉口车道上车流数据信息。信号协调控制模块基于信息采集模块采集的当前时刻交叉口交通状态信息，设计交通信号控制算法以选择一个最优动作，并将结果输出到下一模块。控制决策模块用于接收学习及优化模块中选取的动作，转换成相对应的信号灯配时方案。执行模块将信号灯的配时方案传输给交叉口的信号灯执行。多智能体强化学习算法模块根据执行的动作和信息采集模块获取状态信息，对控制策略进行持续优化。

仿真系统通过各模块之间的协作完成对交通信号的控制，系统的执行过程为：

（1）根据信息采集模块采集交叉口各条车道上的车辆位置信息和速度信息，以及相邻交叉口的状态信息；

（2）信号协调控制模块根据信息采集模块采集的联合状态信息，基于深度强化学习交通信号控制算法从动作空间中选择最优动作；

（3）控制决策模块根据动作信息，生成下一时刻交叉口信号灯的信号配时方案，即选择保持当前相位或执行下一个信号相位；

（4）输出执行模块将控制决策模块的信号配时方案转换成电信号输出给路口节点执行；

（5）当前路口信号灯执行控制策略，保持当前相位或者转换成下一信号相位；

（6）多智能体强化学习算法模块对控制算法进行持续的优化。

5.2.2 信号协调控制模块

信号协调控制优化模块是系统中的核心模块，如图 5.2 所示，主要由路网构建模块、交通需求模块、状态信息模块、环境模块、奖励函数模块以及算法模块和数据记录模块组成。

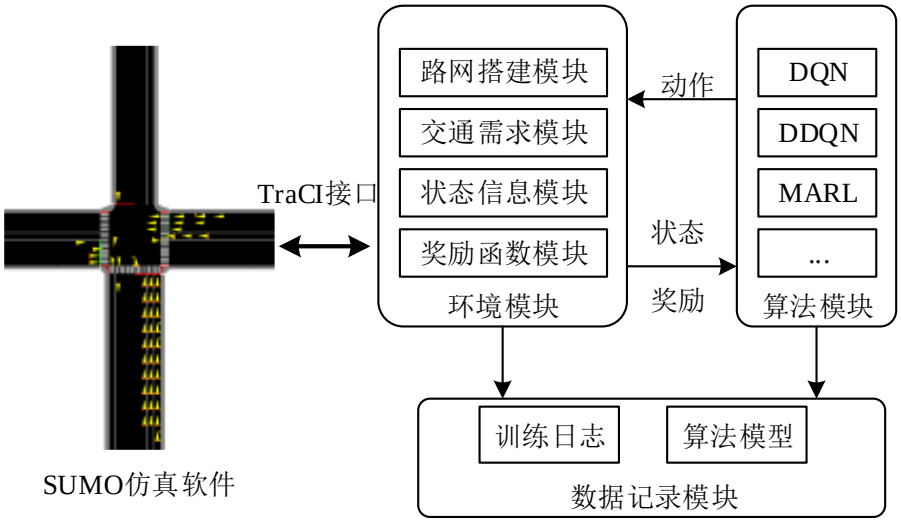

图 5.2 信号协调控制模块

中国知网 https://www.cnki.net

环境模块的作用是实现深度学习算法模块和 SUMO 仿真环境之间的沟通。路网构建模块对路网生成的接口进行封装。在 SUMO 中，路网是由节点和连边组成的，以.node.xml 的格式存储路网文件。路网的构建主要有以下方式。使用路网编辑器 Netedit 的以手动配置方式构建路网；从外部导入路网文件（如 VISSIM）；在 TraCI 接口中，实现 Generator 接口完成对路网构建。交通需求模块对车辆生成信息的接口进行了封装，SUMO 中通过对.rou.xml 路网文件进行配置，完成仿真过程中的交通流的生成。状态信息模块的作用是在仿真实验过程中，获取路网中车辆运行状态信息。

数据记录模块主要有两个作用。一是记录训练日志，在算法的训练和测试过程中记录每个仿真步路网交通流的信息，通过对这些数据可以对算法控制效果进行评估；二是保存保存训练后的算法模型。

5.2.3 仿真系统流程设计

基于 SUMO 的区域交通控制仿真系统的仿真流程如下：

（1）构建区域交通仿真环境。根据实际路网的交通环境和交通流数据，通过 SUMO 建立与目标道路交叉口相似的交通仿真环境，生成仿真阶段的交通流数据；

（2）初始化交通信号控制模型参数，初始化算法参数，通过 TraCI 接口实现控制算法与 SUMO 仿真环境通信，开始仿真运行；

（3）信息采集模块从路网中采集当前交叉口的局部交通路网信息，通过 TraCI 接口传给信号协调模块。

（4）接收到局部交通路网信息后，信息协调模块下的状态信息模块将其转换成由车辆的位置矩阵和速度矩阵组成的联合矩阵，输入到算法模块中，从动作空间中选择一个最优动作，并通过奖励函数模块得到执行动作后来自环境的反馈。

（5）控制决策模块接收到来自算法模块的动作后，转换成路口交通信号灯的配时方案，并传递给执行模块。

（6）执行模块通过 TraCI 接口对交叉口信号灯进行控制，保持当前相位不变或者执行到下一个信号相位。

（7）判断算法的迭代次数是否达到预定的训练步数 T，若否则返回步骤（3）继续进行步骤循环；若是则完成基于强化学习的交通信号控制模型的训练，

（8）数据记录模块记录仿真训练过程中的车辆运行数据以及训练完成的控制算法模型数据。

中国知网 https://www.cnki.net

如图 5.3 所示，基于 SUMO 的区域交通控制仿真系统的仿真流程图如下所示：

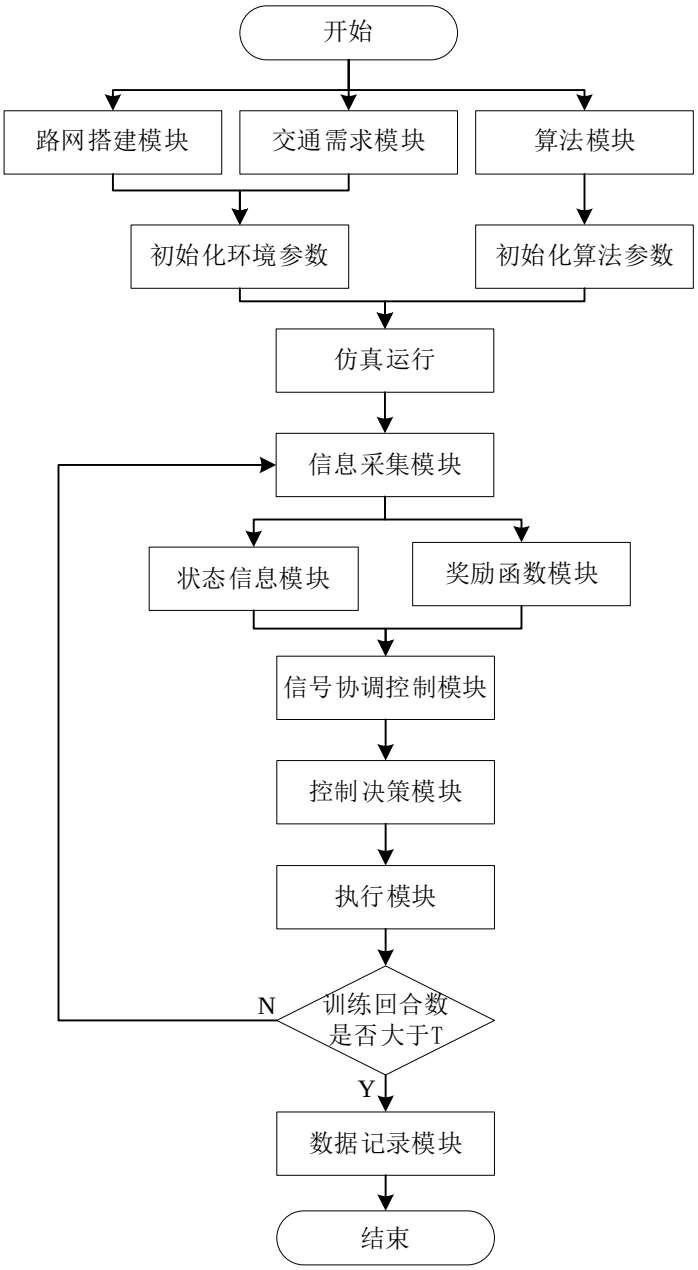

图 5.3 仿真系统控制流程

5.3 系统仿真实例验证

5.3.1 区域路网构建

仿真实验采用 SUMO 交通仿真平台，采用交通仿真中的 Traci（Traffic Control Interface）模块，通过 Python 语言实现算法与 SUMO 在线交互，获取实时的交通状态，并执行调节信号的控制动作。首先，如图 5.4 所示，使用 OpenStreetMap 选取南京市栖霞区某实际路网作为仿真实验研究对象，包括 29 个红绿灯控制的区域路网。

中国知网　https://www.cnki.net

图 5.4 OpenStreetMap 中南京市栖霞区某区域路网

使用 Java OpenStreetMap 编辑器对生成的路网进行调整得到 osm 地图格式文件，然后使用 SUMO 中的 Netconvert 方法将其转换成.xml 格式的路网文件。最后使用 SUMO 的 NetEdit 生成如图 5.5 所示的区域交通路网仿真图。

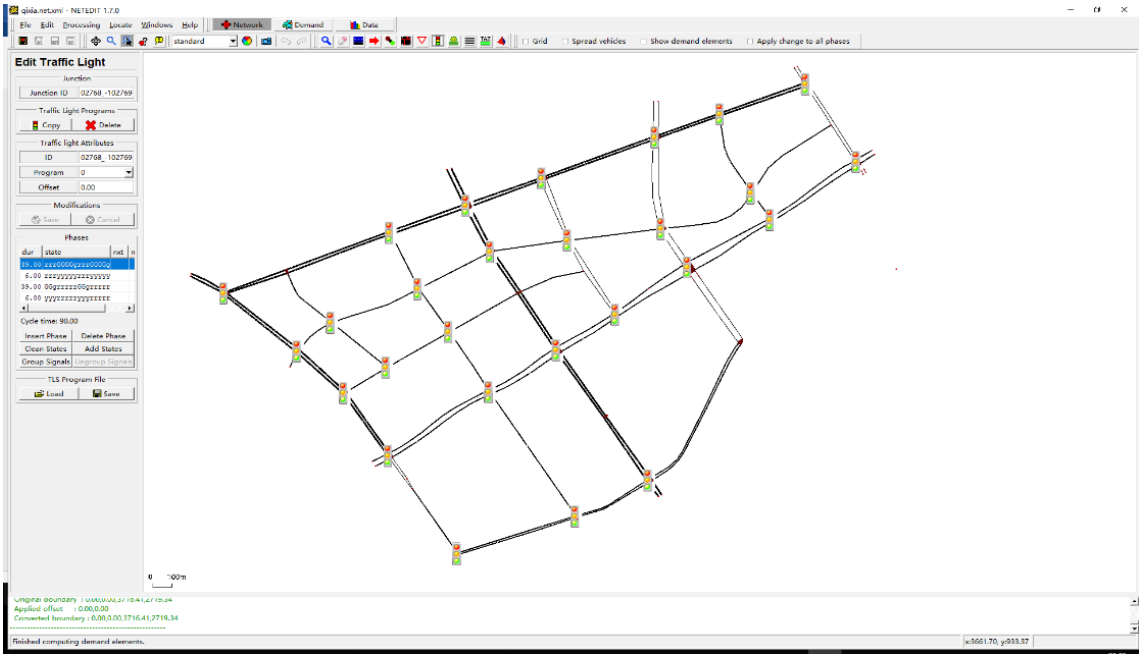

图 5.5 SUMO 路网仿真图

单独对每个交叉口的信号相位进行调整，使其符合实际交叉口的相位控制，图 5.6 路网中某一个交叉口的信号相位配置情况。

中国知网　https://www.cnki.net

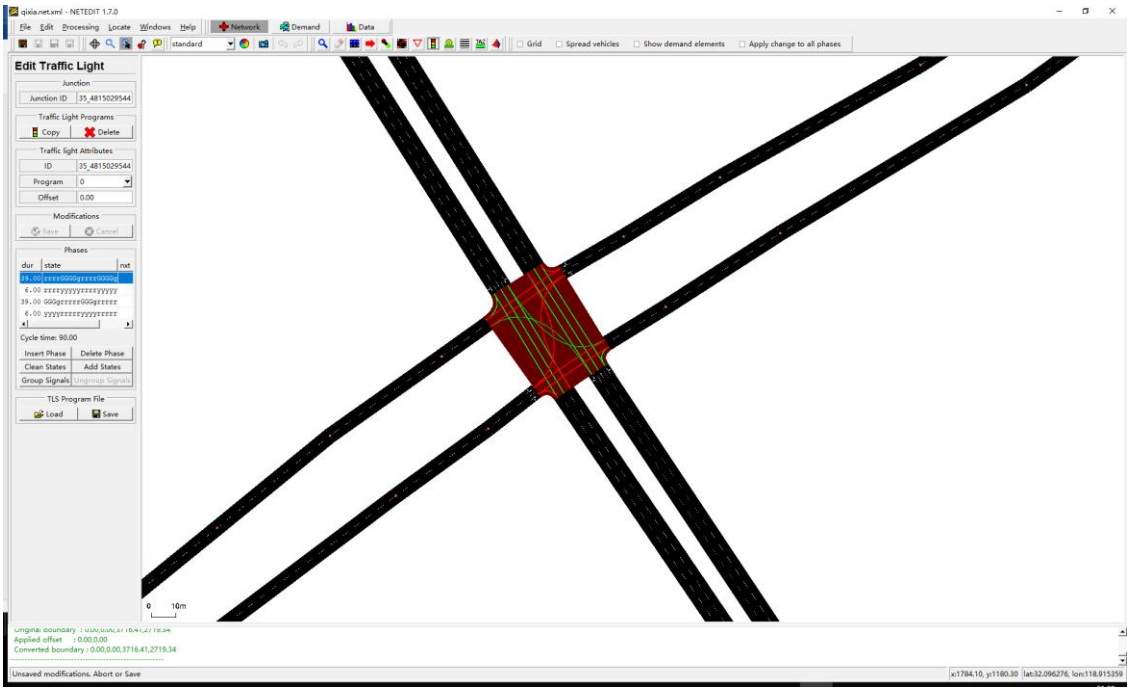

图 5.6 单个交叉口道路和红绿灯设置

5.3.2 实验参数设置

在模拟器运行过程中，每个时间步会产生一定数量的车辆，并在路网中随机分布。每一辆新生成的车辆都会按照一定的规则随机生成一条路线，车辆会沿着这条路线行驶，最终在到达目的地时将车辆从路网中移除。为了实现对真实交通情况的仿真，本文引入了可变的交通流量生成路网中的车辆，模仿现实中高峰期交通流的场景，流量变化如图 5.7 所示，横轴表示时间，时间长度固定为 3600 秒，纵轴表示产生的车辆数。在单位训练周期内车流量会存在一个明显的高峰期和低谷期流量变化由小变大到达高峰，维持一定时间的高峰流量之后逐渐变小。

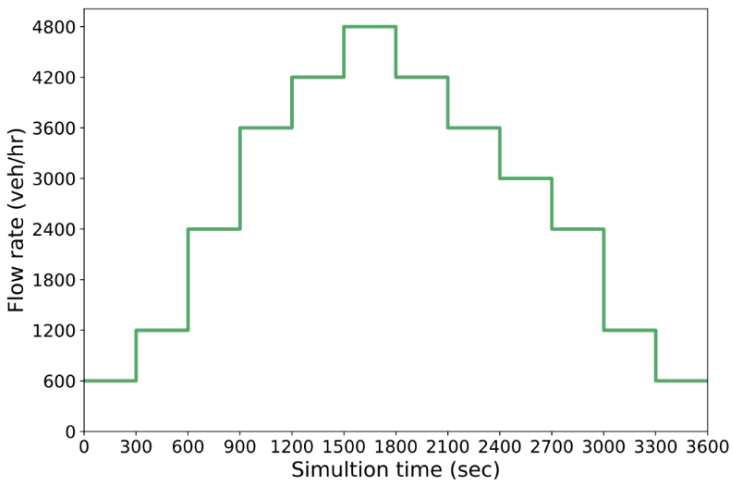

图 5.7：模拟高峰流量场景实验的每回合车流量

中国知网 https://www.cnki.net

实验一：完全独立多智能体强化学习算法，该算法常作为多智能体强化学习算法的对比基准，每个智能体仅使用本地观测作为输入，采用 DQN 作为算法的网络模型，实现对各智能体独立训练，该算法表示为 IQL。

实验二：在 IQL 基础上，智能体在决策过程中考虑相邻交叉口的状态信息分布，算法的模型和神经网络参数与 IQL 相同，该算法表示为 IQL-SS。

实验三：本文提出的基于协作式多智能体深度强化学习算法，通过共享相邻交叉口的状态和奖励信息，采用基于优先级经验回访策略的 DDQN 网络模型实现对交通信号的控制决策，该算法表示为 MARL-SI。

5.3.3 仿真实验结果分析

在相同仿真环境下对三种基于深度强化学习的交通信号控制模型进行训练，在训练阶段，仿真实验的训练总步数为10^6时间步，仿真实验共执行 1400 个迭代回合。每个迭代回合的仿真步数为 720 步。仿真实验阶段，在相同的实验场景下分别对三种方法进行了 10 次仿真实验，并将三种方法的实验结果进行汇总，对每个评价指标去平均值，得到了如表 5.2 所示的对比结果。

表 5.2 三种算法的性能对比

算法	平均行驶时间（s）	平均行驶速度（m/s）	平均延误时间（s）	平均排队长度（辆）
IQL	485	2.07	207	23.90
IQL-SI	237	5.04	157	10.45
MARL-SS	193	5.96	114	6.73

表 5.2 总结了三种方法在评估中比较的关键指标的平均值，本文提出的基于协作式多智能体深度强化学习算法的表现是最好。相对于 IQL-SS，平均行驶时间减少了 18.6%，平均行驶速度提升了 18.3%，平均延误时间减少了 27.4%，平均排队长度减少了 35.6%。实验表明本文提出的方法能够更好缓解交通拥堵问题，提高交通效率。

5.4 本章小结

本章提出了一种基于 SUMO 的区域交通控制仿真系统，对仿真系统的设计进行了详细描述，包括系统结构和使用流程。通过 SUMO 微观交通仿真软件模拟真实的交通路网，使用 Python 语言实现区域信号协调控制算法，通过 TraCI 接口实现算法与模拟环境间的通信，为

中国知网 https://www.cnki.net

区域交通信号控制方法研究提供了一个简单的仿真实现系统。最后通过在 SUMO 对现实路网进行建模，并在搭建的系统中实现了几种基于强化学习的区域交通控制算法，实验结果表明本文提出的算法的优越性，同时也证明了该系统的有效性和易用性。

中国知网 https://www.cnki.net

第六章 总结与展望

6.1 总结

本文通过对强化学习、多智能体和区域交通信号控制方法的研究分析，提出了一种协作式多智能体深度强化学习算法以实现区域路网协调控制。通过构建基于 SUMO 交通仿真软件的交通信号仿真系统，为交通信号智能控制方法提供了一个实验验证平台。主要研究内容如下：

（1）针对深度强化学习算法在交通控制应用中，环境状态空间大、算法收敛速度慢以及过估计等问题，本文提出了一种基于深度双 Q 网络的路口交通信号控制方法，采用离散状态编码将交通信息转化为由车辆位置信息和速度信息组成的二维矩阵作为神经网络的输入，路口交通相位压力差作为强化学习的奖励，压力的计算不仅考虑了道路上车辆排队长度，还考虑了道路的容量问题。通过优先级经验回放策略，提升训练样本的利用率，加快算法收敛速度。以单路口交通信号控制为研究对象，对所提出的算法进行仿真实验，证明了算法具有更快的收敛速度和更好的性能表现。

（2）针对区域交通信号控制由于路网的复杂性，对控制算法的协调性要求很高。将单智能体强化学习交通信号控制算法扩展到区域交通控制中，提出了一种基于协作式多智能体深度强化的区域交通信号协调控制方法，该方法将区域交通路网建模为一个无向图，图中每个结点作为一个强化学习智能体，智能体决策过程中考虑了相邻节点的状态和奖励信息，通过多智能体间马尔可夫博弈达到纳什均衡状态，实现对交通信号的协调控制。仿真实验表明，该方法能更好地实现对区域交通信号的协调控制。

（3）基于 SUMO 微观交通仿真软件和 Python 编程语言构建了一个区域交通协调优化控制仿真系统。在 SUMO 中构建区域交通路网模型，用 Python 编程语言实现深度强化学习框架，为基于强化学习的交通信号协调控制算法提供了一个仿真实验平台，对区域信号协调控制模块进行设计。通过对实际交通路网建模，利用深度强化学习交通信号控制算法在该系统上仿真实验，结果表明了该系统能很好地进行二次开发，能实现对交通信号控制算法的实验验证。

6.2 展望

本文通过深度强化学习算法在交通信号协调控制问题中的研究分析，虽然取得了一定的

中国知网 https://www.cnki.net

研究成果，但是仍然存在一些不足之处有待将来研究和改进：

（1）本文提出的 DDQN 交通信号控制算法，使用归一化压力差作为强化学习的奖励，强化学习的状态空间和奖励函数定义，算法的参数设置都对算法能否取得好的控制效果产生影响，可以进一步研究使用不同的设置对算法性能的影响。

（2）本文提出的区域交通信号控制模型还有待优化。智能体通过共享状态信息和奖励信息实现多路口之间的协调控制，考虑了智能体在空间上的相互影响，但并未考虑相邻交叉口交通流在时间上的相关性。所以，可以将使用序列关系学习和连续地强化学习技术来进一步对算法进行优化。

（3）本文运用 SUMO 交通仿真软件，利用 Python 编程语言实现深度强化学习框架进行二次开发，通过 TraCI 接口与 SUMO 模拟的路网环境进行实况模拟，来验证控制方法的合理性，现实交通中还有行人及非机动车以及天气等影响因素，这些都是对现实交通路网模拟时需要考虑的问题。

中国知网 https://www.cnki.net

参考文献

[1] 张莹. 交通基础设施对经济集聚的作用研究[D]. 西南财经大学, 2019.

[2] 唐建华. 强化学习及其在城市交通信号控制中的应用研究[D].西安电子科技大学,2012.

[3] Khooban M H, Liaghat A. A time-varying strategy for urban traffic network control: A fuzzy logic control based on an improved black hole algorithm[J]. International Journal of Bio-Inspired Computation, 2017, 10(1): 33-42.

[4] Wan H. Research on traffic signal control algorithm based on self-organizing competitive neural network and optimization model[J]. Agro Food Industry HiTech, 2017, 28(3): 2911-2914.

[5] Zhang Y, Zhou Y. Distributed coordination control of traffic network flow using adaptive genetic algorithm based on cloud computing[J]. Journal of Network and Computer Applications, 2018, 119: 110-120.

[6] Wei H, Zheng G, Gayah V, et al. A survey on traffic signal control methods[J]. arXiv preprint arXiv:1904.08117, 2019.

[7] 杨佩昆. 交通管理与控制[M]. 人民交通出版社, 2003.

[8] Webster RV Traffic Signal Setting[R]. Road Research Technical Paper No. 39, London: GreatBritain Road Research Laboratory, 1958.

[9] 叶宝林. 城市路网交通信号协调控制理论与方法研究[D]. 浙江大学, 2015.

[10] [10] Akcelik R. Traffic Signals: Capacity and Timing Analysis[M]. Melbourne: Australian RoadResearch Board, 1981.

[11] Park B, Rouphail N M, Sacks J. Assessment of stochastic signal optimization method using micro simulation[J]. Transportation Research Record, national Research, 2001, 16(2):155-161.

[12] Cowan R. An improved model for signalized intersections with vehicle-actuated control[J]. Journal of Applied Probability, 1978, 15(2): 384-396.

[13] Akcelik, R. Estimation of green times and cycle time for vehicle actuated sign[J]. TransportResearch Record: Journal of the Transportation Record, 1994, 14(57): 398-417.

[14] Peter G. Furth, Burak Cesme. Lost Time and Cycle Length for Actuated Traffic Signal[J].Transportation Research Record: Journal of the Transportation Research Board, 2009,2128:152-160.

[15] Bai L F, Xing D, Fu C L, et al. Traffic Guiding Method Based on Actuated Control and Phase Jump[J]. Applied Mechanics and Materials, 2013, 409: 1110-1117.

[16] Hunt P, Robertson D, Bretherton R, et al. The SCOOT on-line traffic signal optimisation technique[J]. Traffic Engineering & Control, 1982, 23(4): 190-192.

[17] Luk J. Two traffic-responsive area traffic control methods: SCAT and SCOOT[J]. Traffic Engineering & Control, 1984, 25(1): 15-22.

[18] Gershenson C, Rosenblueth D A. Self-organizing traffic lights at multiple-street intersections[J]. Complexity, 2012, 17(4): 23-39.

[19] Z.LiandP.Schonfeld,“Hybrid simulated annealing and genetic algorithm for optimizing arterial signal timings under oversaturated traffic conditions,” Journal of Advanced Transportation , vol.49,no.1,pp.153–170,2015.

[20] S.P.Hoogendoorn,V.L.Knoop,andH.J.VanZuylen,“Robust control of traffic networks under uncertain conditions,”Journal of Advanced Transportation, vol.42, no.3, pp.357–377, 2008.

[21] Van Der Pol E. Deep reinforcement learning for coordination in traffic light control[J]. Master's thesis, University of Amsterdam, 2016.

[22] Arel I, Liu C, Urbanik T, et al. Reinforcement learning-based multi-agent system for network traffic signal control[J]. IET Intelligent Transport Systems, 2010, 4(2): 128-135.

[23] Wiering M A. Multi-agent reinforcement Learning for Traffic light control[C]//Machine Learning:

中国知网 https://www.cnki.net

Proceedings of the Seventeenth International Conference (ICML'2000). 2000: 1151-1158.

[24] Abdoos M, Mozayani N, Bazzan A L C. Traffic light control in non-stationary environments based on multi agent Q-learning[C]//2011 14th International IEEE conference on intelligent transportation systems (ITSC). IEEE, 2011: 1580-1585.

[25] El-Tantawy S, Abdulhai B, Abdelgawad H. Multiagent reinforcement learning for integrated network of adaptive traffic signal controllers (MARLIN-ATSC): methodology and large-scale application on downtown Toronto[J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(3): 1140-1150.

[26] Chu T, Wang J, Codecà L, et al. Multi-agent deep reinforcement learning for large-scale traffic signal control[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(3): 1086-1095.

[27] Chen C, Wei H, Xu N, et al. Toward a thousand lights: Decentralized deep reinforcement learning for large-scale traffic signal control[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34(04): 3414-3421.

[28] Nishi T, Otaki K, Hayakawa K, et al. Traffic signal control based on reinforcement learning with graph convolutional neural nets[C]//2018 21st International Conference on Intelligent Transportation Systems (ITSC). IEEE, 2018: 877-883.

[29] Wei H, Xu N, Zhang H, et al. Colight: Learning network-level cooperation for traffic signal control[C]//Proceedings of the 28th ACM International Conference on Information and Knowledge Management. 2019: 1913-1922.

[30] 温凯歌，曲仕茹，张玉梅. 城市单交叉口信号多相位自适应控制模型[J]. 系统仿真学报, 2009 (10): 3066-3070.

[31] 杨文臣，张轮，Zhu Feng. 多智能体强化学习在城市交通网络信号控制方法中的应用综述[J]. 计算机应用研究, 2018, 35(06):1613-1618

[32] 吴昊. 基于多智能体强化学习的城市自适应交通信号控制方法研究[D]. 长安大学, 2019.

[33] C. Li, F. Yan, Y. Zhou, J. Wu and X. Wang. A Regional Traffic Signal Control Strategy with Deep Reinforcement Learning[C]. 2018 37th Chinese Control Conference (CCC), Wuhan, 2018, pp. 7690-7695.

[34] 唐菁. 基于半监督双竞争网络宽度强化学习的智慧交通信号控制方法研究[D].南京邮电大学,2021.

[35] 孙浩. 基于深度强化学习的交通信号控制方法研究[D]. 南京大学, 2020.

[36] 谢东瀚. 基于多智能体强化学习的智能交通控制系统[D].南京大学,2021.

[37] 杨佩昆，吴兵. 交通管理与控制[M]. 人民交通出版社, 2005: 89-152.

[38] 柴琳果,蔡伯根,上官伟,王剑,王化深,陈俊杰.车联网干线协调控制相位差自适应优化[J].北京交通大学学报,2018,42(02):69-75.

[39] Lämmer S, Helbing D. Self-control of traffic lights and vehicle flows in urban road networks[J]. Journal of Statistical Mechanics: Theory and Experiment, 2008, 2008(04): P04019.

[40] 朱凌云.城市交通区域延误模型与协调控制研究[D]. 中国科学技术大学, 2016.

[41] Kaelbling L P, Littman M L, Moore A W. Reinforcement learning: A survey[J]. Journal of artificial intelligence research, 1996, 4: 237-285.

[42] Papadimitriou C H, Tsitsiklis J N. The complexity of Markov decision processes[J]. Mathematics of operations research, 1987, 12(3): 441-450.

[43] Watkins C J C H, Dayan P. Q-learning[J]. Machine learning, 1992, 8(3): 279-292.

[44] G. A. Rummery and M. Niranjan, On-line Q-learning using connectionist systems. University of Cambridge, Department of Engineering Cambridge, England, 1994, vol. 37.

[45] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.

[46] Dong S, Wang P, Abbas K. A survey on deep learning and its applications[J]. Computer Science Review, 2021, 40: 100379.

[47] Gu J, Wang Z, Kuen J, et al. Recent advances in convolutional neural networks[J]. Pattern Recognition, 2018, 77: 354-377.

中国知网 https://www.cnki.net

[48] LeCun Y. LeNet-5, convolutional neural networks[J]. URL: http://yann. lecun. com/exdb/lenet, 2015, 20(5): 14.

[49] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.

[50] Mnih V, Kavukcuoglu K, Silver D, et al. Playing atari with deep reinforcement learning[J]. arXiv preprint arXiv:1312.5602, 2013.

[51] Van Hasselt H, Guez A, Silver D. Deep reinforcement learning with double q-learning[C]//Proceedings of the AAAI conference on artificial intelligence. 2016, 30(1).

[52] Zhang K, Yang Z, Başar T. Multi-agent reinforcement learning: A selective overview of theories and algorithms[J]. Handbook of Reinforcement Learning and Control, 2021: 321-384.

[53] OroojlooyJadid A, Hajinezhad D. A review of cooperative multi-agent deep reinforcement learning[J]. arXiv preprint arXiv:1908.03963, 2019.

[54] Prashanth L A, Bhatnagar S. Reinforcement learning with function approximation for traffic signal control[J]. IEEE Transactions on Intelligent Transportation Systems, 2010, 12(2): 412-421.

[55] Tampuu A, Matiisen T, Kodelja D, et al. Multiagent cooperation and competition with deep reinforcement learning[J]. PloS one, 2017, 12(4): e0172395.

[56] Usunier N, Synnaeve G, Lin Z, et al. Episodic exploration for deep deterministic policies: An application to starcraft micromanagement tasks[J]. arXiv preprint arXiv:1609.02993, 2016.

[57] Cui L, Wang X, Zhang Y. Reinforcement learning-based asymptotic cooperative tracking of a class multi-agent dynamic systems using neural networks[J]. Neurocomputing, 2016, 171: 220-229.

[58] 孙长银, 穆朝絮. 多智能体深度强化学习的若干关键科学问题[J]. 自动化学报, 2020, 46(7): 1301-1312.

[59] Littman M L. Markov games as a framework for multi-agent reinforcement learning[M]//Machine learning proceedings 1994. Morgan Kaufmann, 1994: 157-163.

[60] John F Nash et al. “Equilibrium points in n-person games”. In: Proceedings of the national academy of sciences 36.1 (1950), pp. 48–49.

[61] Elise van der Pol and Frans A Oliehoek. 2016. Coordinated Deep Reinforcement Learners for Traffic Light Control. Neural Information Processing Systems (NIPS) (2016).

[62] Hua Wei, Guanjie Zheng, Huaxiu Yao, and Zhenhui Li. 2018. IntelliLight: A Reinforcement Learning Approach for Intelligent Traffic Light Control. In ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD). 2496–2505.

[63] Jennie Lioris, Alex Kurzhanskiy, and Pravin Varaiya. 2013. Adaptive Max Pressure Control of Network of Signalized Intersections. Transportation Research Part C 36, 22 (2013), 177–195.

[64] Pravin Varaiya. 2013. Max pressure control of a network of signalized intersections. Transportation Research Part C: Emerging Technologies 36 (2013), 177–195.

[65] Mercader P, Uwayid W, Haddad J. Max-pressure traffic controller based on travel times: An experimental analysis[J]. Transportation Research Part C: Emerging Technologies, 2020, 110: 275-290.

[66] Wei H, Chen C, Zheng G, et al. Presslight: Learning max pressure control to coordinate traffic signals in arterial network[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 1290-1298.

[67] Genders W, Razavi S. Using a deep reinforcement learning agent for traffic signal control[J]. arXiv preprint arXiv:1611.01142, 2016.

[68] Dowling R. Traffic analysis toolbox volume vi: Definition, interpretation, and calculation of traffic analysis tools measures of effectiveness[R]. United States. Federal Highway Administration. Office of Operations, 2007.

[69] 张蕊, 童斌华. 区域交通信号控制系统评价指标[J]. 北京建筑工程学院学报, 2001, 17(4): 17-19.

[70] Ma D, Xiao J, Ma X. A decentralized model predictive traffic signal control method with fixed phase

中国知网 https://www.cnki.net

sequence for urban networks[J]. Journal of Intelligent Transportation Systems, 2021, 25(5): 455-468.

[71] Schaul T, Quan J, Antonoglou I, et al. Prioritized experience replay[J]. arXiv preprint arXiv:1511.05952, 2015.

[72] Bazzan A L C. Opportunities for multiagent systems and multiagent reinforcement learning in traffic control[J]. Autonomous Agents and Multi-Agent Systems, 2009, 18(3): 342-375.

[73] 刘豪. 多智能体博弈强化学习算法及其均衡研究[D]. 西安科技大学, 2020.

[74] H. Ge, Y. Song, C. Wu et al. Cooprttative Deep Q-Learning With Q-Value Transfer for Multi-Intersection Signal Control. [J] IEEE Access, 2019. 40797-40809.

[75] Hernandez-Leal P, Kartal B, Taylor M E. A survey and critique of multiagent deep reinforcement learning[J]. Autonomous Agents and Multi-Agent Systems, 2019, 33(6): 750-797.

[76] Tampuu A, Matiisen T, Kodelja D, et al. Multiagent cooperation and competition with deep reinforcement learning[J]. arXiv preprint arXiv:1511.08779, 2015

[77] Lopez P A, Behrisch M, Bieker-Walz L, et al. Microscopic traffic simulation using sumo[C]//2018 21st international conference on intelligent transportation systems (ITSC). IEEE, 2018: 2575-2582.

[78] Fellendorf, M., & Vortisch, P. (2010). “Microscopic traffic flow simulator VISSIM.” In Fundamentals of Traffic Simulation (pp. 63-93). Springer New York.

中国知网 https://www.cnki.net

附录 1 攻读硕士学位期间撰写的论文

[1] Yu p, Luo j. Minimize pressure difference traffic signal control based on deep reinforcement learning [C]//2022 41th Chinese Control Conference (CCC). (已录用)

中国知网 https://www.cnki.net

附录 2 攻读硕士学位期间申请的专利

[1] 罗杰，余鹏程. 基于最小化压力差的深度强化学习交通信号协调优化控制方法，202210609424.2，2022.5；

中国知网 https://www.cnki.net

致谢

时光荏苒，白驹过隙。在论文完成之际，回忆我从踏入南京邮电大学的校园开始到现在的点点滴滴，有过幸福，悲伤，彷徨，努力。在这期间有着导师的帮助和耐心指导，有着父母的支持，有着师门的相助，有着众多朋友的鼓励。

感谢我的导师罗杰老师！在整个研究生期间，尤其是在论文的选题、构思和资料的收集方面、论文的研究方法以及成文定稿方面，我得到了老师耐心细致的帮助和教诲，特别是他深厚的学术素养、严谨的治学态度和一丝不苟的敬业精神让我终身受益。一次次地帮我审阅论文并提出建议。再次谢谢我的老师！

感谢师门的师兄师姐！感谢曹洪旺师兄、王磊师兄、徐嘉明、黄志杰、顾霞师妹、马燕豪师弟、王灿师弟，在我生活和科研上的帮助和关心，很幸运能和你们在一个师门下。在实验室中与你们一起讨论论文、交流工作，丰富了我看待问题的视角，与你们在实验室的日子充实而快乐。

感谢我的家人！感谢父母这么多年来给予我的爱和关怀。当我在前进道路上遇到挫折与困难时，是你们包容了我的一切，给我无私的关怀与爱护，让我有勇气积极乐观地去面对、解决问题，感谢你们的支持，让我能够顺利地完成硕士学业。

感谢芳芳同学！在我迷茫无助的时候，感谢你一直在我身边。感谢你在学业、生活、工作的种种事情中的关心、勉励与陪伴。

研究生生涯已步入尾声，感谢在南邮遇见的一切人和事。即将踏上工作岗位，面对新的环境，我会继续谨记罗老师的谆谆教诲，在往后的工作中始终保持认真负责的态度。最后再次感谢所有帮助过我的人。

中国知网 https://www.cnki.net