浙江科技大学学报，第 37 卷第 5 期，2025 年 10 月
Journal of Zhejiang University of Science and Technology
Vol. 37 No. 5, Oct. 2025

doi：10.3969/j.issn.2097-5236.2025.05.009

基于 DQN 算法的决策和执行分离的交通信号控制

谢梦伟[1]，陈　光[2]，汪　洋[2]，胡鸿翔[3]，侯北平[1]
（1. 浙江科技大学 自动化与电气工程学院，杭州 310023；2. 台州学院 人工智能学院，台州 318000；
3. 杭州电子科技大学 理学院，杭州 310018）

摘　要：【目的】为了解决交通信号强化学习控制中相位决策即执行机制可能带来的交通安全隐患问题，提出一种相位决策和执行分离的深度强化学习交通信号控制方法。**【方法】**首先，引入相位决策和执行分离的策略，在当前交通信号相位持续时间临近结束的过渡期，智能体（交通信号控制器）基于道路交叉口的实时车流状况信息做出下一相位决策，并在当前相位持续时间结束时执行下一相位，以此在相位决策和执行的过渡期引入信号预警；然后，在深度 Q 网络（deep Q-network，DQN）强化学习的框架上设计并实现算法；最后，搭建仿真试验环境对算法进行验证。**【结果】**过渡期时长为 5 s 时，本研究提出的方法在多种交通流量条件下均表现优异，与 DQN 控制策略相比，本研究方法在高、中、低及混合车流量场景中车辆平均行驶时间分别减少 3.58%、9.85%、12.19% 和 3.44%，在高、中、低车流量场景中平均等待时间分别减少 7.35%、13.92% 和 45.36%，在混合车流量场景中无明显优势；相较于竞争架构深度 Q-network（dueling deep Q-network，Dueling DQN）控制策略，车辆平均行驶时间分别降低 3.09%、7.74%、16.25% 和 25.15%，平均等待时间分别降低 5.24%、10.96%、51.94% 和 57.87%；与柔性演员-评论家（soft actor-critic，SAC）控制策略相比，车辆平均行驶时间分别降低 7.86%、14.19%、24.01% 和 9.50%，平均等待时间分别降低 22.94%、28.47%、63.50% 和 12.17%。**【结论】**本研究有效提高了车辆通行效率，同时通过在相位切换过渡期引入信号预警，使驾驶者能够提前知晓信号变化，避免做出错误决策，从而减少交通安全隐患，对实现智能交通和交通安全有现实意义。

关键词：交通信号控制；深度强化学习；DQN；决策和执行分离
中图分类号：U491.5；TP181　　**文献标志码：**A　　**文章编号：**2097-5236(2025)05-0526-11

Traffic signal control with decoupled decision-making and execution based on DQN

XIE Mengwei[1], CHEN Guang[2], WANG Yang[2], HU Hongxiang[3], HOU Beiping[1]
(1. School of Automation and Electrical Engineering, Zhejiang University of Science and Technology, Hangzhou 310023, Zhejiang, China; 2. School of Artificial Intelligence, Taizhou University, Taizhou 318000, Zhejiang, China; 3. College of Science, Hangzhou University of Electronic Science and Technology, Hangzhou 310018, Zhejiang, China)

Abstract: [**Objective**] To address potential safety risks caused by the immediate execution of phase decisions in reinforcement learning-based traffic signal control, a deep reinforcement

收稿日期：2025-03-23
基金项目：国家自然科学基金项目（62106168，62376079）；浙江省自然科学基金杰出青年科学基金项目（LR22F030004）
通信作者：陈　光（1987—　），男，浙江省温岭人，副教授，博士，主要从事复杂网络流量分析与控制研究。E-mail：xcgmsn@163.com。

中国知网　https://www.cnki.net

learning method that decouples phase decision-making from execution was proposed for traffic signal control. [**Method**] First, a phase decision-execution separation strategy was introduced during the transition period before the ending of the current signal phase, when the agent (traffic signal controller) determined the next phase based on real-time intersection traffic data but executed it only upon the current phase's completion, with an early warning interval embedded between decision and execution; then, an algorithm was designed and implemented within the deep Q-network (DQN) reinforcement learning framework; finally, simulation experiments were conducted for validation. [**Result**] When the transition period is 5 seconds, the method proposed in this study demonstrates excellent performance across various traffic flow conditions. Compared to DQN, the proposed method reduces the average vehicle travel time by 3.58%, 9.85%, 12.19%, and 3.44% under high, medium, low, and mixed traffic volumes, and decreases the average waiting time by 7.35%, 13.92%, and 45.36% under high, medium, and low traffic volumes, and perform equally well under mixed traffic volumes; in comparison to the competing architecture, the dueling deep Q-network (Dueling DQN), it shortens the average vehicle travel time by 3.09%, 7.74%, 16.25%, and 25.15%, and reduces the average waiting time by 5.24%, 10.96%, 51.94%, and 57.87%, respectively; when compared with the soft actor-critic (SAC) control strategy, it reduces the average vehicle travel time by 7.86%, 14.19%, 24.01%, and 9.50%, and decreases the average waiting time by 22.94%, 28.47%, 63.50%, and 12.17%, respectively. [**Conclusion**] The proposed method significantly improves vehicle traffic efficiency while enhancing safety via the signal transition warning mechanism, enabling drivers to anticipate phase changes and avoid erroneous decisions so as to lower potential safety risks. This work offers a practical solution for advancing intelligent transportation and road safety.

Keywords: traffic signal control; deep reinforcement learning; DQN; decoupled decision-making and execution

交通拥堵已成为制约现代城市发展的主要问题之一，它不仅严重影响社会经济运行，还可能引发交通安全隐患[1-2]。受限于城市空间和建设成本，仅依靠拓宽道路等基础设施扩张手段“治堵”往往需要付出高昂的经济代价。相比之下，通过优化交通控制策略等柔性方案，在现有道路条件下实现交通流的有序引导和动态调控，不仅有助于缓解交通拥堵，还能减少交通冲突和事故风险，提升道路交通安全，具有更为显著的应用价值。

自适应交通信号控制(adaptive traffic signal control, ATSC)作为柔性交通管理的重要手段，近年来受到广泛关注[3]。特别是深度强化学习(deep reinforcement learning, DRL)技术的迅速发展，为交通信号控制提供了新的思路[4]。DRL 作为 ATSC 的一个重要方法，可以通过在复杂交通环境中的自主学习和实时决策，持续优化信号灯配时方案，从而实现智能、高效的交通管理和拥堵缓解[5-6]。当前，大部分研究采用决策即执行的方式，即当交通信号当前相位结束时，智能体完成决策后立即切换交通信号状态。Chu 等[7]研究了端到端的离线深度强化学习交通信号控制，以实时图像中的车辆信息作为模型的输入，优化交通信号配时，降低了车辆的平均等待时间。张玺君等[8]将自注意力机制(self-attention)与 DRL 相结合，通过从有限特征中挖掘潜在的交通状态信息，实现交通信号相位的动态优化。Yang 等[9]提出了一种基于多源数据融合的深度强化学习方法，通过物联网技术整合各传感器采集的交通状态信息，为交通信号相位序列预测提供全面的数据支持。

上述方法在交通信号控制中取得了良好效果，但大多采用相位决策即执行的方式，即在当前相位结束时刻决策下一相位并立即执行，这种无征兆的突变方式若与驾驶者常规认知不符，会造成交通参与者错误决策，进而产生安全隐患，在交通信号控制中，交通安全方面的考量也是必要的[10]。针对上述问题，本研究提出一种基于深度 Q 网络(deep Q-network, DQN)改进的相位决策和执行分离的交通信号控制

中国知网 https://www.cnki.net

方法。本方法在当前相位即将结束前的特定过渡期，利用实时交通信息预测下一相位，当前相位结束后再执行新的相位；同时，在过渡期内可以通过显示屏提供信号预警信息，告知驾驶者下一相位的变化，通过试验不断优化过渡期时长，平衡信号预警时长与交通效率，确保交通信号的智能化调控，在减少拥堵的同时降低交通安全隐患。

1 问题描述与假设

交通相位切换过程如图 1 所示，在常规交通信号控制中，东西方向的直行绿灯结束后，通常切换至相应的左转绿灯。然而，在深度强化学习驱动的交通信号控制决策中，下一相位可能直接切换为南北方向的直行绿灯。

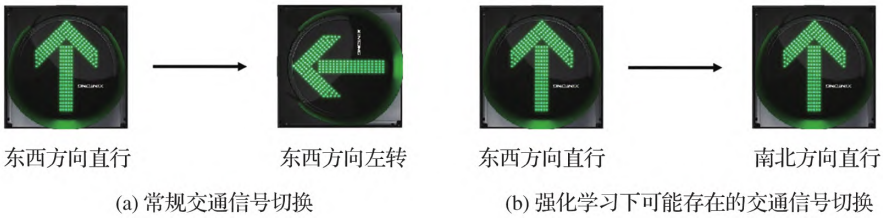

图 1 交通相位切换过程

Fig. 1 Switching of traffic signal phases

这种无固定顺序、无预兆的相位切换方式可能引起驾驶者的错误决策，增加交通冲突的风险，存在潜在的安全隐患。为缓解“决策即执行”式信号控制引发的安全问题，本研究引入了交通信号相位决策和执行分离的机制，在决策和执行的过渡期内进行信号预警，以提升信号切换的可预测性和交通系统的整体安全性。

1.1 强化学习算法

强化学习(reinforcement learning, RL)本质上是一种基于试错机制的学习方法。智能体通过与环境持续交互，从中获取反馈信息，并根据所执行动作获得的奖励或惩罚不断地调整和优化策略。其理论基础建立在马尔可夫决策过程(Markov decision process, MDP)[11]之上。强化学习过程示意图见图 2。

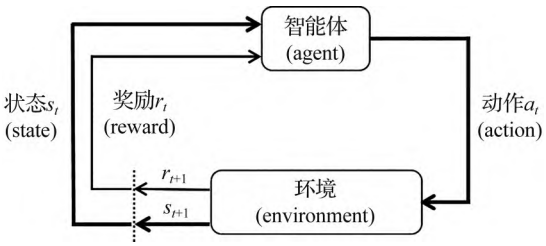

图 2 强化学习过程示意图

Fig. 2 Reinforcement learning process diagram

完整的强化学习过程包括环境、智能体、状态、动作和奖励。MDP 针对有限过程的强化学习，由五元组$\{S,A,P,R,T\}$组成，其中 S 是所有状态的集合，A 是所有动作的集合，P 是状态转移函数，R 是奖励信息，T 是最大轨迹长度。在强化学习中，智能体在一个时间步 t 内根据当前环境状态 s_t 来选择动作 $a_t(a_t \in A)$，动作 a_t 作用到环境之后，环境根据状态转移函数 P 进入新的状态 s_{t+1}，并接收环境反馈的奖励信息 r_t，循环上述过程直到智能体找到最优策略以最大化累积奖励。智能体获得的累计奖励

$$R = \sum_{i=1}^{T-1} \gamma^{i-1} r_{t+i}。 \tag{1}$$

式(1)中：$\gamma \in (0,1)$为奖励折扣系数，其值越大表示智能体越重视未来奖励，其值越小表示智能体更侧重于即时奖励。

1.2 描述与假设

交通信号控制系统的状态演变具有强马尔可夫特性[12]，即系统未来状态的发展仅依赖于当前的状态，而不受过去历史状态的直接影响。基于这一特性及前文对强化学习的阐述，本研究将强化学习中的环境、状态、动作和奖励等定义及相关假设作以下描述。

中国知网 https://www.cnki.net

1.2.1　环　境

研究对象为带有交通信号灯的十字交叉口，十字交叉口处含有多个受控车道，车辆在十字交叉口根据自身的行进方向进入对应的受控车道，不同受控车道上车辆的通行由交通灯发出的信号控制。十字交叉口信号通过相位进行管理，每一相位表示允许一个或多个方向车辆通行的绿灯状态，如直行和右转同时绿灯。十字交叉口范例及其中的交通信号相位如图 3 所示，包含 12 个受控车道，该十字交叉口的交通信号包含 4 个相位：东西方向直行和右转绿灯（EW-SR）、东西方向左转绿灯（EW-L）、南北方向直行和右转绿灯（SN-SR），以及南北方向左转绿灯（SN-L）。

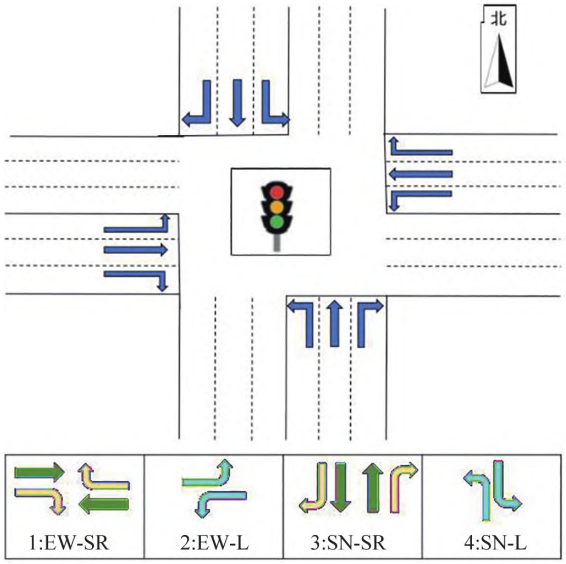

图 3　十字交叉口范例及其中的交通信号相位

Fig. 3　Example of an intersection and its traffic signal phases

1.2.2　动　作

在强化学习框架中，智能体的动作通常分为连续动作和离散动作两类。连续动作适用于连续控制场景，动作空间为无限集合；而离散动作则由一组预定义的有限可选项构成。在本研究中，智能体采用离散动作方式控制十字交叉口交通流，具体动作被定义为将交通信号切换至某一指定相位。以图 3 所示的 12车道十字交叉口为例，智能体的动作空间包含 4 个动作，分别为切换交通信号至 EW-SR、EW-L、SN-SR和 SN-L，编号为动作 1 至动作 4。

1.2.3　状　态

若有交叉口受控车道的集合为 L_{in}，本研究假设智能体在进行第 k 次决策时可感知并用于强化学习的环境状态信息 s_k 如下：1）各受控车道排队车辆数量集合 $N_{t_k}=\{N_{l,t_k}, l\in L_{\text{in}}\}$，其中 N_{l,t_k} 为相位 p_{t_k} 部署时刻至 t_k 期间车道 l 上车速低于 0.1 m/s 车辆的数量；2）各受控车道排队车辆长度集合 $Q_{t_k}=\{Q_{l,t_k}, l\in L_{\text{in}}\}$，其中 Q_{l,t_k} 为相位 p_{t_k} 部署时刻至 t_k 期间车道 l 上车速低于 0.1 m/s 车辆的车长之和；3）各受控车道车辆等待时间集合 $W_{t_k}=\{W_{l,t_k}, l\in L_{\text{in}}\}$，其中 W_{l,t_k} 为相位 p_{t_k} 部署时刻至 t_k 期间车道 l 上所有车辆车速低于 0.1 m/s 情况的时长之和；4）当前相位 p_{t_k} 及其持续时间 d_{t_k}。

1.2.4　奖　励

在强化学习中，即时奖励 r_k 用于评估智能体在当前状态 s_k 下采取动作 a_k 获得的短期收益，对其进行合理设置，可以激励智能体学习能够最大化累积奖励的最佳决策策略。考虑到交通信号控制系统的设计目标为缩短排队车队长度与减少车辆等待时间，本研究中定义智能体动作执行的即时奖励

$$r_k=-\sum_{l\in L_{\text{in}}}(\alpha Q_{l,t_{k+1}}+\beta W_{l,t_{k+1}})。\tag{2}$$

式（2）中：r_k 为第 k 次决策做出的动作 a_k 在执行后获得的即时奖励；$Q_{l,t_{k+1}}$ 为 a_k 对应的相位 $p_{t_{k+1}}$ 从部署时刻至下一次决策时刻 t_{k+1} 期间车道 l 上车速低于 0.1 m/s 车辆的车长之和，反映了低速车辆在空间维

中国知网　https://www.cnki.net

度上的积聚程度，车辆在低速状态下聚集，表明车道空间资源占用严重，是静态排队的直接体现；$W_{l,t_{k+1}}$ 为 $p_{t_{k+1}}$ 从部署时刻至 t_{k+1} 期间车道 l 上所有车辆车速低于 0.1 m/s 情况的时长之和，捕捉了低速状态的时域特征，较长的持续时间意味着系统恢复慢、排队消散效率低，是动态拥堵的反映；车长之和与时长之和能较全面地反映交通状态。因此，在奖励函数中引入这两个指标，有助于强化学习中的智能体学习疏导拥堵的策略；α、β 分别为两部分所占的比重。

1.3 决策和执行分离策略

本研究中按如下规则实现智能体动作决策和执行的分离：智能体在当前相位持续时间结束前 δ s 决策新动作，而新动作则在当前相位持续时间结束时执行。具体地，设智能体在 t_k 时刻进行第 k 次决策，当前相位 p_{t_k} 预定的结束时刻为 t'_k，则有 $t_k=t'_k-\delta$。若 t_k 时刻决策得到的动作为 a_{t_k}，对应地把交通信号相位切换为 $p_{t_{k+1}}$，则 a_{t_k} 将在当前相位 p_{t_k} 结束，即当前时刻 t_k 的 δ s 后的 $t_k=t'_k+\delta$ 时刻被执行。

值得注意的是，在上述规则中，智能体在一次决策时得到的动作（相位）可能与上一次决策相同或不相同，考虑到现实中相邻绿灯相位的切换之间存在过渡的黄灯信号，本研究将相位切换决策和执行策略分为两种情况，见图 4。

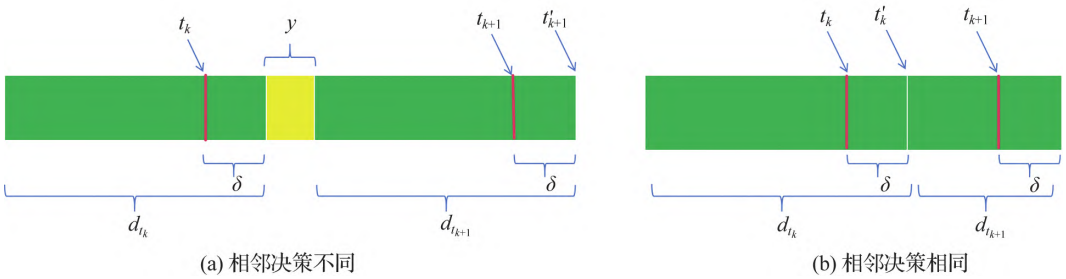

图 4 相位切换决策和执行策略示意图

Fig. 4 Schematic diagram of phase switching decision-making and execution strategy

本研究提出的方法中，规定动作的执行遵循如下规则：设当前相位的持续时间为 d_{t_k}，当智能体决策的下一相位 $p_{t_{k+1}}$ 与 p_{t_k} 不同时，在 p_{t_k} 结束后，首先部署 y s 的过渡黄灯，再部署 $p_{t_{k+1}}$；当下一相位 $p_{t_{k+1}}$ 与当前相位 p_{t_k} 相同时，则不设置过渡黄灯，在当前相位结束后直接部署 $p_{t_{k+1}}$，即等同于将 p_{t_k} 的持续时间延长 d_{t_k}。同时，在本研究中，对于不同的 k，d_{t_k} 固定不变，为一个给定常量。

2 改进的 DQN 算法

2.1 改进的 DQN 工作框架

DQN 是一种经典且高效的方法，有着广泛的应用场景，通过引入深度神经网络以近似动作价值函数，显著增强了 Q-Learning 在处理高维和复杂状态空间问题中的能力。DQN 采用两个神经网络结构：评估网络与目标网络。其中，目标网络的参数以较低频率从评估网络中进行同步更新，从而在一定程度上缓解了训练过程中的不稳定性；评估网络通过最小化时序差分（temporal difference，TD）误差[13]以优化网络参数。损失函数

$$L_\theta(\mathrm{DQN})=\frac{1}{B}\sum_{k=1}^{B}\mu_k^2。\tag{3}$$

式(3)中：B 为批大小（batch size）；μ_k^2 为第 k 次 TD 误差的平方。TD 误差

$$\mu=r+\gamma\max a'q(s',a';\theta^-)-q(s,a;\theta)。\tag{4}$$

式(4)中：$r+\gamma\max a'q(s',a';\theta^-)$ 为目标网络的预测值；$q(s,a;\theta)$ 为评估网络的计算值；θ^-、θ 分别为两个网络的参数；评估网络每经过 τ 次训练，θ^- 通过复制 θ 参数进行一次更新。此外，DQN 还引入了经验回放机制，采用在经验回放池中存储历史交互数据并进行随机采样的方法，有效降低了样本间的相关性，进一步提升了学习效率与训练稳定性。

基于上述对 DQN 的描述，本研究提出一种基于 DQN 改进的深度强化学习方法 DQN-δ，δ 即过渡期

中国知网 https://www.cnki.net

时长参数，本方法的工作框架如图 5 所示，基本原理与 DQN 一致，不同的是本研究引入了动作决策和执行分离机制。具体地，在 t_k 时刻从交通环境中提取相位、相位时间、车辆密度、排队长度和等待时间等关键状态特征，经过 DQN 中的评估网络和目标网络进行计算和决策，并在 $t_k+\delta$ 或 $t_k+\delta+y$ 时执行新的相位。最后计算奖励信息，并将状态特征、奖励等经验数据存储在经验回放池中。此外，在训练时同样通过随机抽样打破数据之间的关联性，提高训练稳定性。决策和执行分离机制在不影响交通通行效率的前提下，可以在动作决策和执行的过渡期内加入信号预警，缓解潜在的交通安全问题。

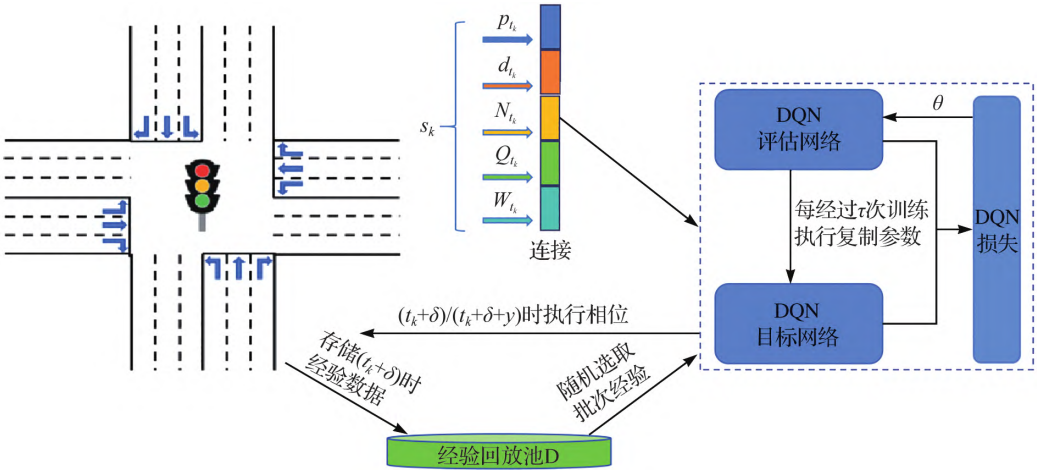

图 5　DQN-δ 的工作框架

Fig. 5　Working framework of DQN-δ

2.2　改进的 DQN 算法网络结构

在 DQN-δ 中使用的评估网络和目标网络的结构如图 6 所示。1)网络的输入为环境状态信息 s_k，以图 3 所示的十字交叉口对象为例，输入层应包含当前信号相位 p_{t_k} 编号、当前相位持续时间 d_{t_k}，以及 12 个受控车道各自的排队车辆数量 N_{l,t_k}、排队车辆长度 Q_{l,t_k} 与车辆等待时间 W_{l,t_k}，共计 38 个神经元；2)网络包含 3 个隐藏全连接层，每层的节点数均为 256，且均使用 ReLu 激活函数；3)网络输出层为不使用激活函数的全连接层，各神经元的输出为对应编号动作 a_k 的价值 $Q(s_k,a_k)$，以图 1 所示的十字交叉口对象为例，输出层应包含 4 个神经元。

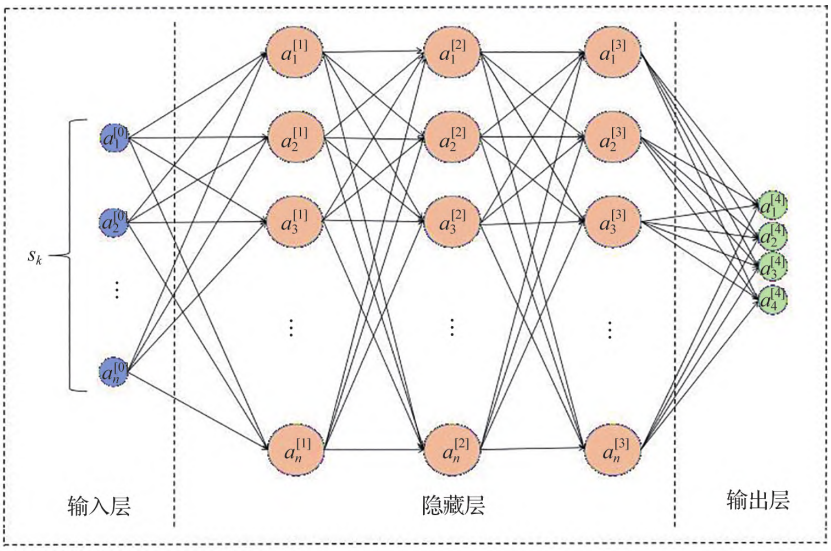

图 6　DQN-δ 中评估网络与目标网络的结构

Fig. 6　Structure of evaluation network and target network in DQN-δ

中国知网　https://www.cnki.net

3 试验设置及试验结果分析

3.1 试验设置

为验证 DQN-δ 算法在交通信号控制中的性能，本研究基于城市交通仿真软件 SUMO[14]（simulation of urban mobility），分别对 DQN、竞争架构深度 Q-network（dueling deep Q-network，Dueling DQN）、柔性演员-评论家[15]（soft actor-critic，SAC）及 DQN-δ 等方法开展了仿真试验。试验选取图 1 的十字交叉口为对象，图 7 展示了十字道路交叉口仿真场景本地局部快照。

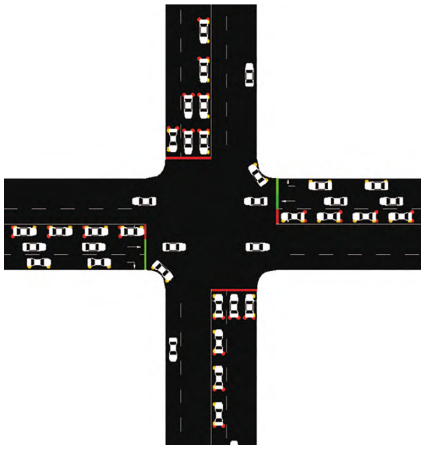

图 7 十字道路交叉口仿真场景本地局部快照

Fig. 7 Local snapshot of a crossroad intersection simulation scenario

训练时，DQN-δ 的超参数设置如下：回合数 E 为 110 次；各回合运行时长 T 为 3 600 s；奖励折扣系数 γ 为 0.98；经验回放池经验数量上限 $D_{\max}$、下限 $D_{\min}$ 分别为 50 000 条、500 条；目标网络参数更新周期 τ 为 10；每回合 ε-greedy 策略探索系数 ε 初始为 1.0，并在每次训练衰减 0.000 5，直到衰减至 0.001 后维持不变；神经网络训练采用 Adam 优化器，学习率为 0.001 5，批量样本数 B 为 32；即时奖励函数式(2)中的比重系数 α、β 均为 0.5，即认为二者对疏导拥堵的贡献程度相同；相位持续时间 d_{t_k} 为 30 s，若下一相位与当前相位相同，则该相位的延长时间设置为 10 s；黄灯持续时间 y 为 3 s。

同时，本研究考虑了 4 种不同的交通流量场景：高车流量、中车流量、低车流量和混合车流量。其中，在高、中、低车流情景中，模拟车辆的生成率分别为 1.00 辆/s、0.67 辆/s 和 0.23 辆/s，一辆新生成的车辆以相同的概率随机进入一个车道，其中直行概率为 60%，左转概率为 25%，右转概率为 15%；在混合车流量情景中，模拟车辆的生成率为 1.0 辆/s，一辆新生成的车辆分别以 45%、33%、22%的概率随机进入一个直行、左转、右转车道。具体地，仿真中设置连接交叉口的道路长度为 600 m，每条道路为双向 6 车道，车道限速为 50 km/h，最大速度比为 1.3，即允许车辆最大可以限速的 1.3 倍（即 65 km/h）行驶，仿真环境的详细参数见表 1，其中智能驾驶员模型（intelligent driver model，IDM）是一种基于连续加速度方程的微观跟驰模型，能够模拟车辆在自由流、跟驰和紧急制动等场景下的动态行为，贴近真实的驾驶行为。

表 1 仿真环境的详细参数

Table 1 Detailed parameters of simulation environment

交叉口类型	交通路网参数	参数值或情况	交叉口类型	交通路由参数	参数值或情况
十字交叉口	节点(个)	5	十字交叉口	路径(概率)	0.6/0.25/0.15
	边(条)	4		车辆类型	小型汽车
	车道(个)	24		加速度(m/s^2)	2.0
	交通灯(个)	1		减速度(m/s^2)	4.5
	车道长度(m)	600		跟驰模型	IDM
	车流量	高/中/低/混合		限速(km/h)	50

中国知网 https://www.cnki.net

同时，考虑到 δ 设置过大可能产生延迟响应的不良影响，设置过小则可能引发不稳定控制行为且有违设置过渡期以缓冲信号变换的初衷，本研究分别在 δ 为 3、5、7 s 等 3 种情况下开展了仿真试验。

3.2　试验结果分析

从训练阶段评估 DQN、Dueling DQN、SAC 及 DQN-δ 的收敛速度和稳定性。图 8 展示了不同车流量下各方法的回合累计奖励变化曲线。通过奖励变化曲线图可以看出，各方法均能在十个训练回合内实现累计奖励的快速提升，且之后趋于稳定。对比来看，在中车流量和高车流量的情况下，DQN-δ(δ=3 s)和 DQN-δ(δ=5 s)的奖励曲线相较 DQN、Dueling DQN 和 SAC 的奖励曲线振荡更小，说明相较传统 DQN、Dueling DQN 和 SAC 方法，引入动作决策和执行分离策略的方法在强化学习训练过程中表现出更优的稳定性。

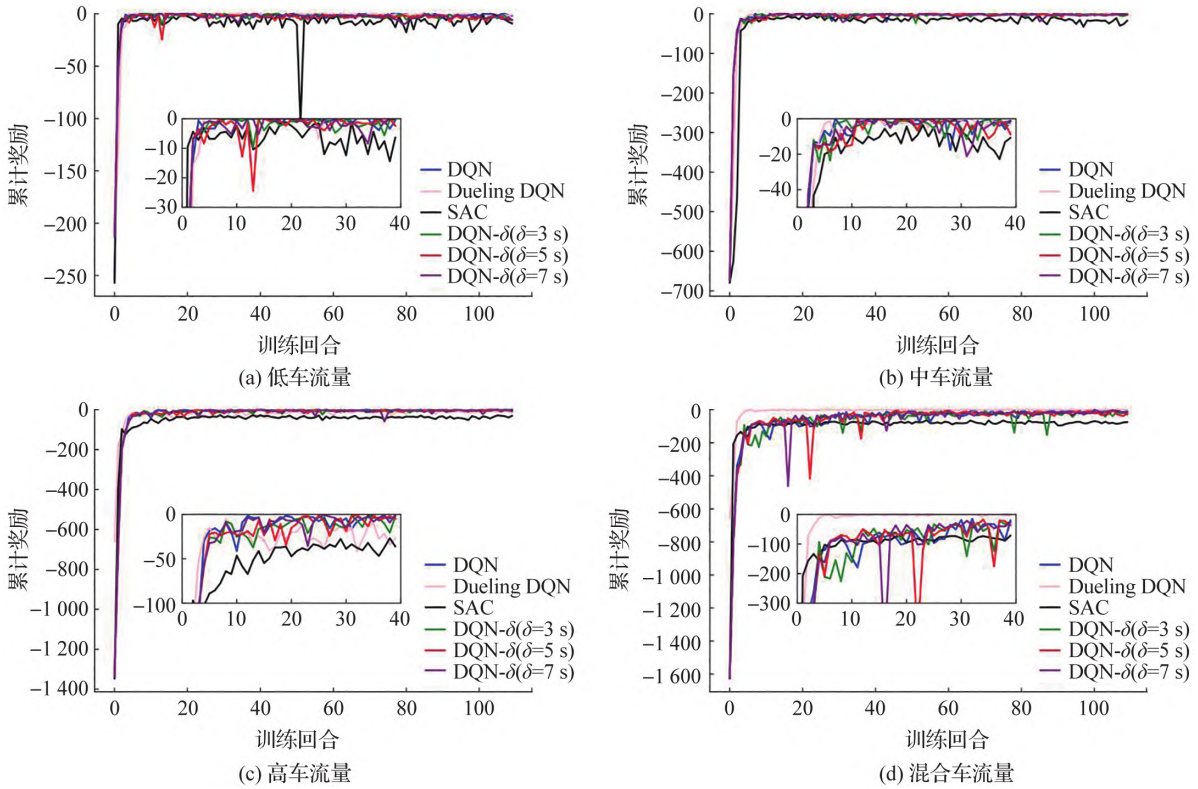

图 8　不同车流量下各方法的回合累计奖励变化曲线

Fig. 8　Episode-wise cumulative reward curves of different methods under varying traffic volumes

为验证强化学习训练所得策略的交通控制性能，本研究采用如下评估方案：在强化学习训练过程中，保存累计奖励最高的训练回合对应的目标网络参数作为最终控制策略。性能评估阶段采用与训练阶段相同的仿真环境，不过将每次的仿真时长 T 设置为 15 000 s，然后通过 5 次独立仿真试验进行测试，最终取 5 次试验结果的算术平均值作为性能指标。参考文献[16-17]，本研究选取以下 3 个指标用于评估：

1)平均行驶时间(average travel time，ATT)，所有车辆从起点到终点完成整个行程所花费的平均时间，单位为 s。

2)平均等待时间(average waiting time，AWT)，所有车辆因拥堵或等红灯等原因停止行驶而产生的平均等待时间，单位为 s。

3)车道平均车队长度(average queue length，AQL)，运行期间，各受控车道车队平均排队车辆长度的均值，单位为 m。

对 DQN、Dueling DQN、SAC 及本文方法进行仿真评估试验。表 2、表 3 和表 4 所示为各控制策略在

中国知网　https://www.cnki.net

不同车流量下车辆平均行驶时间、平均等待时间和车道平均车队长度的对比情况。从表 2 不同车流量下各控制策略车辆平均行驶时间对比结果来看，在过渡期时长 δ 为 5 s 的情况下，本研究提出的方法在高、中、低及混合车流量场景中，相比 DQN 控制策略的 ATT 分别降低了 3.58%、9.85%、12.19%和 3.44%；相比 Dueling DQN 控制策略的 ATT 分别降低了 3.09%、7.74%、16.25%和 25.15%。相比 SAC 控制策略的 ATT 分别降低了 7.86%、14.19%、24.01%和 9.50%。

表 2 不同车流量下各控制策略车辆平均行驶时间

Table 2 Average vehicle travel time by control strategy under different traffic flows s

车流量情况	SAC	DQN	Dueling DQN	DQN-δ(δ=3 s)	DQN-δ(δ=5 s)	DQN-δ(δ=7 s)
高车流量	148.94	142.33	141.61	163.04	137.23	183.48
中车流量	146.55	139.48	136.29	161.73	125.74	170.45
低车流量	160.03	138.50	145.21	217.78	121.61	218.18
混合车流量	180.15	168.85	217.82	275.23	163.04	152.09

从表 3 不同车流量下各控制策略车辆平均等待时间对比结果来看，在过渡期时长 δ 为 5 s 的情况下，本研究提出的方法在高、中、低车流量场景中，相比 DQN 控制策略的 AWT 分别减少了 7.35%、13.92%和 45.36%；相比 Dueling DQN 控制策略的 AWT 分别降低了 5.24%、10.96%和 51.94%。在混合车流量场景中，本文方法与 DQN 控制策略的性能表现相当，但与 Dueling DQN 控制策略相比，AWT 减少了 57.87%。相比 SAC 控制策略，在高、中、低及混合车流量场景中，本文方法的 AWT 分别减少了 22.94%、28.47%、63.50%和 12.17%。

表 3 不同车流量下各控制策略车辆平均等待时间

Table 3 Average vehicle waiting time by control strategy under different traffic flows s

车流量情况	SAC	DQN	Dueling DQN	DQN-δ(δ=3 s)	DQN-δ(δ=5 s)	DQN-δ(δ=7 s)
高车流量	56.11	46.67	45.63	66.43	43.24	80.72
中车流量	58.61	48.70	47.08	75.23	41.92	84.12
低车流量	82.14	54.83	73.33	98.04	29.96	133.50
混合车流量	109.06	89.60	227.35	312.78	95.78	243.90

从表 4 不同车流量下各控制策略车道平均车队长度对比结果来看，在过渡期时长 δ 为 5 s 的情况下，本研究提出的方法在高车流量场景中的表现与 DQN 及 Dueling DQN 控制策略相当。在混合车流量场景中，本研究的方法与 DQN 控制策略相比，也仅存在细微差异。然而，在中车流量和低车流量场景中，本研究方法的优势得到了充分体现。具体而言，相比 DQN 控制策略，本文方法的 AQL 分别降低了 28.5%和 74.59%。同时，与 Dueling DQN 控制策略对比，本文方法的 AQL 在中、低及混合车流量场景中分别降低了 15%、57.63%及 59.09%。相比 SAC 控制策略，本文方法的 AQL 在高、中、低及混合车流量场景中分别降低了 28.19%、52.63%、74.32%和 34.86%。

表 4 不同车流量下各控制策略车道平均车队长度

Table 4 Average queue length by control strategy under different traffic flows m

车流量情况	SAC	DQN	Dueling DQN	DQN-δ(δ=3 s)	DQN-δ(δ=5 s)	DQN-δ(δ=7 s)
高车流量	13.37	8.57	7.67	18.21	9.60	12.61
中车流量	9.69	6.42	5.40	8.91	4.59	10.26
低车流量	6.70	6.77	4.06	7.28	1.72	7.49
混合车流量	22.80	14.64	36.30	87.04	14.85	8.66

中国知网 https://www.cnki.net

由上述试验结果可知：本研究提出的 DQN-δ 方法在训练阶段表现出色，无论是在收敛速度还是训练稳定性方面均表现出优异性能；在试验评估阶段，相比较于 DQN、Dueling DQN 及 SAC 三种控制策略，DQN-δ 方法在 δ 为 5 s 时不同车流量场景下的多数评价指标上均有所提升。这表明交通信号相位的决策和执行分离机制不仅有效提升了交通通行效率，同时也为相邻相位切换之间引入了过渡期，过渡期内可实施信号预警措施，增强了交通系统的整体安全性。尽管试验结果表明 δ 为 5 s 时多数情况下具有最优性能，但在 δ 为 3 s、7 s 的多个场景中表现不如传统基线方法，这可能是：当 δ 为 7 s 时，决策提前量过大，在决策与执行期间交通状态可能发生显著变化（如队列增长、到达车辆增加），导致决策依据与执行状态脱节，削弱了控制对拥堵变化的响应能力；当 δ 为 3 s 时，虽然提供了相对实时的状态信息，但过渡期不足以为信号切换提供平滑过渡，容易引发车辆紧急减速或停止线前排队波动大，增强了状态观测的敏感性，导致控制策略性能的下降。

综上所述，过渡期时长 δ 并非越短或越长越优，其合理设置对强化学习交通信号控制的时效性、可预测性和收敛性具有重要作用。

4　结　语

本研究针对深度强化学习交通信号控制中，因相位无预兆突变可能带来的安全隐患问题，提出一种动作决策和执行分离的交通信号控制深度强化学习方法。本方法在交通信号相位切换之间引入过渡期，过渡期内可通信号预警告知交通参与者下一相位，避免做出错误决策，从而提升道路安全性。通过试验逐步优化过渡期时长，选出既能提升交通效率又能尽量延长过渡期的最优时长参数。通过 SUMO 交通仿真软件对 DQN、Dueling DQN、SAC 和本研究方法等四种控制策略进行仿真测试试验，结果表明：在不同车流量场景下，本研究方法能有效减少车辆平均行驶时间和车辆平均等待时间，并能显著缩短车道平均车队长度。试验结果验证了动作决策和执行分离机制的有效性。本研究针对十字交叉口的固定过渡期研究，未来可进一步探索自适应 δ 调整策略和研究在复杂交通场景（如同步交叉口、特殊交通事件等）时可能存在的局限性及应对措施，以增强控制系统在多变交通环境下的鲁棒性。

参考文献：

[1]　孙夕云，韩凤春. 基于 Vissim 仿真的交通拥堵负外部成本研究[J]. 中国人民公安大学学报（自然科学版），2023，29(4)：40.

[2]　王立夫，刘一铄，孔芝，等. 多车道交叉口交通信号与混合车辆轨迹协同优化框架[J]. 控制与决策，2024，39(11)：3567.

[3]　张功权，常方蓉，金杰灵，等. 安全驱动的城市交叉口自适应信号控制方法[J]. 中国安全生产科学技术，2023，19(10)：192.

[4]　翟子洋，郝茹茹，董世浩. 大规模智慧交通信号控制中的强化学习和深度强化学习方法综述[J]. 计算机应用研究，2024，41(6)：1618.

[5]　邱建东，解小平，汤旻安，等. 基于车流量的智能交通信号优化控制研究[J]. 计算机应用与软件，2018，35(1)：92.

[6]　张国有，张新武. 基于样本优化的 PPO 算法在单路口信号控制的应用[J]. 计算机系统应用，2024，33(6)：161.

[7]　CHU K F, LAM A Y S, LI V O K. Traffic signal control using end-to-end off-policy deep reinforcement learning [J]. IEEE Transactions on Intelligent Transportation Systems, 2022，23(7)：7184.

[8]　张玺君，聂生元，李喆，等. 基于自注意力机制的深度强化学习交通信号控制[J]. 交通运输系统工程与信息，2024，24(2)：96.

[9]　YANG X X, XU Y S, KUANG L, et al. An information fusion approach to intelligent traffic signal control using the joint methods of multiagent reinforcement learning and artificial intelligence of things[J]. IEEE Transactions on Intelligent Transportation Systems，2022，23(7)：9335.

[10]　左志强，刘正璇，王一晶. 基于车路云一体化的混合交通系统优化控制综述[J]. 控制与决策，2023，38(3)：577.

[11]　BELLMAN R. Dynamic programming[M]. Princeton: Princeton University Press, 1957.

中国知网　https://www.cnki.net

[12] 刘迪,吴林林,巩宇,等.基于滚动采样马尔可夫链模型的光伏时序功率模拟研究[J].电力科学与技术学报,2024,39(3):207.

[13] 杨硕,李时珍,赵中原,等.基于时序差分学习模型预测控制的一体化自动驾驶换道策略[J].机械工程学报,2024,60(10):329.

[14] KRAJZEWJCZ D, ERDAMNN J, BEHRISCH M, et al. Recent development and applications of SUMO: simulation of urban mobility[J]. International Journal on Advances in Systems and Measurements, 2012,5(3):128.

[15] 李斌,沈立,赵传信,等.基于柔性演员-评论家的通感算融合网络稳健资源优化[J].电子与信息学报,2025,47(4):948.

[16] 吐尔逊·买买提,曲古拉·图马尔拜,马洁,等.基于数据驱动的交叉口通行效率评价[J].科学技术与工程,2023,23(34):14857.

[17] HUA W, ZHENG G J, YAO H X, et al. Intellilight: a reinforcement learning approach for intelligent traffic light control[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. London:ACM, 2018:2496.

中国知网 https://www.cnki.net